ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ανάπτυξη Αυτόνομου Συστήματος Επίλυσης IT Συμβάντων με χρήση Fine-Tuned LLM και Αρχιτεκτονική Microservices

Ιωάννης Μαντζάκος

Επιβλέπων: Πάρις Μαστοροκώστας

Τμήμα Μηχανικών Πληροφορικής και Υπολογιστών – Πανεπιστήμιο Δυτικής Αττικής - 2026

Το πρόβλημα: κόστος & πολυπλοκότητα των βλαβών IT

Στα σύγχρονα περιβάλλοντα IT, ο χρόνος διακοπής λειτουργίας (downtime) και η καθυστέρηση επίλυσης έχουν άμεσο, υψηλό κόστος. Η χειροκίνητη διαλογή δεν κλιμακώνεται με τον όγκο των αιτημάτων.

Διαχείριση συμβάντων

Διαλογή & επίλυση υπό πίεση χρόνου (SLA, MTTR).

Root Cause Analysis (RCA)

Ο εντοπισμός της ρίζας είναι χρονοβόρος.

Ανάγκη Αυτοματοποίησης

Αξιόπιστη - αλλά και ασφαλής.

Κόστος Downtime ανά ώρα

33%

των επιχειρήσεων: μία ώρα βλάβης κοστίζει πάνω από 1 εκατ. δολάρια

81% ξεπερνούν τις $300K/ώρα

Πηγή: ITIC - Hourly Cost of Downtime Survey

Στόχος & Συνεισφορά

Ένα αυτόνομο σύστημα που επιλύει περιστατικά τεχνικής υποστήριξης πάνω στο IBM TechQA - και, κρίσιμα, γνωρίζει πότε ΔΕΝ πρέπει να απαντήσει.

1

Υβριδική Ανάκτηση

Σημασιολογική & λεξική αναζήτηση με επανακατάταξη.

2

Τεκμηριωμένη Παραγωγή

Απαντήσεις βασισμένες αποκλειστικά στα ανακτηθέντα έγγραφα.

3

Διδασκόμενη Αποχή

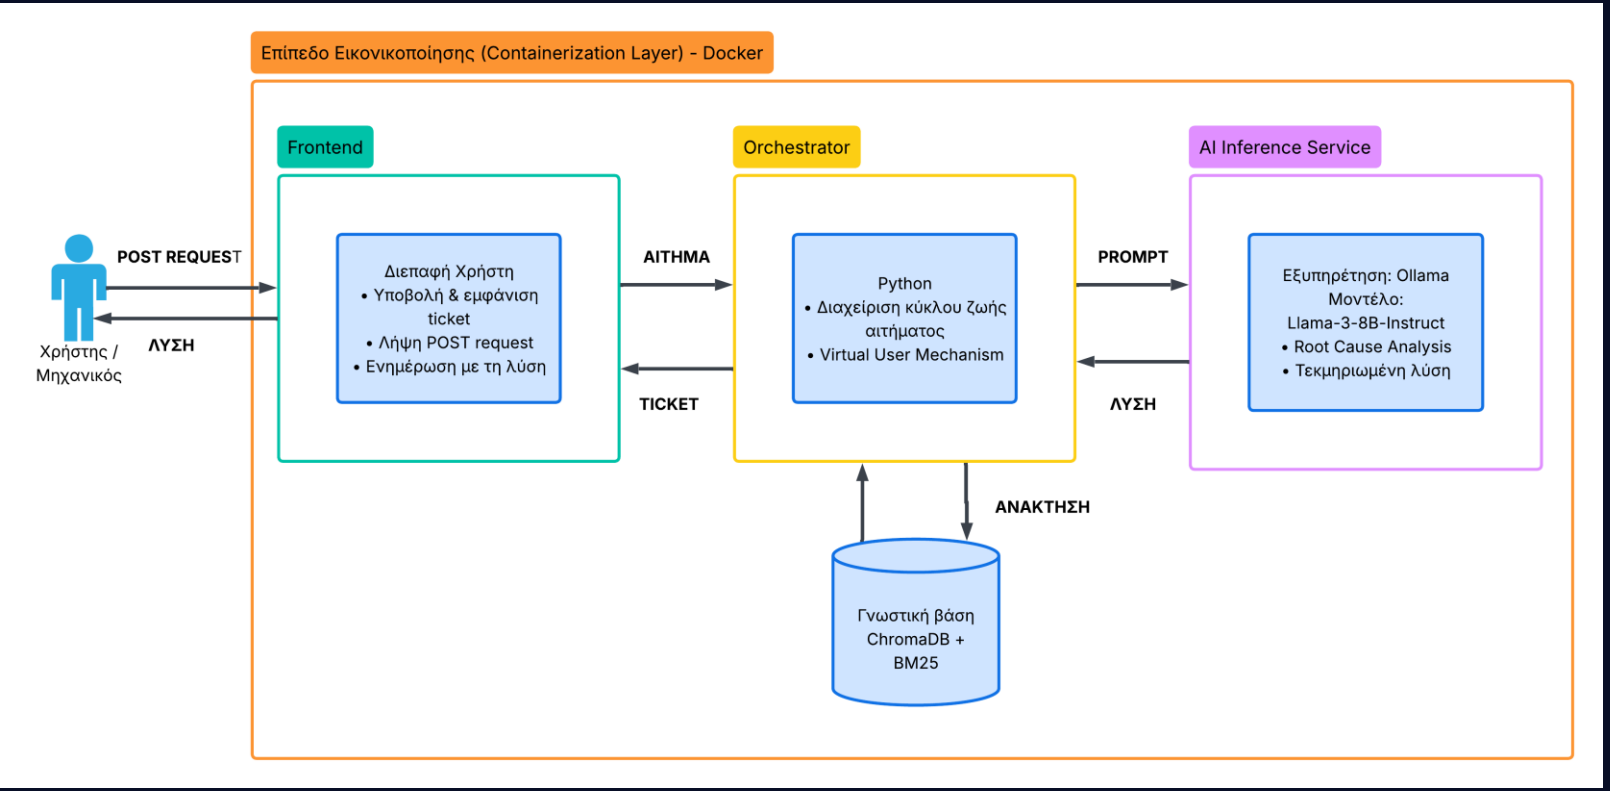
Το μοντέλο μαθαίνει να απέχει - υπερτερεί της ευρετικής πύλης.

4

Αυτόνομος βρόχος

Ολοκληρωμένη ροή στο Jira, χωρίς ανθρώπινη παρέμβαση.

Αρχιτεκτονική μικροϋπηρεσιών



Αποκεντρωμένη δομή

Frontend - διεπαφή χρήστη (Jira)

Orchestrator - Python, κύκλος ζωής αιτήματος

AI Inference - Ollama + Llama-3-8B-Instruct

Κάθε υπηρεσία σε απομονωμένο Docker container – πλήρης φορητότητα & ταχεία κλιμάκωση.

Το σύνολο Δεδομένων: IBM TechQA

Πραγματικά ερωτήματα τεχνικής υποστήριξης με επίσημα τεχνικά έγγραφα (technotes) της IBM - υψηλός ρεαλισμός και τεχνική πολυπλοκότητα.

801.998

technotes στη γνωσιακή βάση

Answerable

με τεκμηριωμένη λύση

Unanswerable

Χωρίς λύση – έλεγχος αποχής

Γιατί έχει σημασία η ανάμειξη: μόνο μέσω των μη επιλύσιμων περιστατικών αξιολογείται ουσιαστικά η ικανότητα του συστήματος να αναγνωρίζει τα όρια της γνώσης του και να απέχει, αντί να παράγει εσφαλμένη λύση.

ΣΤΆΔΙΟ Α

Υβριδική ροή ανάκτησης

1 **Πυκνή Αναζήτηση**

ChromaDB - embeddings all-MiniLM-L6-v2 (σημασιολογική ομοιότητα)

2 **Λεξική Αναζήτηση**

BM25 σε 801.998 έγγραφα (ακριβείς ταυτίσεις όρων)

3 **Επανακατάταξη**

CrossEncoder reranker – εξειδικευμένος (fine-tuned) στο TechQA

4 **Σύνταξη Βαθμολογιών**

Score fusion με βάρη 0,35 / 0,35 / 0,30

Ιδέα

Κανένας μόνος μηχανισμός δεν αρκεί.

Η σημασιολογική πιάνει το νόημα και η λεξική τους τεχνικούς όρους. Η σύνταξη τα συνδυάζει και ο reranker εξυγιάνει την τελική κατάταξη.

ΣΤΆΔΙΟ Α

Αποτελέσματα Ανάκτησης

~65%

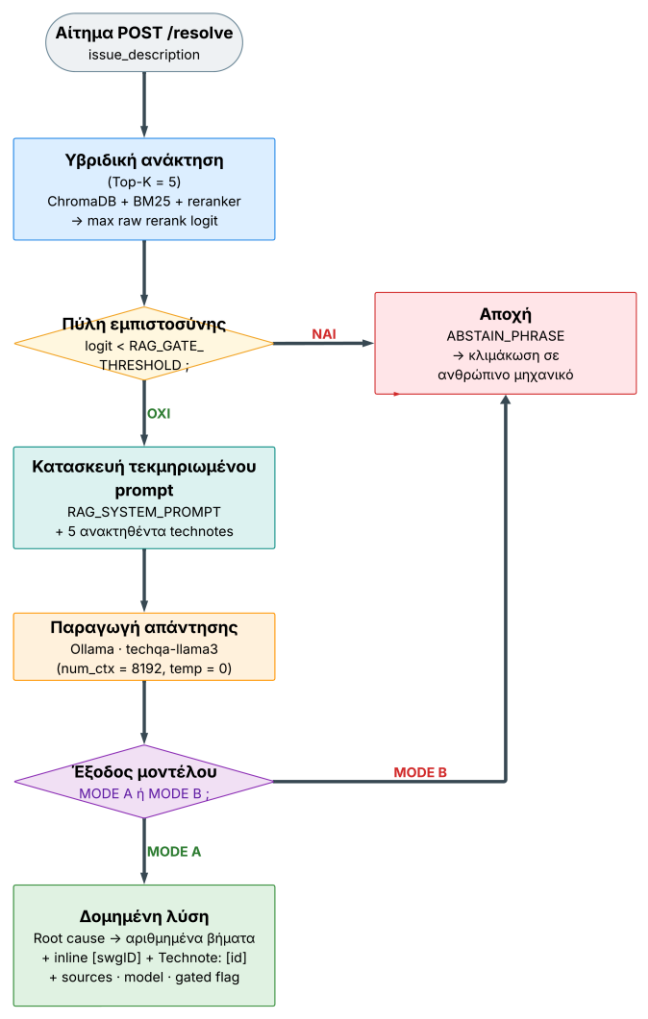
Recall@5 - το ορθό έγγραφο στα 5 πρώτα

~0,55

MRR - Μέση Αντίστροφη Κατάταξη

Η ανάκτηση θέτει την «οροφή απόδοσης». Όταν το ορθό έγγραφο δεν ανακτηθεί (recall@5 ∼65% ⇒ ∼35% αστοχία), καμία παραγωγή δεν μπορεί να δώσει σωστή, τεκμηριωμένη λύση. Αυτό ακριβώς, καθιστά αναγκαία τη διδασκόμενη αποχή στο Στάδιο Β.

Παραγωγή Τεκμηριωμένης Λύσης - /resolve



Αυστηρή λογική «είτε “Χ” / είτε “Υ”»

MODE A - Λύση

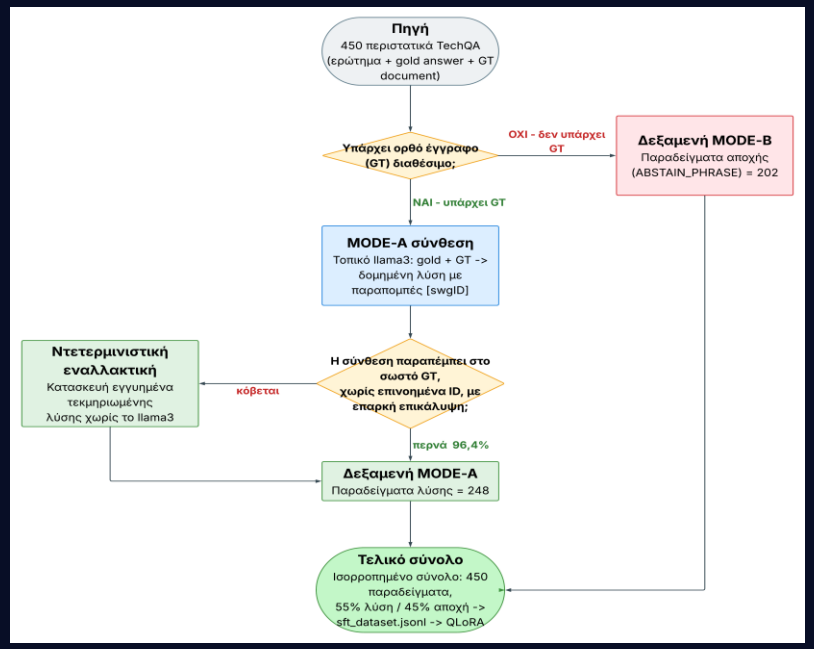
Root cause - αριθμημένα βήματα, με ρητές παραπομπές [swgID] στα technotes.

MODE B - Αποχή

Σταθερή φάση αποχής - κλιμάκωση σε μηχανικό. Καμία επικίνδυνη «μαντεψιά».

Δύο σημεία αποχής: (1) πύλη εμπιστοσύνης πριν την παραγωγή και (2) διδασκόμενη αποχή του μοντέλου.

Κατασκευή δεδομένων εκπαίδευσης και εξειδίκευση με QLoRA



450 παραδείγματα SFT

248 λύσεις / 202 αποχής - απόσταξη γνώσης

Φίλτρο πιστότητας

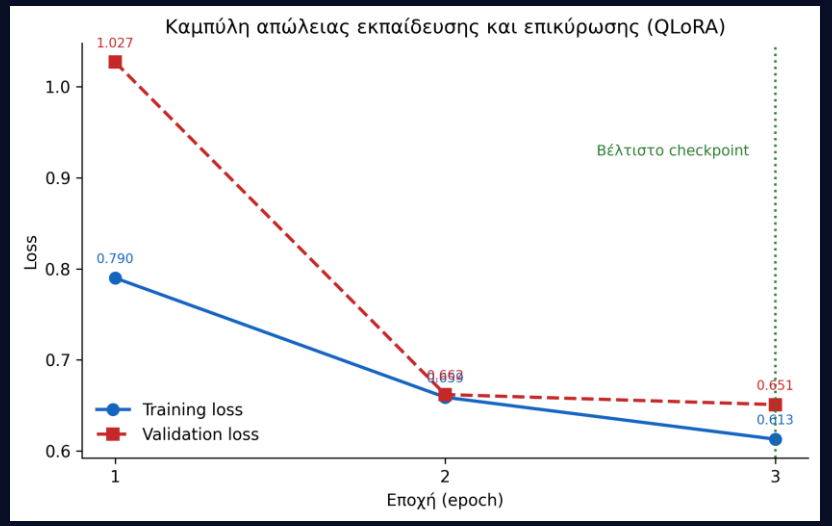
96,4% των στόχων περνούν τον έλεγχο τεκμηρίωσης

4-bit NF4

Κβαντικοποίηση του παγωμένου βασικού μοντέλου - χωράει σε GPU καταναλωτή

LoRA r=16, α=32

Εκπαίδευση διεξήχθη για τρεις εποχές (epochs) - παρουσίασε την ελάχιστη απώλεια επικύρωσης



ΣΤΆΔΙΟ Β

Η καρδία της συνεισφοράς: Διδασκόμενη αποχή

Δύο τρόποι να πει «δεν ξέρω» ένα σύστημα - με πολύ διαφορετική αξιοπιστία.

Ευρετική πύλη

Απορρίπτει βάσει κατωφλίου εμπιστοσύνης ανάκτησης.

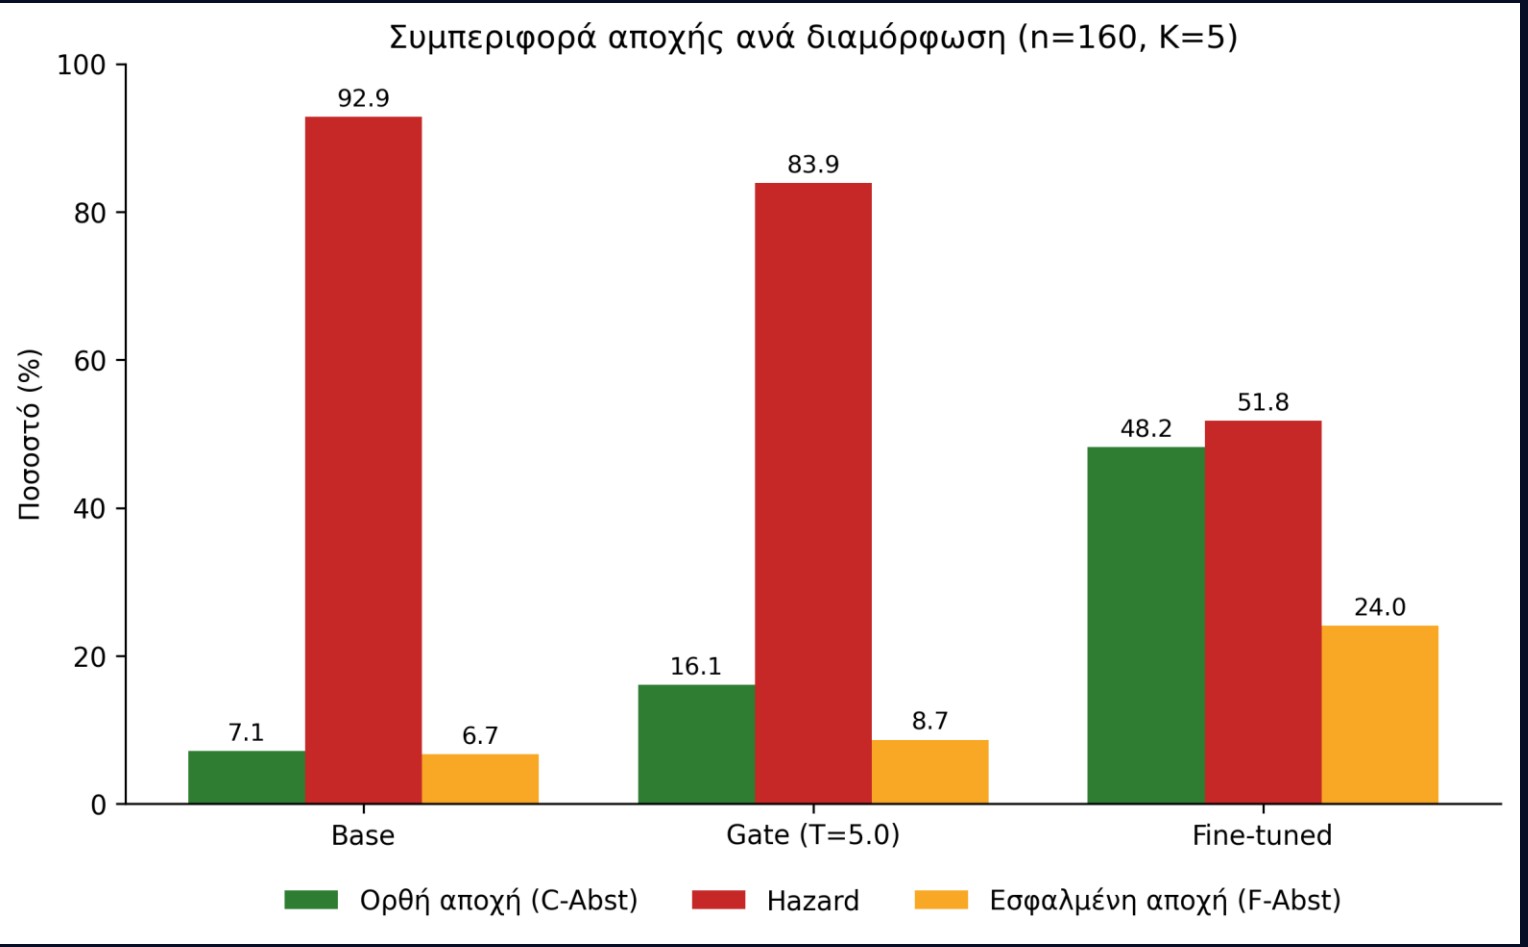
✗ Οι κατανομές «σωστό» / «λάθος» επικαλύπτονται - κανένα κατώφλι δεν τις χωρίζει.
✗ Στατιστικά μη σημαντική βελτίωση.

Διδασκόμενη αποχή

Το μοντέλο μαθαίνει ΠΟΤΕ να απέχει, μέσω εξειδίκευσης (MODE B).

✓ Ενσωματωμένη κρίση, όχι εξωτερικό κατώφλι.
✓ Εντάσσεται στην επιλεκτική πρόβλεψη (selective prediction).

Αποτελέσματα: base ⇒ gate ⇒ fine-tuned



Στατιστική σημασία (Wilson 95%)

Base vs Gate:
τα διαστήματα επικαλύπτονται - μη σημαντική βελτίωση.

Fine-tuned:
διακριτό διάστημα - αναμφισβήτητα σημαντική βελτίωση.

Hazard: 92,9% ⇒ 51,8% (υποδιπλασιασμός)

ΣΤΆΔΙΟ Γ

Αυτόνομος βρόχος σε πλατφόρμα Jira

1 → **Pseudo-users**
Δημιουργούν tickets από TechQA

2 → **Jira**
Νέα tickets στο board

3 → **Worker**
Ανίχνευση (polling) & κλήση /resolve

4 → **Απόφαση**
Πολιτική Κλιμάκωσης

5 → **Εγγραφή πίσω**
Σχόλιο - Ετικέτα - Ανάθεση

Πολιτική Κλιμάκωσης – τρεις έλεγχοί χωρίς ground truth

MODE-B;
Το μοντέλο δηλώνει αποχή

Gate;
Χαμηλή εμπιστοσύνη ανάκτησης

Faithfulness;
Καμία έγκυρη παραπομπή

Οποιοσδήποτε «ναι» ⇒ κλιμάκωση. Και οι τρεις «όχι» ⇒ αυτόματη επίλυση.

Αποτελέσματα σε παραγωγικό περιβάλλον (n=200)

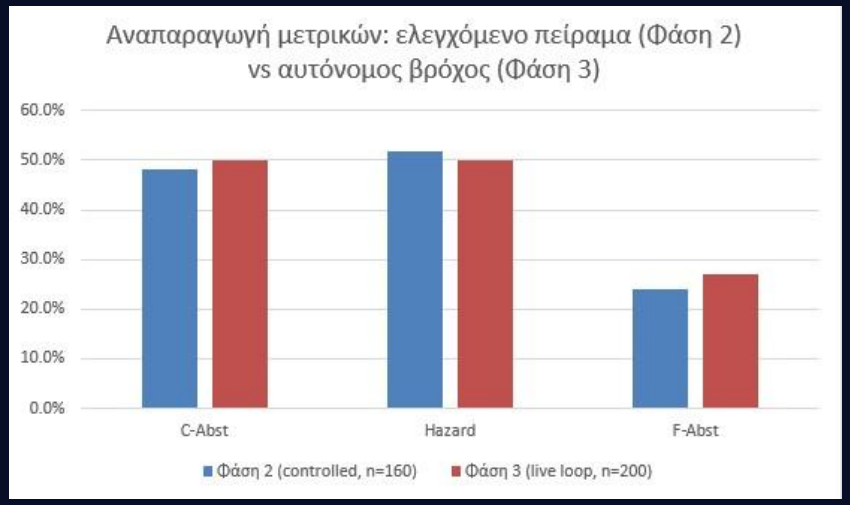
62%
αυτόματη επίλυση

38%
κλιμάκωση

60,6%
ορθή αυτόματη λύση

97,4%
αιτία: διδασκόμενη αποχή

Αναπαραγωγή των μετρικών της Φάσης Β και Φάσης Γ



Η κρίσιμη επικύρωση

Η συμπεριφορά που μετρήθηκε απομονωμένα (Φάση Β) διατηρείται όταν όλες οι συνιστώσες λειτουργούν μαζί – το σύστημα είναι συνεκτικό, όχι απλώς άθροισμα τμημάτων.

Συμπεράσματα

Διδασκόμενη Αποχή > Ευρετική

Υπερτερεί ουσιωδώς & στατιστικά σημαντικά, επί σταθερής βάσης ανάκτησης.

Δραστική μείωση κινδύνου

Το hazard υποδιπλασιάστηκε (92,9% ⇒ ~50%) χωρίς υποβάθμιση πιστότητας.

Επικύρωση σε Παραγωγή

Ο αυτόνομος βρόχος αναπαρήγαγε τα αποτελέσματα σε ρεαλιστικό περιβάλλον (n=200).

Έντιμο Όριο

Εναπομείναν hazard ~50%.

Ο έλεγχος πιστότητας δεν πιάνει απαντήσεις εδραζόμενες σε ανακτηθέν αλλά άσχετο έγγραφο. Παραμένει, όμως, υποδιπλάσιο του base (92,9%).

ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ

Βελτίωση Ανάκτησης

Αύξηση recall ⇒ λιγότερα GT-missing ⇒ μικρότερο hazard

Δυναμική πολιτική κλιμάκωσης

Ρύθμιση της αυστηρότητας ανάλογα με το κόστος του πεδίου: πιο συντηρητική όπου το λάθος κοστίζει, πιο επιθετική όπου προέχει η ταχύτητα

Ανθρώπινη ανατροφοδότηση

Συνεχής βελτίωση μέσω των διορθώσεων των μηχανικών

Ευχαριστώ για την προσοχή σας

Ερωτήσεις;