

ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ

ΣΧΟΛΗ ΜΗΧΑΝΙΚΩΝ

ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ανάπτυξη Αυτόνομου Συστήματος Επίλυσης IT Συμβάντων με χρήση Fine-Tuned LLM και Αρχιτεκτονική Microservices

ΙΩΑΝΝΗΣ ΜΑΝΤΖΑΚΟΣ
Α.Μ. 21390126

Εισηγητής: ΠΑΡΙΣ ΜΑΣΤΟΡΟΚΩΣΤΑΣ, Καθηγητής

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ανάπτυξη Αυτόνομου Συστήματος Επίλυσης IT Συμβάντων με χρήση Fine-Tuned LLM και Αρχιτεκτονική Microservices

ΙΩΑΝΝΗΣ ΜΑΝΤΖΑΚΟΣ
Α.Μ. 21390126
Εισηγητής: ΠΑΡΙΣ, ΜΑΣΤΟΡΟΚΩΣΤΑΣ, Καθηγητής

Εγκρίθηκε από την εξεταστική επιτροπή στις 21/09/2026:		
PARIS MASTOROKOSTAS Digitally signed by PARIS MASTOROKOSTAS Date: 2026.09.21 20:31:59 +03'00'	Φοίβος-Απόστολος Μυλωνάς - ψηφιακά υπογεγραμμένο 2026.09.21 22:20:27 +03'00'	CHRISTOS TROUSSAS Digitally signed by CHRISTOS TROUSSAS Date: 2026.10.01 13:23:17 +03'00'
ΠΑΡΙΣ, ΜΑΣΤΟΡΟΚΩΣΤΑΣ, Καθηγητής	**ΦΟΙΒΟΣ-ΑΠΟΣΤΟΛΟΣ, ΜΥΛΩΝΑΣ, Καθηγητής**	**ΧΡΗΣΤΟΣ, ΤΡΟΥΣΣΑΣ, Αναπληρωτής Καθηγητής**

ΔΗΛΩΣΗ ΣΥΓΓΡΑΦΕΑ ΜΕΤΑΠΤΥΧΙΑΚΗΣ ΕΡΓΑΣΙΑΣ

«Βεβαιώνω ότι είμαι συγγραφέας αυτής της Διπλωματικής εργασίας και κάθε βοήθεια την οποία είχα για την προετοιμασία της, είναι πλήρως αναγνωρισμένη και αναφέρεται στην εργασία. Επίσης, οι όποιες πηγές από τις οποίες έκανα χρήση δεδομένων, ιδεών ή λέξεων, είτε ακριβώς είτε παραφρασμένες, αναφέρονται στο σύνολό τους, με πλήρη αναφορά στους συγγραφείς, τον εκδοτικό οίκο ή το περιοδικό, συμπεριλαμβανομένων και των πηγών που ενδεχομένως χρησιμοποιήθηκαν από το διαδίκτυο. Επίσης, βεβαιώνω ότι αυτή η εργασία έχει συγγραφεί από μένα αποκλειστικά και αποτελεί προϊόν πνευματικής ιδιοκτησίας τόσο δικής μου, όσο και του Ιδρύματος.».

Ο Δηλών
Ιωάννης Μαντζάκος



ΕΥΧΑΡΙΣΤΙΕΣ

Με την ολοκλήρωση της παρούσας διπλωματικής εργασίας, αισθάνομαι την ανάγκη να ευχαριστήσω θερμά όσους συνέβαλαν στην υλοποίησή της. Αρχικά, θα ήθελα να εκφράσω τις ειλικρινείς μου ευχαριστίες προς τον επιβλέποντα καθηγητή μου, κ. Πάρι Μαστοροκώστα, για την πολύτιμη καθοδήγηση, την επιστημονική του αρτιότητα και την άψογη συνεργασία που μου έδειξε.

Παράλληλα, θα ήθελα να ευχαριστήσω από καρδίας την οικογένειά μου και τους φίλους μου. Η αμέριστη συμπαράσταση, η υπομονή και η ενθάρρυνσή τους καθ' όλη τη διάρκεια των σπουδών μου, και ιδιαίτερα κατά την περίοδο εκπόνησης αυτής της εργασίας, αποτέλεσαν το στήριγμα που μου επέτρεψε να ολοκληρώσω με επιτυχία αυτόν τον σημαντικό κύκλο της ακαδημαϊκής μου πορείας.

ΠΕΡΙΛΗΨΗ

Η παρούσα διπλωματική εργασία ασχολείται με τον σχεδιασμό και την ανάπτυξη ενός αυτόνομου συστήματος επίλυσης συμβάντων πληροφορικής (IT Incident Resolution), το οποίο βασίζεται σε αρχιτεκτονική μικροϋπηρεσιών (microservices) και στην αξιοποίηση Μεγάλων Γλωσσικών Μοντέλων (LLMs). Κεντρικό αντικείμενο της μελέτης αποτέλεσε η αυτοματοποιημένη διαχείριση τεχνικών αιτημάτων μέσω ενός ευφυούς πράκτορα (AI Agent), ο οποίος εκπαιδεύτηκε στο εξειδικευμένο σύνολο δεδομένων IBM TechQA.

Ο αναπτυχθείς πράκτορας διαθέτει τη δυνατότητα ανάλυσης εισερχόμενων tickets και την αυτόματη παραγωγή τεκμηριωμένων τεχνικών λύσεων. Το σύστημα υλοποιήθηκε ως μια πλήρως εικονικοποιημένη εφαρμογή μηχανικής μάθησης (MLOps). Η αρχιτεκτονικής του συστήματος στηρίχθηκε αποκλειστικά στη σύνθεση εργαλείων ανοιχτού κώδικα. Η διεπαφή χρήστη (frontend) και η διαχείριση των αιτημάτων πραγματοποιήθηκαν μέσω ολοκληρωμένων λύσεων διαχείρισης έργου, ενώ η τροφοδοσία του συστήματος με δεδομένα προσομοιώθηκε μέσω μηχανισμού εικονικών χρηστών, οι οποίοι υπέβαλαν αιτήματα POST σε API.

Στο επίπεδο της τεχνικής νοημοσύνης, χρησιμοποιήθηκε το μοντέλο Llama-3-8B-Instruct, οι παράμετροι του οποίου βελτιστοποιήθηκαν με την μέθοδο QLoRA. Η εκτέλεση του μοντέλου και η παροχή των αποκρίσεων σε πραγματικό χρόνο επιτεύχθηκε μέσω των εργαλείων Ollama εντός containers. Ο συντονισμός του ευφυούς πράκτορα υλοποιήθηκε σε γλώσσα προγραμματισμούς Python, διασφαλίζοντας την αδιάλειπτη παρακολούθηση των δεδομένων και την ενημέρωση των αιτημάτων με τις προτεινόμενες λύσεις. Η εργασία ολοκληρώθηκε με την πλήρη ενοποίηση των υποσυστημάτων και τη δημιουργία μιας εφαρμογής, αποδεικνύοντας την ικανότητα του συστήματος να ανταποκρίνεται αποτελεσματικά σε πραγματικά τεχνικά προβλήματα.

ΕΠΙΣΤΗΜΟΝΙΚΗ ΠΕΡΙΟΧΗ: Τεχνητή Νοημοσύνη, Μηχανική Λογισμικού, Επιχειρησιακή Πληροφορική & Διαχείριση IT Υπηρεσιών
ΛΕΞΕΙΣ ΚΛΕΙΔΙΑ: Μεγάλα Γλωσσικά Μοντέλα, Ευφυείς Πράκτορές, Αρχιτεκτονική Μικροϋπηρεσιών, Βελτιστοποίηση Παραμέτρων, Docker & Containerization, MLOps

ABSTRACT

The present thesis concerns the design and development of an autonomous IT incident resolution system based on a microservices architecture and the use of Large Language Models (LLMs). The central focus of the study was the automated management of technical requests through an AI agent, which was trained on the specialized IBM TechQA dataset.

The developed agent is capable of analyzing incoming support tickets and automatically generating documented technical solutions. The system was implemented as a fully containerized application using the Docker platform, adopting modern machine learning operations (MLOps) practices. The system architecture relied exclusively on a combination of open-source tools. The user interface (frontend) and request management were implemented using integrated project management solutions, while the system's data feed was simulated via a mechanism of virtual users who submitted PST requests to an API.

In terms of artificial intelligence, the Llama-3-8B-Instruct model was used, whose parameters were optimized using the QLoRA method. The model was executed and responses were provided in real time using the Ollama tool within containers. The intelligent agent was implemented in the Python programming language, ensuring uninterrupted data monitoring and the updating of queries with the proposed solutions. The project was completed with the full integration of the subsystems and the creation of a proof-of-concept application, demonstrating the system's ability to effectively address real-world technical problems.

RESEARCH AREA: Artificial Intelligence, Software Engineering, Business Informatics & IT Service Management
KEYWORDS: Large Language Models, Intelligent Agents, Microservices Architecture, Parameter Optimization, Docker & Containerization, MLOps

Περιεχόμενα

ΠΕΡΙΛΗΨΗ 9
ABSTRACT 10
ΣΥΝΤΟΜΟΓΡΑΦΙΕΣ 16
ΛΕΞΙΛΟΓΙΟ 17
1. ΕΙΣΑΓΩΓΗ 21
1.1 Σημαντικότητα Αντικειμένου και διατύπωση προβλήματος 21
1.2 Θεωρητικό Υπόβαθρο: Παραγωγική Τεχνητή Νοημοσύνη, Ανάκτηση Πληροφορίας και Εξόρυξη Δεδομένων 24
1.3 Σκοπός, Αντικείμενο και Στόχοι της Διατριβής 28
2. Αρχιτεκτονική 30
2.1 Αρχιτεκτονική Δομή Μικροϋπηρεσιών (Microservices Architecture) 30
2.2 Ανάλυση και Χαρακτηριστικά του Εξειδικευμένου Συνόλου Δεδομένων (IBM TechQA Dataset) 32
2.3 Μεθοδολογικό Πλαίσιο και Στάδια Υλοποίησης του Έργου 32
3. Ανάκτηση Πληροφορίας και Βελτιστοποίηση Κατάταξης Δεδομένων από το TechQA Dataset (Στάδιο Α) 34
3.1 Υλοποίηση Μοντέλου Αναφοράς (Baseline Retrieval Model) 34
3.2 Προεπεξεργασία Ερωτημάτων και Στρατηγικές Φιλτραρίσματος Πληροφοριακού Θορύβου 38
3.3 Μηχανισμοί Σύνθεσης Βαθμολογιών (Score Fusion) και Επανακατατάξης βάσει Τεχνικών Όρων (Overlap Scoring) 41
3.4 Αξιολόγηση και Επίδραση Εναλλακτικών Μοντέλων Διανυσματικών Αναπαραστάσεων 43
3.5 Πειραματικά Αποτελέσματα και Συγκριτική Ανάλυση για το Στάδιο Α 45
4. Ενσωμάτωση και εξειδίκευση μεγάλων γλωσσικών μοντέλων (Στάδιο Β) 49
4.1 Αρχιτεκτονική Ενσωμάτωση και Containerization του Μοντέλου Llama-3-8B-Instruct 50
4.2 Εξειδίκευση Παραμέτρων στο Τεχνικό Πεδίο (Domain-Specific Fine-Tuning) μέσω της Μεθόδου QLoRA 53
4.3 Αποτελέσματα και Αξιολόγηση της Απόδοσης του Γλωσσικού Μοντέλου για το Στάδιο Β 57
5. Αυτοματοποιημένη ροή εργασίας και διεπαφή χρήστη (Στάδιο Γ) 63
5.1 Ανάπτυξη Μηχανισμού Προσομοίωσης Επιχειρησιακού Φόρτου μέσω Εικονικών Χρηστών 63
5.2 Ενοποίηση με Πλατφόρμες Διαχείρισης Έργου (Jira Service Desk Integration) και Αυτοματοποιημένες Ροές 66
5.3 Αποτελέσματα και Αξιολόγηση Λειτουργικότητας για το Στάδιο Γ 73
6. Συνολική προσομοίωση και συμπεράσματα 78
6.1 End-to-End Προσομοίωση σε Περιβάλλον Παραγωγής 78
6.2 Ανάλυση Αποτελεσμάτων, Συμπεράσματα και Μελλοντικές Επεκτάσεις 79

Βιβλιογραφία 81
Παράρτημα 83
Παράρτημα Α 83
Παράρτημα Β 84
Παράρτημα Γ 87
Παράρτημα Δ 91
Παράρτημα Ε 92
Παράρτημα ΣΤ 93
Παράρτημα Ζ 95
Παράρτημα Η 100
Παράρτημα Θ 101

ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ

Εικόνα 1 - Dashboard Monitoring σε πραγματικό χρόνο 21
Εικόνα 2 - Παρτίδα Σκάκι του Garry Kasparov εναντίων της Μηχανής TN “Deep Blue” της IBM 24
Εικόνα 3 - Αποτέλεσμα Μοντέλου Αναφοράς 37
Εικόνα 4 - Αποτελέσματα Ανάκτησης έπειτα την επεξεργασία Ερωτήματος και Θορύβου 39
Εικόνα 5 - Μέρος του Ερωτήματος "Q022" 40
Εικόνα 6 - Μέρος του Ερωτήματος "Q027" 40
Εικόνα 7 - Μέρος του Ερωτήματος "Q039" 40
Εικόνα 8 - Μέρος του ερωτήματος "Q034" 40
Εικόνα 9 - Αποτελέσματα Ανάκτησης με κατανομή βαρών 0,35/0,35/0,30 και χρήση finetuned reranker 42
Εικόνα 10 - Αποτελέσματα Ανάκτησης με κατανομή βαρών 0,35/0,35/0,30 και χρήση generic reranker (ms-marco-MiniLM) 42
Εικόνα 11 - Αποτελέσματα Ανάκτησης έπειτα από χρήση BGE embedding model και BGE reranker 44
Εικόνα 12 - Στιγμιότυπο CSV αρχείου 45
Εικόνα 13 - Αποτελέσματα Συστήματος με BGE ως Embedding Model 46
Εικόνα 14 - Αποτελέσματα Συστήματος με all-MiniLM-L6-v2 ως Embedding Model 47
Εικόνα 15 - Δημιουργία ticket από πολλαπλούς reporters 64
Εικόνα 16 - Κατάσταση και Λεπτομέρειες ticket 70
Εικόνα 17 – «Σκέψη» και Κλιμάκωση από τον AI Agent / Εσωτερικό σχόλιο 70
Εικόνα 18 - Σύνδεση με λογαριασμό pseudo user 71
Εικόνα 19 - Απάντηση κλιμάκωσης προς pseudo user 71
Εικόνα 20 - Στιγμιότυπο τίτλου και περιγραφής Ticket 71
Εικόνα 21 - "Σκέψη" AI Agent / Εσωτερικό σχόλιο 72
Εικόνα 22 - Απάντηση του AI-Agent προς τον χρήστη 72
Εικόνα 23 - Auto Resolve του ticket 73

ΚΑΤΑΛΟΓΟΣ ΣΧΗΜΑΤΩΝ

Σχήμα 1 - Γράφημα κόστους downtime ανά ώρα από δημόσια στοιχεία του ITIC 22
Σχήμα 2 - Incident Lifecycle 22
Σχήμα 3 - Ενδεικτικό Παράδειγμα MTTF/MTTR επεξήγηση snowball effect 23
Σχήμα 4 - Χρονολόγιο Εξέλιξης TN 25
Σχήμα 5 - Κατηγορίες ML 25
Σχήμα 6 - Precision vs Recall tradeoff curve 27
Σχήμα 7 - Διαδικασίας Ανακάλυψης Γνώσης σε Σύνολα Δεδομένων 28
Σχήμα 8 - MLOps Pipeline 30
Σχήμα 9 - Διάγραμμα Αρχιτεκτονικής Microservices 31
Σχήμα 10 - Διάγραμμα Λειτουργίας του RAG 32
Σχήμα 11 - Διάγραμμα Gantt υλοποίησης Φάσεων έργου 33
Σχήμα 12 - Διάγραμμα Αρχιτεκτονικής /resolve 51
Σχήμα 13 - Pipeline (Αγωγός) SFT Dataset 54
Σχήμα 14 - Καμπύλη απώλειας εκπαίδευσης (QLoRA) 55
Σχήμα 15 - Συμπεριφορά αποχής ανά διαμόρφωση (C-Abst/Hazard/F-Abst) 58
Σχήμα 16 - Ορθή Αποχή με 95% διάστημα Εμπιστοσύνης Wilson 59
Σχήμα 17 - Διάγραμμα ροής δημιουργίας ticket 64
Σχήμα 18 - Αυτόνομος βρόχος 67
Σχήμα 19 - Διάγραμμα πολιτικής κλιμάκωσης 68
Σχήμα 20 - Μηχανή καταστάσεων (κύκλος ζωής ticket) 69
Σχήμα 21 - Αναπαραγωγή μετρικών: ελεγχόμενο πείραμα (Φάση 2) εναντίων αυτόνομος βρόχος (Φάση 3) 75
Σχήμα 22 - Ποσοστό κλιμάκωσης ανά τύπο περιστατικού 75

ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

Πίνακας 1 - Σύγκριση Μετρικών ανά Διαμόρφωση με K = 5 60
Πίνακας 2 - Πίνακας αποτελεσμάτων n=200..... 74
Πίνακας 3 - Πίνακας Αιτιών Κλιμάκωσης 76

ΣΥΝΤΟΜΟΓΡΑΦΙΕΣ

AI/TN	Artificial Intelligence - Τεχνητή Νοημοσύνη
AI-a	AI Agent - Ευφυής Πράκτορας
API	Application Programming Interface - Διεπαφή Προγραμματισμού Εφαρμογών
BGE	BAAI General Embedding - οικογένεια μοντέλων διανυσματικής αναπαράστασης
BM25	Best Matching 25 - αλγόριθμος λεξικής κατάταξης
CPU	Central Processing Unit - Κεντρική Μονάδα Επεξεργασίας - Επεξεργαστής
DM/ΕΔ	Data Mining - Εξόρυξη Δεδομένων
GGUF	Μορφή αρχείου για την αποθήκευση και διανομή γλωσσικών μοντέλων
GPU	Graphics Processing Unit - Μονάδα Επεξεργασίας Γραφικών
GT	Ground Truth - έγγραφο/απάντηση αναφοράς
IR/ΑΠ	Information Retrieval - Ανάκτηση Πληροφορίας
IT	Information Technology - Τεχνολογία Πληροφορικής
LLM	Large Language Model - Μεγάλο Γλωσσικό Μοντέλο
MRR	Mean Reciprocal Rank - Μέση Αντίστροφη Κατάταξη
MTTF	Mean Time to Failure - Μέσος Χρόνος Μέχρι την Αστοχία
MTTR	Mean Time to Repair - Μέσος Χρόνος Αποκατάστασης
NLP	Natural Language Processing - Επεξεργασία Φυσικής Γλώσσας
PRF	Probabilistic Relevance Framework - Πιθανοθεωρητικό Πλαίσιο Σχετικότητας
PRP	Probability Ranking Principle - Αρχή Κατάταξης Πιθανοτήτων
QLoRA	Quantized Low-Rank Adaptation - Κβαντικοποιημένη προσαρμογή χαμηλής τάξης
RAG	Retrieval-Augmented Generation - Ανάκτηση-Επαυξημένη Παραγωγή
RRF	Reciprocal Rank Fusion - Σύντηξη Αντίστροφης Κατάταξης
SLA	Service Level Agreement - Συμφωνία Επιπέδου Υπηρεσιών

ΛΕΞΙΛΟΓΙΟ

Όρος	Περιγραφή
Αβάσιμες / ευλογοφανείς απαντήσεις (hallucination)	Απαντήσεις που παράγει το μοντέλο χωρίς πραγματική τεκμηρίωση.
αδιαλειψία (idempotency)	Η ιδιότητα μια ενέργεια να δίνει το ίδιο αποτέλεσμα όσες φορές κι αν εκτελεστεί.
Ακρίβεια (Precision)	Το ποσοστό των ανακτηθέντων αποτελεσμάτων που είναι όντως σχετικά.
ακριβείς ταυτίσεις όρων (exact matches)	Περιπτώσεις όπου οι όροι του ερωτήματος εμφανίζονται αυτούσιοι στο έγγραφο.
Ανάκληση (Recall)	Το ποσοστό των σχετικών εγγράφων που κατάφερε να ανακτήσει το σύστημα.
ανάκτηση-επαυξημένη παραγωγή (Retrieval-Augmented Generation)	Παραγωγή απάντησης με βάση έγγραφα που ανακτήθηκαν πρώτα.
από-διπλασιάζονται (deduplication)	διαδικασία κατά την οποία αφαιρούνται τα διπλότυπα δεδομένα
απόσταξη γνώσης (knowledge distillation)	Μεταφορά γνώσης από ένα μοντέλο ή πηγή σε ένα μικρότερο ή εξειδικευμένο μοντέλο.
Αρχή Κατάταξης Πιθανοτήτων (Probability Ranking Principle)	Αρχή που κατατάσσει τα έγγραφα κατά φθίνουσα πιθανότητα σχετικότητας.
ασυμφωνία λεξιλογίου (vocabulary mismatch)	Όταν ερώτημα και έγγραφο εννοούν το ίδιο πράγμα με διαφορετικές λέξεις.
βαθμολογία επικάλυψης όρων (overlap score)	Μέτρο της επικάλυψης τεχνικών όρων μεταξύ ερωτήματος και εγγράφου.
«βέβαια παραπλανητικά» έγγραφα confident distractor)	Άσχετα έγγραφα που μοιάζουν σχετικά και παραπλανούν το μοντέλο.
γνωστική αυτοματοποίηση (cognitive automation)	Αυτοματοποίηση εργασιών που απαιτούν κρίση, όχι μόνο μηχανικά βήματα.
διακριτικά σύμβολα (tokens)	Οι στοιχειώδεις μονάδες κειμένου που επεξεργάζεται ένα γλωσσικό μοντέλο.
διαρροή πληροφορίας (information leakage)	Όταν πληροφορία της αξιολόγησης διαρρέει και νοθεύει τα αποτελέσματα.

διαχείριση συμβάντων (incident management)	Η διαδικασία καταγραφής και επίλυσης περιστατικών ή βλαβών IT.
εκ των υστέρων επεξεργασία (post-processing)	Επεξεργασία των αποτελεσμάτων μετά την παραγωγή τους.
εμπλουτισμένο ερώτημα (prompt)	Το κείμενο εισόδου προς το μοντέλο, με το ερώτημα και τα συμφραζόμενα.
εξειδίκευση / βελτιστοποίηση (fine-tuning)	Περαιτέρω εκπαίδευση ενός έτοιμου μοντέλου σε συγκεκριμένο πεδίο.
επέκταση ερωτήματος (query expansion)	Εμπλουτισμός του ερωτήματος με επιπλέον όρους για καλύτερη ανάκτηση.
επιλεκτική πρόβλεψη (selective prediction)	Το μοντέλο απαντά μόνο όταν είναι αρκετά σίγουρο, αλλιώς απέχει.
επίπεδο εικονικοποίησης (Containerization Layer)	Το επίπεδο που τρέχει κάθε υπηρεσία σε απομονωμένο container.
επιταχυντής (accelerator)	Εξειδικευμένο υλικό (π.χ. GPU) που επιταχύνει τους υπολογισμούς.
εποχές (epochs)	Οι πλήρεις διελεύσεις του συνόλου εκπαίδευσης κατά την εκπαίδευση.
εσφαλμένη αποχή (false abstention)	Όταν το σύστημα απέχει ενώ είχε τη σωστή πληροφορία για να απαντήσει.
ευρετική πύλη εμπιστοσύνης (retrieval confidence / heuristic gate)	Κανόνας που απορρίπτει την απάντηση όταν η εμπιστοσύνη ανάκτησης είναι χαμηλή.
ευφυής πράκτορας (AI Agent)	Λογισμικό που δρα αυτόνομα για την επίτευξη ενός στόχου.
ικανότητα μάθησης (learnability)	Ο βαθμός στον οποίο μια συμπεριφορά ή έννοια μπορεί να διδαχθεί.
κανονικές εκφράσεις (regex)	Μοτίβα για την αναζήτηση και εξαγωγή κειμένου.
«κλείσιμο του βρόχου» (closing the loop)	Η επιστροφή του αποτελέσματος πίσω στο σύστημα, ολοκληρώνοντας τον κύκλο.
κλήσεις επανάκλησης (webhooks)	Μηχανισμός όπου ένα σύστημα ειδοποιεί αυτόματα ένα άλλο για ένα γεγονός.
μεγάλα δεδομένα (Big Data)	Πολύ μεγάλοι όγκοι δεδομένων που απαιτούν ειδικές τεχνικές επεξεργασίας.

Μέση Αντίστροφη Κατάταξη (Mean Reciprocal Rank)	Μετρική που βραβεύει την υψηλή θέση του πρώτου σωστού αποτελέσματος.
μεταβλητές περιβάλλοντος (environment variables)	Ρυθμίσεις που δίνονται στην εφαρμογή απ' έξω, χωρίς αλλαγή κώδικα.
μηχανισμός επανακατάταξης (reranker)	Μοντέλο που αναδιατάσσει τα ανακτηθέντα έγγραφα κατά σχετικότητα.
μηχανισμός προσομοίωσης φόρτου (Virtual User Mechanism)	Μηχανισμός που παράγει τεχνητά αιτήματα για δοκιμή του συστήματος υπό φόρτο.
μικροϋπηρεσίες (microservices)	Αρχιτεκτονική όπου η εφαρμογή χωρίζεται σε μικρές, ανεξάρτητες υπηρεσίες (Frontend, Orchestrator, AI Interface).
μοντέλο διανυσματικής αναπαράστασης (embedding model)	Μοντέλο που μετατρέπει κείμενο σε αριθμητικά διανύσματα νοήματος.
ορθή αποχή (correct abstention)	Όταν το σύστημα σωστά απέχει επειδή δεν έχει τεκμηριωμένη απάντηση.
οροφή απόδοσης (performance celling)	Το ανώτατο όριο απόδοσης που θέτει ένα στάδιο (π.χ. η ανάκτηση).
παραγωγικό επίπεδο (generation level)	Το τμήμα του συστήματος που παράγει την τελική απάντηση.
Πιθανοθεωρητικό Πλαίσιο Σχετικότητας (Probabilistic Relevance Framework)	Θεωρητικό πλαίσιο εκτίμησης της σχετικότητας εγγράφου-ερωτήματος με πιθανότητες.
πιστότητα (faithfulness)	Ο βαθμός στον οποίο η απάντηση στηρίζεται πράγματι στα ανακτηθέντα έγγραφα.
προεπεξεργασία (pre-processing)	Η προετοιμασία και ο καθαρισμός των δεδομένων πριν την επεξεργασία.
προσαρμογέας (adapter)	Μικρό σύνολο εκπαιδεύσιμων παραμέτρων που προστίθεται στο βασικό μοντέλο (αποθηκεύεται σε μορφή GGUF).
πρότυπες απαντήσεις (gold answers)	Οι σωστές απαντήσεις αναφοράς για αξιολόγηση και εκπαίδευση.
σενάρια αυτοματοποίησης (scripts)	Μικρά προγράμματα που εκτελούν αυτόματα επαναλαμβανόμενες εργασίες.

σημείο διεπαφής (endpoint)	Διεύθυνση ενός API στην οποία στέλνονται τα αιτήματα.
σπόρος τυχαιότητας (seed)	Αρχική τιμή που κάνει μια τυχαία διαδικασία αναπαραγώγιμη.
στιλιστική συγγένεια (stylistic alignment)	Ο βαθμός στον οποίο η απάντηση ταιριάζει στο ύφος της αναφοράς.
σύνολο δεδομένων εποπτευόμενης εκπαίδευσης (Supervised Fine-Tuning Dataset)	Ζεύγη εισόδου-εξόδου για την εξειδίκευση του μοντέλου.
σύντηξη βαθμολογιών (score fusion)	Συνδυασμός βαθμολογιών από διαφορετικές μεθόδους ανάκτησης σε μία ενιαία.
Συστήματα Στήριξης Αποφάσεων (Decision Support System)	Συστήματα που βοηθούν τον άνθρωπο να λάβει αποφάσεις.
συστημικό μήνυμα (system prompt)	Οδηγία που καθορίζει τη συμπεριφορά του γλωσσικού μοντέλου.
υβριδική ροή ανάκτησης (Hybrid Retrieval Pipeline)	Ανάκτηση που συνδυάζει λεξική και σημασιολογική αναζήτηση.
υπερπροσαρμογή (overfitting)	Όταν το μοντέλο απομνημονεύει τα δεδομένα εκπαίδευσης και δεν γενικεύει.
Υπολογιστικό Νέφος (Cloud Computing)	Παροχή υπολογιστικών πόρων μέσω διαδικτύου.
φαινόμενο «χιονοστιβάδας» (snowball effect)	Όταν ένα μικρό πρόβλημα μεγεθύνεται διαδοχικά.
φιλτράρισμα πιστότητας (faithfulness filter)	Έλεγχος που απορρίπτει απαντήσεις μη στηριζόμενες στα ανακτηθέντα έγγραφα.
χρόνος διακοπής λειτουργίας (downtime)	Το διάστημα κατά το οποίο μια υπηρεσία είναι εκτός λειτουργίας.
χρόνος εκτέλεσης (runtime)	Ο χρόνος κατά τον οποίο εκτελείται το πρόγραμμα ή το μοντέλο.

1. ΕΙΣΑΓΩΓΗ

Η σύγχρονη ψηφιακή πραγματικότητα χαρακτηρίζεται από μια καθολική εξάρτηση των οργανισμών από τις υπηρεσίες πληροφορικής, οι οποίες αποτελούν πλέον θεμέλιο λίθο της επιχειρησιακής επιτυχίας και της λειτουργικής ανθεκτικότητας. Ωστόσο, η πολυπλοκότητα των υποδομών αυτών συνεπάγεται με την εμφάνιση συμβάντων διακοπής λειτουργίας (IT downtime), τα οποία προκαλούν σημαντικές οικονομικές απώλειες, πλήττουν τη φήμη των εταιρειών και διαταράσσουν την αλυσίδα εφοδιασμού μέσω φαινομένων διάχυσης. Η ανάγκη για ταχεία και ακριβή επίλυση των τεχνικών διαχείρισης σε ευφυή συστήματα που βασίζονται στην Ανάκτηση Πληροφορίας (Information Retrieval) και Εξόρυξη Δεδομένων (Data Mining). Η παρούσα διπλωματική εργασία εστιάζει στην ανάπτυξη ενός αυτόνομου πράκτορα που αξιοποιεί Μεγάλα Γλωσσικά Μοντέλα (LLM's) για την αυτοματοποιημένη διαχείριση τεχνικών αιτημάτων. Στο παρόν κεφάλαιο, τεκμηριώνεται η κρισιμότητα του προβλήματος, αναλύεται το θεωρητικό πλαίσιο της Τεχνική Νοημοσύνης, Ανάκτησης Πληροφορίας και Εξόρυξης Δεδομένων ως εργαλεία επίλυσης και οριοθετείτε ο σκοπός και οι επιμέρους στόχοι της προτεινόμενης λύσης.



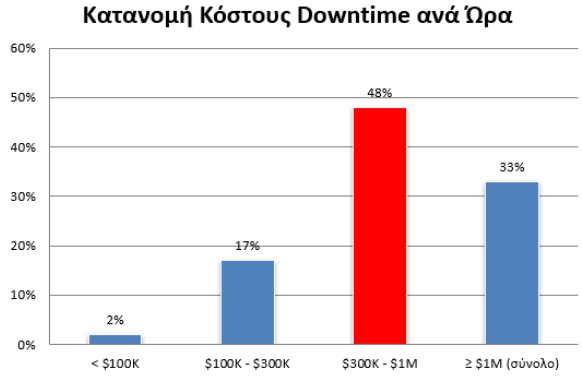
Εικόνα 1 - Dashboard Monitoring σε πραγματικό χρόνο

1.1 Σημαντικότητα Αντικειμένου και διατύπωση προβλήματος

Στο σύγχρονο ψηφιακό τοπίο, η αξιοπιστία των υπηρεσιών πληροφορικής (IT services) είναι ύψιστης σημασίας για την επιτυχία κάθε οργανισμού. Ο χρόνος διακοπής λειτουργίας των υπηρεσιών πληροφορικής (IT service downtime) αποτελεί ένα σύνηθες αλλά εξαιρετικά ανατρεπτικό πρόβλημα. Το πρόβλημα αυτό, μπορεί να προκύψει από ποικίλες αιτίες, όπως αστοχίες υλικού, σφάλματα λογισμικού, παραβιάσεις ασφαλείας ανθρώπινα λάθη, φυσικές καταστροφές ή ακόμα και εξωτερικούς παράγοντες όπως διακοπές ρεύματος. Οι επιπτώσεις αυτών των διακοπών εκτείνονται πολύ πέρα από την άμεση μη διαθεσιμότητα των υπηρεσιών, καθώς μπορούν να εμποδίσουν την παραγωγικότητα, να καθυστερήσουν κρίσιμες λειτουργίες και να προκαλέσουν υψηλό κόστος. Σύμφωνα με αναφορές του κλάδου, το κόστος του χρόνου διακοπής λειτουργίας μπορεί να κυμαίνεται από χιλιάδες έως και εκατομμύρια δολάρια ανά ώρα, ανάλογα με το μέγεθος του οργανισμού, τον κλάδο και την εξάρτηση του από την τεχνολογία [1, 2, 22].

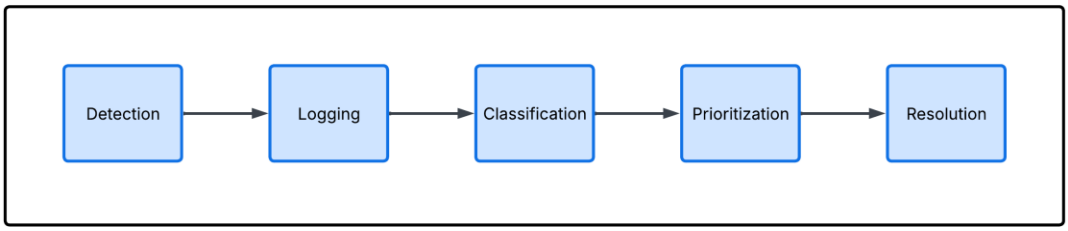
Πέραν του άμεσου οικονομικού κόστους, υπάρχουν σημαντικά έμμεσα κόστη:

- Οι διακοπές λειτουργίας μπορούν να οδηγήσουν σε σημαντικές καθυστερήσεις στην εξυπηρέτηση πελατών, αφήνοντας τους τελικούς χρήστες δυσαρεστημένους και πιο πιθανό να στραφούν στον ανταγωνισμό.
- Η απώλεια πολύτιμων δεδομένων κατά τη διάρκεια διακοπών μπορεί να βλάψει τη λήψη αποφάσεων και να μειώσει τη συνολική λειτουργική αποδοτικότητα.
- Οι επιπτώσεις στη φήμη ενός οργανισμού μπορεί να είναι τεράστιες, περιλαμβάνοντας ακόμα και την κατακόρυφη πτώση των τιμών των μετοχών του.
- Σε περιπτώσεις όπου το κόστος αυξάνεται εκθετικά με την πάροδο του χρόνου (φαινόμενο «χιονοστιβάδας» ή snowball effect), οι σύντομες διακοπές μπορεί να είναι ανεπαίσθητες, αλλά οι μεγαλύτερες διακοπές έχουν καταστροφικές συνέπειες.



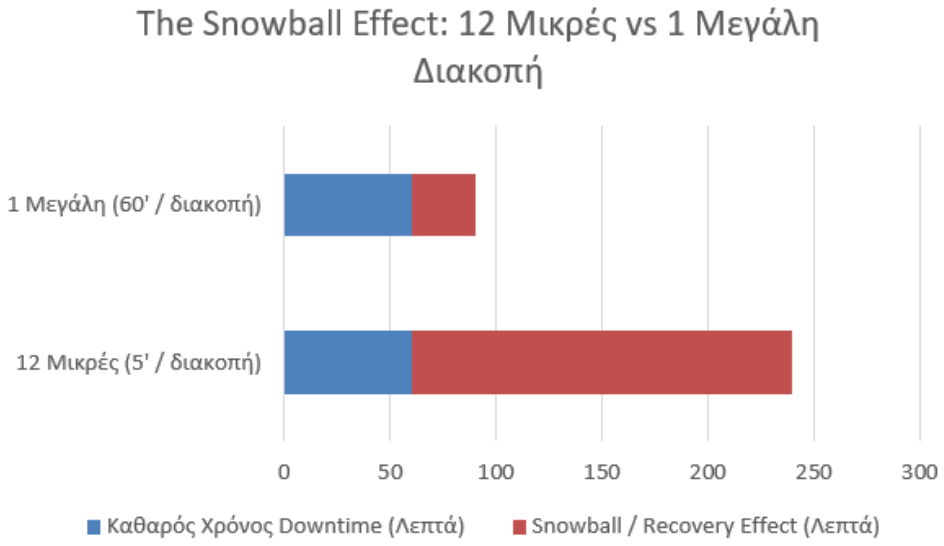
Σχήμα 1 - Γράφημα κόστους downtime ανά ώρα από δημόσια στοιχεία του ITIC

Για τον μετριασμό αυτών των επιπτώσεων, απαιτείται αποτελεσματική διαχείριση συμβάντων (incident management). Η διαχείριση συμβάντων είναι η δεδομένη προσέγγιση για τον εντοπισμό, την ανάλυση και την επίλυση διαταραχών, με στόχο την ταχύτερη δυνατή αποκατάσταση των κανονικών λειτουργιών. Παραδοσιακά, τα βήματα περιλαμβάνουν την ανίχνευση του συμβάντος, την καταγραφή, την κατηγοριοποίηση, την ιεράρχηση και την επίλυσή του.



Σχήμα 2 - Incident Lifecycle

Ωστόσο, η παραδοσιακή αξιολόγηση της διαθεσιμότητας, η οποία υπολογίζεται συχνά ως ο λόγος του Μέσου Χρόνου Μέχρι την Αστοχία (MTTF) προς το άθροισμα του MTTF και του Μέσου Χρόνου Αποκατάστασης (MTTR), παρουσιάζει αδυναμίες. Η μέθοδος αυτή δεν διαφοροποιεί, για παράδειγμα, τις 12 σύντομες διακοπές των 2 ωρών από μια ενιαία καταστροφική διακοπή των 24 ωρών, παρόλο που ο οικονομικός αντίκτυπος είναι ριζικά διαφορετικός [2].



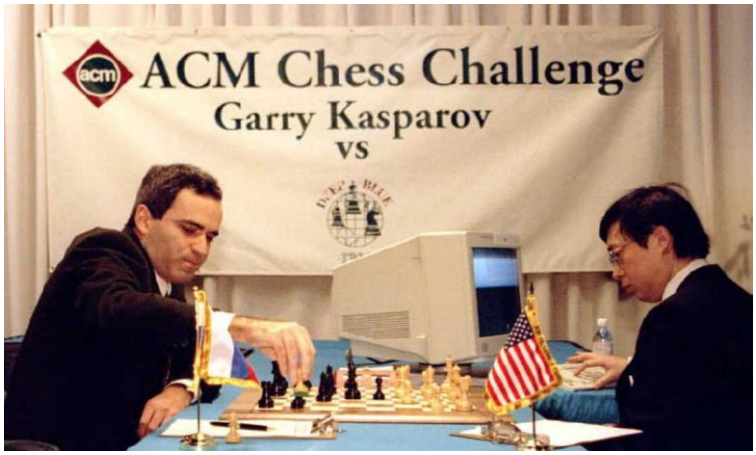
Σχήμα 3 - Ενδεικτικό Παράδειγμα MTTF/MTTR επεξήγηση snowball effect

Το κύριο πρόβλημα εντοπίζεται στο γεγονός ότι οι παραδοσιακές διαδικασίες διαχείρισης συμβάντων συχνά περιορίζονται σε αντιδραστικά μέτρα που αντιμετωπίζουν μόνο τα συμπτώματα. Για να είναι πραγματικά αποτελεσματική η διαχείριση, απαιτείται μια συστηματική προσέγγιση Ανάλυσης Βασικής Αιτίας (Root Cause Analysis - RCA), η οποία εντοπίζει την υποκειμενική αιτία ενός προβλήματος. Επιπλέον, πολλές οργανώσεις αντιμετωπίζουν εμπόδια στην ενοποίηση των συστημάτων τους (integration challenges), γεγονός που δημιουργεί «σιλό» δεδομένων τα οποία εμποδίζουν την ανταλλαγή πληροφοριών και την ολιστική ανάληψη των συμβάντων. Η παρούσα εργασία επιχειρεί να επιλύσει αυτά τα ζητήματα, εισάγοντας προσεγγίσεις βασισμένες στα δεδομένα (data-driven) για την ταχύτερη αναγνώριση, ιεράρχηση και επίλυση των περιστατικών[1].

1.2 Θεωρητικό Υπόβαθρο: Παραγωγική Τεχνητή Νοημοσύνη, Ανάκτηση Πληροφορίας και Εξόρυξη Δεδομένων

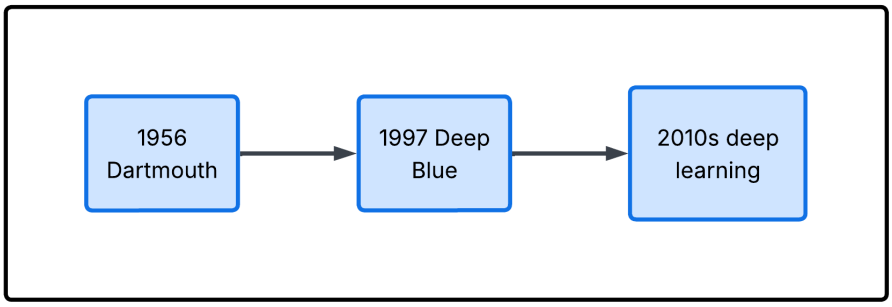
Η Τεχνική Νοημοσύνη (ΤΝ) έχει μια μακρά ιστορία, ωστόσο η σύγχρονη εκδοχή της γεννήθηκε ουσιαστικά γύρω στην δεκαετία του 1950. Η σύγχρονη ορολογία αποδίδεται στον Alan Turing και το ιστορικό συνέδριο του Dartmouth το 1956, όπου ο John McCarthy όρισε την ΤΝ ως «την επιστήμη και την μηχανική της κατασκευής ευφυών μηχανών». Στο σύγχρονο τομέα των Πληροφοριακών Συστημάτων, η ΤΝ ασχολείται με την ικανότητα μιας μηχανής να εκτελεί γνωστικές λειτουργίες που παραδοσιακά συνδέονται με τον ανθρώπινο νου, όπως η αντίληψη, η λογική, η μάθηση, η αλληλεπίδραση με το περιβάλλον, η επίλυση προβλημάτων και η λήψη αποφάσεων. Συνοπτικά, περιγράφει ένα μοντέλο που διαθέτει την ικανότητα να λογικεύεται, να μαθαίνει και να ενεργεί αυτόνομα, προσομοιάζοντας την ανθρώπινη συμπεριφορά [8].

Ιστορικά, ο τομέας γνώρισε περιόδους μεγάλης άνθισης αλλά και στασιμότητας, όπως η περίοδος μεταξύ 1974 και των αρχών της δεκαετίας του 1980, η οποία χαρακτηριστικέ από μειωμένη χρηματοδότηση και πτώση του ενδιαφέροντος. Σταθμός στην αναζωπύρωση του τομέα υπήρξε το 1997, όταν ο υπολογιστής Deep Blue της IBM νίκησε τον παγκόσμιο πρωταθλητή στο σκάκι Garry Kasparov, αποδεικνύοντας ότι οι υπολογιστές μπορούν να ξεπεράσουν την ανθρώπινη νοημοσύνη σε διαδικασίες με συγκεκριμένη στοχοθεσία.



Εικόνα 2 - Παρτίδα Σκάκι του Garry Kasparov εναντίων της Μηχανής ΤΝ "Deep Blue" της IBM

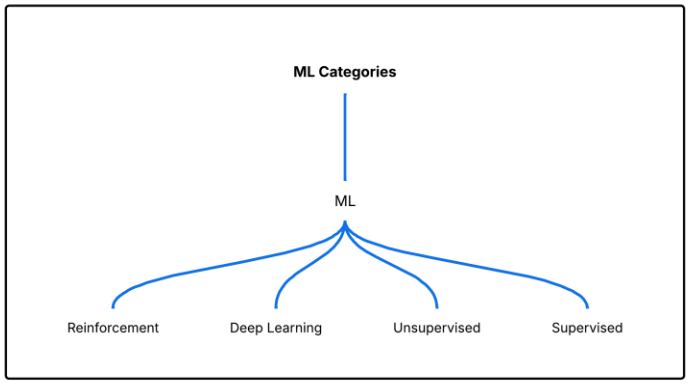
Η σαρωτική επιστροφή της ΤΝ από το 2010 και μετά (το νέο «καλοκαίρι») οφείλεται κυρίως σε τρεις καταλύτες: (1) την εμφάνιση πολύ πιο εξελιγμένων αλγορίθμων, (2) την έλευση επεξεργαστών γραφικών (GPU's) χαμηλού κόστους, ικανών να εκτελέσουν εκατομμύρια υπολογισμούς σε χιλιοστά του δευτερολέπτου, και (3) την πρωτοφανή διαθεσιμότητα τεράστιων βάσεων δεδομένων (Biga Data), Παράλληλα, η εξάπλωση των υπηρεσιών Υπολογιστικού Νέφους (Cloud Computing) και η ανοιχτή διάθεση εργαλείων λογισμικού κατέστησαν την τεχνολογία πολύ πιο προσιτή στους οργανισμούς.



Σχήμα 4 - Χρονολόγιο Εξέλιξης ΤΝ

Ο ευρύτερος κλάδος της ΤΝ συγκροτείται από επιμέρους τεχνολογίες και γνωστικά αντικείμενα [3, 4]:

- ***Μηχανική Μάθηση (Machine Learning - ML)***: Αποτελεί τον πυρήνα των σύγχρονων συστημάτων ΤΝ. Επιτρέπει σε ένα σύστημα να βελτιώνει αυτόματα τις μεθόδου τους και τα αποτελέσματα του καθώς εκτίθεται σε περισσότερα δεδομένα. Περιλαμβάνει την επιβλεπόμενη (supervised), μη επιβλεπόμενη (unsupervised), βαθιά μάθηση (deep learning) και την ενισχυτική μάθηση (reinforcement learning).



Σχήμα 5 - Κατηγορίες ML

- ***Επεξεργασία Φυσικής Γλώσσας (Natural Language Processing - NLP)***: Σχεδιάζεται για να κατανοεί και να αναλύει την ανθρώπινη γλώσσα, υποστηρίζοντας τεχνολογίες όπως τα chatbots την αναγνώριση οντοτήτων και την ανάλυση συναισθήματος.
- ***Έμπειρα Συστήματα (Expert Systems)***: Συστήματα σχεδιασμένα να προσομοιώνουν τη συμπεριφορά επίλυσης προβλημάτων ενός ανθρώπου ειδικού σε έναν συγκεκριμένο τομέα.
- ***Υπολογιστική Όραση (Computer/Machine Vision)***: Η ικανότητα ενός συστήματος να κατανοεί και να ερμηνεύει οπτικά δεδομένα (όπως αναγνώριση αντικειμένων ή προσώπων).

Μέσα στο περιβάλλον των Πληροφοριακών Συστημάτων, η χρήση της ΤΝ δημιουργεί επιχειρηματική αξία που ταξινομείται σε τρεις κύριες κατηγορίες:

- ***Αυτοματοποίηση Διαδικασιών (Process Automation)***, η οποία είναι και η συχνότερη εφαρμογή, αφορώντας την αυτοματοποίηση των ψηφιακών και των φυσικών εργασιών (π.χ. back-office operation). Η παρούσα διπλωματική εργασία ταυτίζεται απόλυτα με αυτόν ακριβώς τον πυλώνα. Ο σχεδιασμός και η ανάπτυξη του αυτόνομου πράκτορα αποσκοπεί στην αυτοματοποίηση της διαχείρισης και επίλυσης τεχνικών αιτημάτων (IT Incident Resolution) μιας κατεξοχήν χρονοβόρας back-office διαδικασίας, η οποία μέσω της ΤΝ, μετασχηματίζεται πλέον σε μια ταχύτατη και αυτόνομη ροή εργασίας, μειώνοντας δραστικά το λειτουργικό κόστος.
- ***Γνωστική Διείσδυση (Cognitive Insight)***, για την απόκτηση κρίσιμης γνώσης μέσω της ανάλυσης τεράστιων όγκων δεδομένων με ταχύτητες αδιανόητες για τον άνθρωπο, και
- ***Γνωστική Εμπλοκή (Cognitive Engagement)***, η οποία εστιάζει στην άμεση αλληλεπίδραση των συστημάτων με υπαλλήλους ή πελάτες.

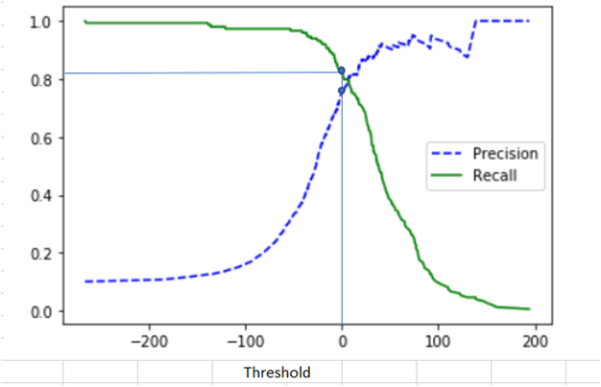
Η Ανάκτηση Πληροφορίας (Information Retrieval - IR) είναι η τέχνη και η επιστήμη της ανάκτησης ενός υποσυνόλου αντικειμένων από μια συλλογή, το οποίο εξυπηρετεί τον σκοπό του χρήστη. Το κύριο ζητούμενο είναι η ανάκτηση των χρήσιμων πληροφοριών, αφήνοντας πίσω όσα δεν είναι σχετικά. Τα συστήματα IR διαχειρίζονται κυρίως μη δομημένες πληροφορίες, όπως κείμενα ελεύθερης μορφής, και εντοπίζουν έγγραφα που είναι περισσότερο ή λιγότερο σχετικά με το ερώτημα [5].

Για την αποτελεσματική ανάκτηση πληροφοριών έχουν αναπτυχθεί διάφορα μοντέλα, με τα τρία κλασικά να είναι:

- ***Το Μοντέλο Boole (Boolean Model)***: Βασίζεται στη λογική Boole και τη θεωρία συνόλων, όπου τα έγγραφα και τα ερωτήματα θεωρούνται σύνολα όρων. Η ανάκτηση βασίζεται στο αν τα έγγραφα περιέχουν ή όχι τους όρους του ερωτήματος με χρήση τελεστών (AND, OR, NOT). Είναι αποδοτικό υπολογιστικά και επιτρέπει την ακριβή διατύπωση ερωτημάτων, αλλά οι χρήστες συχνά δυσκολεύονται να διατυπώσουν σωστά ερωτήματα, καθώς συγχέουν τους τελεστές με τη χρήση τους στη φυσική γλώσσα.
- ***Το Διανυσματικό Μοντέλο (Vector Space Model)***: Πρόκειται για ένα στατιστικό μοντέλο (αλγεβρικό) που αναπαριστά έγγραφα και ερωτήματα ως διανύσματα σε έναν πολυδιάστατο χώρο. Η σύγκριση γίνεται μέσω μετρικών ομοιότητας, όπως το συνημίτονο (cosine similarity). Στο μοντέλο αυτό, οι όροι σταθμίζονται με βάση τη στατιστική τους κατανομή στη συλλογή εγγράφων, επιτρέποντας την ιεράρχηση της σχετικότητας (relevance ranking).
- ***Το Πιθανοθεωρητικό Μοντέλο Βέλτιστης Αντιστοίχισης (Okapi BM25)***: Αποτελεί την πλέον επιτυχημένη υλοποίηση του Πιθανοθεωρητικού Πλαισίου Σχετικότητας (Probabilistic Relevance Framework - PRF). Βασίζεται στην Αρχή Κατάταξης Πιθανοτήτων (Probability

Ranking Principal - PRP), η οποία ορίζει ότι η βέλτιστη αποτελεσματικότητα ενός συστήματος επιτυγχάνεται όταν τα έγγραφα κατατάσσονται με φθίνουσα σειρά ως προς την εκτιμώμενη πιθανότητα σχετικότητάς τους με το ερώτημα του χρήστη. Το BM25 ενσωματώνει την έννοια της «ελίτ», υποθέτοντας ότι η εμφάνιση ενός όρου σε ένα έγγραφο εξαρτάται από το αν το έγγραφο πραγματεύεται ουσιαστικά τη συγκεκριμένη έννοια, ξεπερνώντας την απλή καταμέτρηση λέξεων. Δύο θεμελιώδη χαρακτηριστικά του αλγορίθμου είναι: (α) ο κορεσμός της συχνότητας όρου (tf saturation), όπου η συνεισφορά ενός όρου τείνει σε ένα ασυμπτωτικό όριο όσο αυξάνεται η συχνότητά του, αποτρέποντας την κυριαρχία ενός μόνο όρου στο τελικό σκορ , και (β) η ομαλή κανονικοποίηση του μήκους του εγγράφου (soft document length normalization), η οποία προσαρμόζει το βάρος λαμβάνοντας υπόψη εάν η έκταση ενός κειμένου οφείλεται σε «φλυαρία» (verbosity) ή σε ευρύτερο πεδίο κάλυψης (scope) [6].

Η αξιολόγηση των συστημάτων IR βασίζεται σε δύο βασικές μετρικές: την Ανάκληση (Recall), που είναι το ποσοστό των σχετικών εγγράφων που ανακτήθηκαν επιτυχώς σε σχέση με το σύνολο των σχετικών εγγράφων της συλλογής, και την Ακρίβεια (Presession), που είναι το ποσοστό των ανακτηθέντων εγγράφων που είναι πράγματι σχετικά. Ένα καλό σύστημα IR πρέπει να έχει υψηλή ανάκληση και υψηλή ακρίβεια, ωστόσο ιστορικά αποδεικνύεται ότι αυτοί οι δύο στόχοι είναι συχνά αντιφατικοί, δηλαδή, η αύξηση του ενός τείνει να βλάπτει τον άλλον [10].



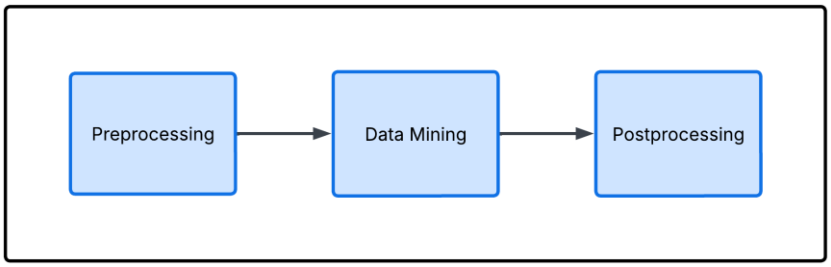
Σχήμα 6 - Precision vs Recall tradeoff curve

Πέρα από τα παραδοσιακά μοντέλα ανάκτησης, η σύγχρονη διαχείριση της πληροφορίας ενσωματώνει ισχυρές στατιστικές και συντακτικές μεθόδους Επεξεργασίας Φυσικής Γλώσσας (NLP) σε άμεση συνέργεια με τεχνικές Μηχανικής Μάθησης και Εξόρυξης Δεδομένων (Data Mining - ΕΔ). Η Επεξεργασία Φυσικής Γλώσσας αναλαμβάνει την εξαγωγή νοήματος από το κείμενο και τη δημιουργία λεπτομερών μεταδεδομένων για στοχευμένη αναζήτηση.

Η ΕΔ συνιστά αναπόσπαστο τμήμα της ευρύτερης διαδικασίας Ανακάλυψης Γνώσης σε Σύνολα Δεδομένων, η οποία αποτελεί τη συνολική διεργασία μετατροπής ακατέργαστων δεδομένων σε εκμεταλλεύσιμη γνώση. Τα δεδομένα εισόδου δύνανται να αποθηκευτούν σε ποικίλες μορφές και να

κατανέμονται σε διαφορετικές τοποθεσίες. Η διαδικασία εκκινεί με το κρίσιμο στάδιο της προεπεξεργασίας (pre-processing), του οποίου σκοπός είναι να μετατρέψει τα ακατέργαστα δεδομένα εισόδου σε μορφή κατάλληλη για ανάλυση. Το στάδιο αυτό περιλαμβάνει τη σύνταξη δεδομένων από πολλαπλές πηγές, την εκκαθάριση για την απάλειψη του «θορύβου» και των διπλότυπων παρατηρήσεων, καθώς και την επιλογή των σχετικών χαρακτηριστικών. Εξαιτίας της ετερογένειας των δεδομένων, η προεπεξεργασία αποτελεί ίσως το πιο επίπονο και χρονοβόρο βήμα ολόκληρης της διαδικασίας ανακάλυψης γνώσης.

Η διεργασία ολοκληρώνεται με την εκ των υστέρων επεξεργασία (post-processing), ή αλλιώς το «κλείσιμο του βρόχου» (closing the loop), που αναφέρεται στην ενσωμάτωση των αποτελεσμάτων της εξόρυξης σε Συστήματα Στήριξης Αποφάσεων (Decision Support System). Το βήμα αυτό διασφαλίζει, μέσω μεθόδων ελέγχου υποθέσεων, ότι αναδεικνύονται μόνο τα έγκυρα και αξιοποιήσιμα πρότυπα. Η σύνθεση αυτών των προηγμένων τεχνικών (NLP, IR και Data Mining) επιτρέπει στα σύγχρονα συστήματα να απαντούν σε περίπλοκα ερωτήματα μέσω συμπερασμού (inference), παρέχοντας πρωτοφανή υποστήριξη στην επίλυση προβλημάτων, το οποίο αποτελεί τον πυρήνα της λειτουργίας του ευφυούς πράκτορα (AI Agent) της παρούσας εργασίας για την αυτοματοποιημένη ανάλυση και επίλυση IT tickets [9].



Σχήμα 7 - Διαδικασίας Ανακάλυψης Γνώσης σε Σύνολα Δεδομένων

1.3 Σκοπός, Αντικείμενο και Στόχοι της Διατριβής

Ο κεντρικός σκοπός της παρούσας διπλωματικής εργασίας είναι ο σχεδιασμός και η ανάπτυξη ενός ευφυούς, αυτόνομου συστήματος για τη διαχείριση και επίλυση συμβάντων πληροφορικής (IT Incident Resolution), με απώτερο στόχο τη ριζική μείωση του χρόνου διακοπής λειτουργίας (downtime) των συστημάτων. Η υλοποίηση επιδιώκει να μεταβεί από την παραδοσιακή, αντιδραστική διαχείριση συμβάντων σε μια προληπτική, αυτοματοποιημένη και βασισμένη σε δεδομένα προσέγγιση (data-driven approach).

Για την επίτευξη αυτού του σκοπού, τίθενται οι ακόλουθοι επιμέρους στόχοι:

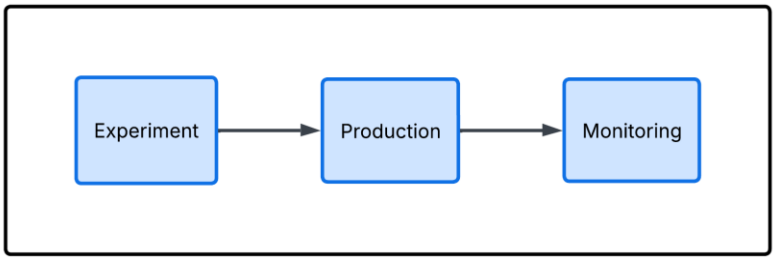
- ***Αυτοματοποίηση της Διαχείρισης Συμβάντων μέσω Δεδομένων***: Ο πρώτος στόχος είναι η αξιοποίηση αναλυτικών δεδομένων για την ενίσχυση κάθε σταδίου του κύκλου ζωής ενός

συμβάντος, από την ανίχνευση έως την επίλυση. Η προσέγγιση αυτή επιτρέπει στις ομάδες πληροφορικής να εντοπίζουν μοτίβα και να προβλέπουν πιθανά προβλήματα.

- ***Βελτιστοποίηση της Κατανομής Πόρων και Μείωση Κόστους***: Το σύστημα στοχεύει στην ιεράρχηση των εισερχόμενων αιτημάτων βάσει του αντίκτυπου και της σοβαρότητάς τους, ώστε οι πόροι να διατίθενται αποτελεσματικότερα. Οικονομικά, αυτό μεταφράζεται στη βέλτιστη εξισορρόπηση των επενδύσεων είτε για τη μείωση της συχνότητας των διακοπών (frequency of outages) είτε για τη μείωση της διάρκειας των διακοπών (duration of outages). Για παράδειγμα, εάν το κόστος του χρόνου διακοπής λειτουργίας αυξάνεται ταχύτερα από γραμμικά σε σχέση με το χρόνο (quadratic model/snowball effect), ο στόχος είναι η κατεύθυνση των πόρων στη μείωση της διάρκειας της διακοπής. Αντίθετα, εάν το κόστος είναι κυρίως σταθερό (fixed restart cost), ο στόχος είναι η ελαχιστοποίηση της συχνότητας εμφάνισης των συμβάντων.
- ***Καθιέρωση Κουλτούρας Συνεχούς Βελτίωσης***: Κρίσιμος στόχος είναι η δημιουργία ενός βρόχου ανατροφοδότησης (feedback loop). Μέσω της συνεχούς ανάλυσης δεδομένων από προηγούμενα περιστατικά, το σύστημα θα εκλεπτύνει τις διαδικασίες απόκρισής του, βελτιώνοντας την ταχύτητα και την ακρίβεια των επιλύσεων σε βάθος χρόνου.
- ***Ενοποίηση Συστημάτων και Συνεργασία μέσω Μικροϋπηρεσιών (Microservices)***: Προκειμένου να αποφευχθούν τα προβλήματα ολοκλήρωσης (integration challenges) και τα απομονωμένα συστήματα δεδομένων που εμποδίζουν την αποτελεσματική ανάλυση, ο σχεδιασμός βασίζεται σε αρχιτεκτονική μικροϋπηρεσιών. Αυτό εξασφαλίζει την απρόσκοπτη επικοινωνία μεταξύ διαφορετικών πλατφόρμων και προωθεί μια διαλειτουργική (cross-functional) προσέγγιση στη διαχείριση περιστατικών.

2. Αρχιτεκτονική

Η αρχιτεκτονική του συστήματος αποτελεί την υλοποίηση μιας σύγχρονης στρατηγικής MLOps, η οποία στοχεύει στη γεφύρωση του χάσματος μεταξύ της πειραματικής ΤΝ και της παραγωγικής λειτουργίας σε επιχειρησιακό επίπεδο.



Σχήμα 8 - MLOps Pipeline

Η επιλογή μιας δομής βασισμένης σε μικροϋπηρεσίες (microservices) δεν είναι απλώς μια σχεδιαστική προτίμηση, αλλά μια τεχνική για την αντιμετώπιση των εμποδίων ενοποίησης (integration challenges) και των απομονωμένων συστημάτων δεδομένων που συχνά παρεμποδίζουν την ολιστική ανάλυση των συμβάντων. Η προσέγγιση αυτή επιτρέπει στον οργανισμό να επιτύχει μεγαλύτερη ανθεκτικότητα και λειτουργική αποδοτικότητα, μετατρέποντας την επεξεργασία των περιστατικών από μια χειροκίνητη εργασία σε μια χειροκίνητη εργασία σε μια αυτοματοποιημένη ροή δεδομένων.

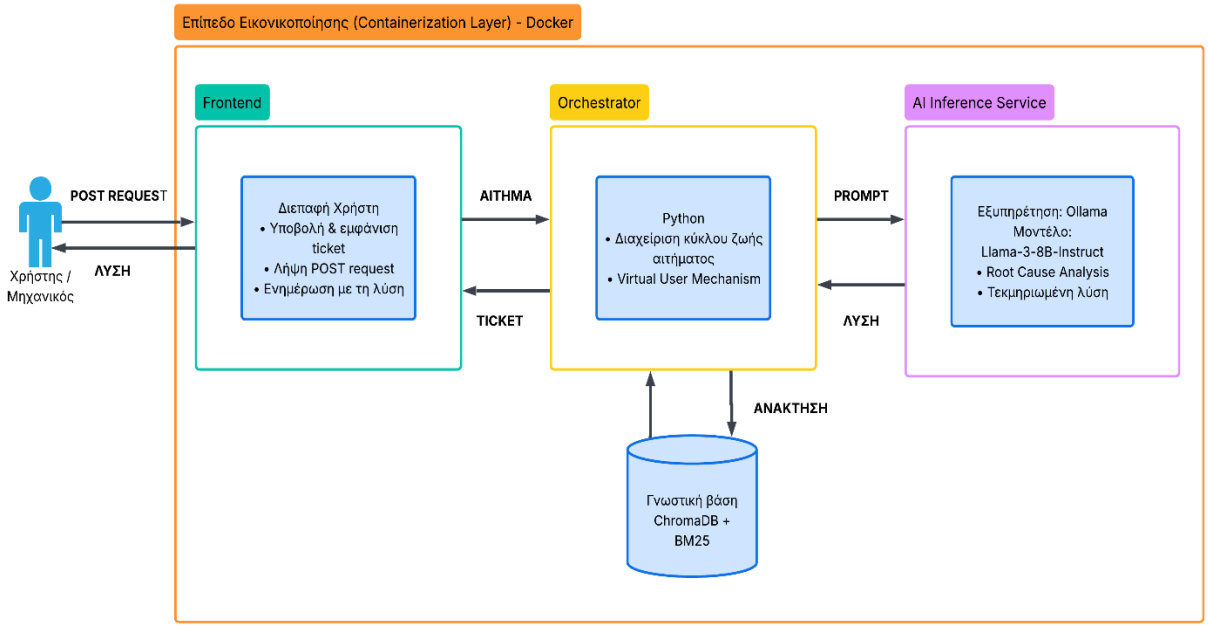
2.1 Αρχιτεκτονική Δομή Μικροϋπηρεσιών (Microservices Architecture)

Η δομή του έργου ακολουθεί τις αρχές της αποκεντρωμένης αρχιτεκτονικής, διασφαλίζοντας ότι κάθε υποσύστημα είναι αυτόνομο, επεκτάσιμο και εύκολα συντηρήσιμο. Η προσέγγιση αυτή ευθυγραμμίζεται με την ανάγκη για συνεχή βελτίωση (continuous improvement), επιτρέποντας την αναβάθμιση μεμονωμένων τμημάτων χωρίς τη διακοπή της συνολικής υπηρεσίας. Η ενοποίηση του Root Cause Analysis (RCA) εντός τα διαχείρισης συμβάντων είναι απαραίτητη για την διατήρηση υψηλής διαθεσιμότητας και τη βελτιστοποίηση των IT λειτουργιών.

Το επίπεδο εικονικοποίησης (Containerization Layer) με τη χρήση του Docker αποτελεί τη βάση της υποδομής, όπου κάθε μικροϋηρεσία (Frontend, AI Inference, Orchestrator) εκτελείται εντός απομονωμένων containers. Αυτό εξασφαλίζει την απόλυτη φορητότητα του συστήματος και την εξάλειψη των προβλημάτων συμβατότητας μεταξύ διαφορετικών περιβαλλόντων εκτέλεσης. Στο πλαίσιο της διαχείρισης συμβάντων, η εικονικοποίηση επιτρέπει την ταχεία κλιμάκωση των πόρων AI όταν ο όγκος των εισερχόμενων tickets αυξάνεται απότομα, διασφαλίζοντας ότι η απόδοση παραμένει σταθερή παρά την αυξημένη ζήτηση.

Στη καρδία της δομής βρίσκεται η Υπηρεσία Συμπερασμού (AI Inference Service) που φιλοξενεί το μοντέλο Llama-8B-Instruct μέσω των εργαλείων Ollama. Η επιλογή του Ollama είναι στρατηγική, καθώς χρησιμοποιεί προηγμένες τεχνικές διαχείρισης μνήμης, βελτιώνοντας δραματικά το throughput και μειώνοντας τον χρόνο απόκρισης [18]. Η μείωση του χρόνου ανίχνευσης και απόκρισης είναι κρίσιμη για την τήρηση των SLA (Service Level Agreements) σε κρίσιμες υποδομές, καθώς ακόμη και λίγα λεπτά διακοπής μπορούν να έχουν σοβαρές οικονομικές επίπτωσης.

Ο συντονιστής και η ροή δεδομένων υλοποιούνται σε γλώσσα προγραμματισμού Python, η οποία λειτουργεί ως ο «συνδετικός ιστός» μεταξύ της διεπαφής χρήστη και της μηχανής AI. Ο Orchestrator διαχειρίζεται τον πλήρη κύκλο ζωής του αιτήματος, από την παραλάβει του POST request έως την τελική ενημέρωση του ticket με την προτεινόμενη λύση. Η διαδικασία αυτή ενισχύεται από έναν μηχανισμό προσομοίωσης φόρτου (Virtual User Mechanism), ο οποίος επιτρέπει την αξιολόγηση της ανθεκτικότητας και τον έλεγχο της ικανότητας του να μειώνει τον Μέσο Χρόνο Αποκατάστασης (MTTR) υπό συνθήκες πραγματικής πίεσης.



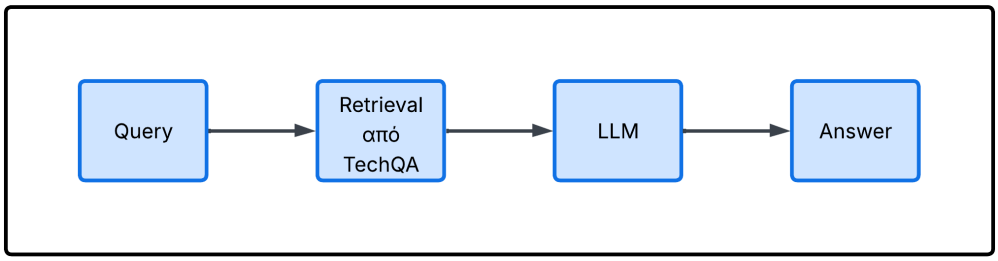
Σχήμα 9 - Διάγραμμα Αρχιτεκτονικής Microservices

2.2 Ανάλυση και Χαρακτηριστικά του Εξειδικευμένου Συνόλου Δεδομένων (IBM TechQA Dataset)

Η αποτελεσματικότητα ενός συστήματος είναι άρρηκτα συνδεδεμένη με την ποιότητα και τη σχετικότητα του χρησιμοποιούμενου συνόλου δεδομένων (Dataset). Για την παρούσα εργασία, επιλέχθηκε το σύνολο δεδομένων IBM TechQA [13], το οποίο προσφέρει το απαραίτητο γνωσιακό υπόβαθρο για την επίλυση εξειδικευμένων τεχνικών προβλημάτων, λειτουργώντας ως μια παγκόσμια δεξαμενή γνώσης για τον AI πράκτορα (AI Agent).

Η σημασιολογική σχετικότητα και η εξειδίκευση που προσφέρει το TechQA επιτρέπουν στο μοντέλο να ξεπεράσει τους περιορισμούς της απλής αντιστοίχισης λέξεων-κλειδιών και να αντιληφθεί το βαθύτερο νόημα ενός προβλήματος. Αυτό είναι ζωτικής σημασίας στην πληροφορική, όπου η μεταβλητότητα της γλώσσας είναι μεγάλη και η ανάκτηση πρέπει να βασίζεται στο εννοιολογικό σχήμα και όχι μόνο σε επιφανειακούς όρους. Η χρήση δομημένης τεχνικής πληροφορίας επιτρέπει στον πράκτορα να «μαθαίνει» να ανακτά μόνο τις πληροφορίες εκείνες που είναι κατάλληλες (pertinent) για τις συγκεκριμένες ανάγκες του χρήστη.

Ένα κρίσιμο ζήτημα είναι η βελτίωση της Ακρίβειας (Precision), δηλαδή η διασφάλιση ότι τα ανακτηθέντα έγγραφα είναι πράγματι σχετικά με το αίτημα. Το TechQA παρέχει τη δυνατότητα στον ευφυή πράκτορα να φιλτράρει τον θόρυβο και να εστιάζει σε λύσεις υψηλής ποιότητας, αποφεύγοντας τις ψευδαισθήσεις (hallucination) που συχνά χαρακτηρίζουν τα γενικά γλωσσικά μοντέλα [7]. Η εκπαίδευση πάνω σε εξειδικευμένη τεχνική τεκμηρίωση ενισχύει την αξιοπιστία του συστήματος, διασφαλίζοντας ότι οι προτεινόμενες οδηγίες επιδιόρθωσης είναι έγκυρες και μειώνουν το ρίσκο λανθασμένων ενεργειών.



Σχήμα 10 - Διάγραμμα Λειτουργίας του RAG

2.3 Μεθοδολογικό Πλαίσιο και Στάδια Υλοποίησης του Έργου

Η υλοποίηση του συστήματος ακολουθεί έναν αυστηρά δομημένο οδικό χάρτη τριών βασικών φάσεων, όπως ορίζεται στον σχεδιασμό του έργου, διασφαλίζοντας τη μετάβαση από την απλή διαχείριση δεδομένων στην πλήρη αυτόνομη λειτουργία.

Η πρώτη φάση της εργασίας επικεντρώνεται στην προετοιμασία των δεδομένων και την βελτιστοποίηση των παραμέτρων του μοντέλου. Κατά το στάδιο αυτό, το σύνολο δεδομένων IBM TechQA υποβάλλεται

σε επεξεργασία και καθαρισμό, ώστε να διαμορφωθεί ένα ποιοτικό γνωσιακό υπόβαθρο που διασφαλίζει υψηλή ακρίβεια (precision) κατά τη διαδικασία της ανάκτησης πληροφορίας.

Η δεύτερη φάση πραγματοποιείται η βελτιστοποίηση των παραμέτρων του μοντέλου Llama8B-Instruct μέσω της μεθόδου QLoRA, μια διαδικασία κρίσιμη για την ενίσχυση της ικανότητας μάθησης (learnability) του πράκτορα. Αυτή η εξειδίκευση επιτρέπει στο σύστημα να αντιλαμβάνεται το βαθύ σημασιολογικό περιεχόμενο των τεχνικών όρων και να αποφεύγει τις «ψευδαισθήσεις» (hallucinations), ξεπερνώντας τις δυνατότητες των παραδοσιακών αντιδραστικών συστημάτων. Παράλληλα, αναπτύσσονται scripts σε Python που αξιοποιούν το API του Ollama για την τροφοδοσία των αιτημάτων στο μοντέλο Llama-3, υλοποιώντας τη λογική την «γνωστικές αυτοματοποίησης» (cognitive automation). Η φάση αυτή μετασχηματίζει τις παραδοσιακές back-office διαδικασίες σε μια ενοποιημένη ροή εργασίας, θέτοντας τις βάσεις για την αυτόνομη παραγωγή τεκμηριωμένων λύσεων.

Η τελική φάση ολοκληρώνεται με την πλήρη ενοποίηση του ευφυούς πράκτορα με την πλατφόρμα διαχείρισης έργου Jira και την υλοποίηση προηγμένων αυτοματισμών. Σε αυτό το στάδιο, ο πράκτορας συνδέεται απευθείας με τις ροές εργασίας του Jira, αναλαμβάνοντας την αυτόματη ανάλυση των εισερχόμενων tickets και την προσθήκη των προτεινόμενων λύσεων ως σχόλια ή ενημερώσεις στα πεδία των αιτημάτων. Μέσω αυτών των αυτοματισμών, το σύστημα ανταποκρίνεται σε πραγματικό χρόνο σε σύνθετα τεχνικά προβλήματα χωρίς την ανάγκη ανθρώπινης παρέμβασης. Η επιτυχής ολοκλήρωση αυτή της φάσης αποδεικνύει την ικανότητα του συστήματος να βελτιώνει την επιχειρησιακή ανθεκτικότητα, μειώνοντας αποτελεσματικά τον Μέσο Χρόνο Αποκατάστασης (MTTR) και ελαχιστοποιώντας τις οικονομικές επιπτώσεις από τον χρόνο διακοπής λειτουργίας των υπηρεσιών πληροφορικής.



Σχήμα 11 - Διάγραμμα Gantt υλοποίησης Φάσεων έργου

3. Ανάκτηση Πληροφορίας και Βελτιστοποίηση Κατάταξης Δεδομένων από το TechQA Dataset (Στάδιο Α)

Για την πρακτική υλοποίηση της προτεινόμενης αρχιτεκτονικής μικροϋπηρεσιών και την επιχειρησιακή ανάπτυξη του ευφυούς πράκτορα, σχεδιαστικέ και αναπτύχθηκε μια ολοκληρωμένη διοχέτευση μηχανικής μάθησης (MLOps Pipeline), η οποία διαρθρώθηκε σε επιμέρους προγραμματιστικές συνιστώσες και αυτοματοποιημένα σενάρια (scripts), Κάθε ένα από αυτά τα συστατικά στοιχεία ανέλαβε έναν διακριτό και κρίσιμο ρόλο, καλύπτοντας πλήρως τον κύκλο ζωής του συστήματος: από την αρχική εισαγωγή, τον καθαρισμό και τη διανυσματική προετοιμασία των δεδομένων, την δόμηση των ευρετηρίων παραδοσιακής αναζήτησης και τη σημασιολογική βελτιστοποίηση (fine-tuning) του μοντέλου επανακατάταξης, έως την παραγωγική λειτουργία του κεντρικού API και την αντικειμενική αξιολόγηση της τελικής ακρίβειας μέσω αυτοματοποιημένων προσομοιώσεων. Στις παραγράφους που ακολουθούν, αναλύθηκε η αρχιτεκτονική δομή, η λειτουργικότητα και η προγραμματιστική λογική των κεντρικών αυτών αρχείων, αναδεικνύοντας τον τρόπο με τον οποίο συντέθηκαν οργανικά προκειμένου να μετασχηματιστούν τα μη δομημένα τεχνικά κείμενα της συλλογής σε μια ενιαία, υψηλής απόδοσης end-to-end λύση γνωστικής αυτοματοποίησης.

3.1 Υλοποίηση Μοντέλου Αναφοράς (Baseline Retrieval Model)

Η διαδικασία προετοιμασίας, επεξεργασίας και εισαγωγής των τεχνικών δεδομένων υλοποιήθηκε μέσω ενός αυτοματοποιημένου σεναρίου (script) σε γλώσσα προγραμματισμού Python (ingest.py), το οποίο σχεδιάστηκε για την ανάγνωση και την αποδοτική διαχείριση του αρχικού συμπιεσμένου αρχείου TechQA.tar.gz. Το σύστημα ανέλαβε να εντοπίσει και να εξάγει τη συλλογή τεχνικών εγγράφων (technotes) από το συμπιεσμένο αρχείο full_technote_collection.txt.bz2, μετατρέποντας τις γραμμές του κειμένου σε δομές JSON. Κατά τη ροή φόρτωσης των δεδομένων, ενσωματώθηκε ένας μηχανισμός διασφάλισης των δεδομένων αναφοράς (guarantee_ground_truth), ο οποίος εκτέλεσε προσπέλαση στο αρχείο dev_Q_A.json μέσω της συνάρτησης collect_ground_truth_ids() (βλ. Παράρτημα Α). Η συνάρτηση αυτή, εξάγει ένα σύνολο μοναδικών αναγνωριστικών (ID’s) που αντιστοιχούν σε επιβεβαιωμένες απαντήσεις τεχνικών προβλημάτων (ANSWERABLE == 'Y'). Η αποθήκευση των εγγράφων πραγματοποιήθηκε σε 2 διακριτές μορφές: αρχικά, έγινε χρήση του μοντέλου all-MiniLM-L6-v2 μέσω της βιβλιοθήκης Sentence Transformers για την μετατροπή των κειμένων, που περιλάμβαναν τον τίτλο και το κυρίως σώμα κάθε τεχνικού σημειώματος, σε διανυσματικές αναπαραστάσεις (embeddings). Αυτά τα διανύσματα εισήχθησαν στη διανυσματική βάση δεδομένων ChromaDB με την μέθοδο του batch processing ανά 500 έγγραφα (CHROMA_BATCH = 512), ενώ σε περίπτωση σφάλματος εκτελέστηκε η μέθοδος upsert για την αποφυγή διπλοεγγραφών. Παράλληλα, το κείμενο υποβλήθηκε σε λεκτική ανάλυση (tokenization) μέσω κανονικών εκφράσεων (re.findall(r'\w+', text.lower())) και αποθηκεύτηκε περιοδικά

ανά 10.000 εγγραφές (TOKEN_FLUSH_EVERY = 10_000) σε ένα αρχείο μορφής JSONL (/data/bm25_tokens.jsonl), διασφαλίζοντας ότι ακόμη και κατά την προσέγγιση του προκαθορισμένου ορίου εγγράφων στην κανονική ροή, τα έγγραφα του ground truth που εκκρεμούσαν θα φορτώνονταν κατά προτεραιότητα στην ChromaDB και στο δίσκο. Για την δόμηση του ευρετηρίου λέξεων-κλειδιών, αναπτύχθηκε μια αυτοματοποιημένη διαδικασία επεξεργασίας σε περιβάλλον Kaggle Notebook (βλ. Παράρτημα Β) με τη χρήση επιταχυντή (accelerator) GPU Tesla T4. Αρχικά, εγκαταστάθηκε η εξειδικευμένη βιβλιοθήκη bm25s για την υλοποίηση του αλγορίθμου ανάκτησης. Η διαδικασία διαρθρώθηκε σε τέσσερα συγκεκριμένα βήματα, ξεκινώντας από την φόρτωση αποκλειστικά και μόνο των λεκτικών τεκμηρίων (tokens) από το παραχθέν αρχείο bm25_tokens,jsonl, μια στρατηγική που εφαρμόστηκε για την ελαχιστοποίηση του αρχικού αποτυπώματος μνήμης RAM κατά τη διαχείριση των 801.998 εγγράφων της συλλογής. Στο δεύτερο στάδιο, αρχικοποιήθηκε το αντικείμενο bm25s.BM25() και εκτελέστηκε η δημιουργία του ευρετηρίου με τη μέθοδο retriever.index(all_tokens), ενώ αμέσως μετά πραγματοποιήθηκε χειροκίνητη εκκαθάριση μνήμης μέσω του (gc.collect()). Κατά το τρίτο στάδιο υλοποίησης, το παραχθέν ευρετήριο αποθηκεύτηκε μόνιμα στον κατάλογο /kaggle/working/bm25s_index/, δημιουργώντας τα απαραίτητα αρχεία δομής, όπως τα vocab.index.json, indptr.csc.index.npy, indices.csc.index.npy, params.index.json και data.csc.index.npy. Η διαδικασία ολοκληρώθηκε με το τέταρτο στάδιο, όπου το αρχείο tokens αναγνωστικέ εκ νέου για την εξαγωγή των αναγνωριστικών, των κειμένων και των μεταδεδομένων, τα οποία σειριοποιήθηκαν και αποθηκευτήκαν σε ένα αρχείο μορφής pickle (bm25_index.pkl) συνολικού μεγέθους 2.59GB, παρέχοντας έναν αποδοτικό μηχανισμό μεταφοράς των δομών εντός του container της εφαρμογής.

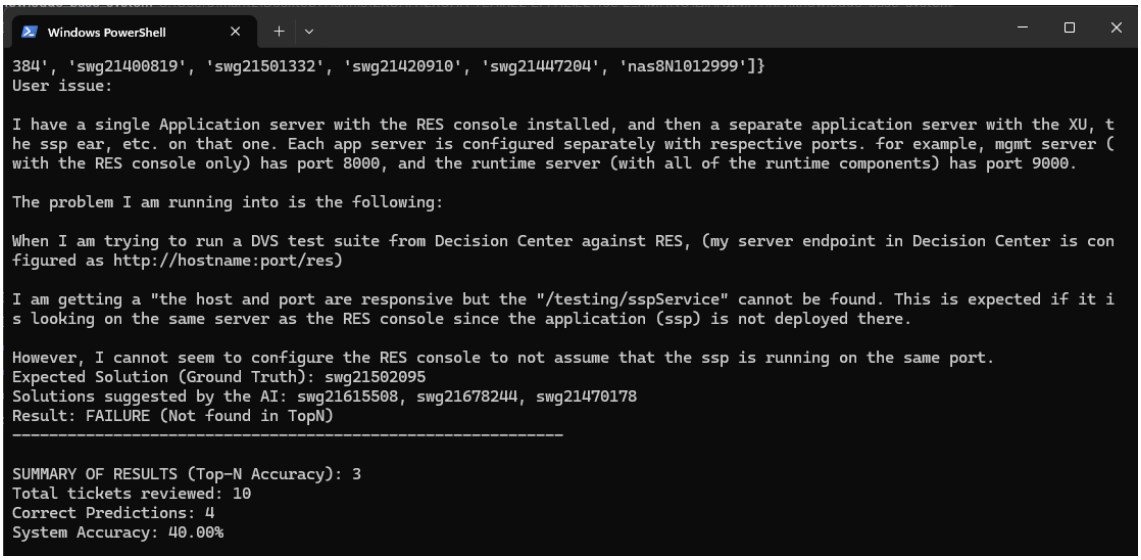
Η εξειδίκευση του μηχανισμού επανακατάταξης στο τεχνικό πεδίο (domain-specific tuning) επιτεύχθηκε μέσω της εκπαίδευσης και βελτιστοποίησης (fine-tuning) του προεκπαιδευμένου μοντέλου CrossEncoder ms-marco-MiniLM-L-6-v2 σε περιβάλλον Kaggle με τη χρήση GPU Tesla T4 και του πλαισίου PyTorch. Αναπτύχθηκε μια «answer-aware» προσέγγιση εκπαίδευσης, κατά την οποία τα δεδομένα εισόδου δεν περιορίστηκαν σε απλά ζεύγη ερωτήματος-κειμένου, αλλά εμπλουτίστηκαν με το αναμενόμενο πλαίσιο της απάντησης. Το σενάριο φόρτωσε τη συλλογή τεχνικών κειμένων από το αρχείο full_technote_collection.sections.json και άντλησε τα ζεύγη ερωτήσεων-απαντήσεων από τα αρχεία training_Q_A.json και dev_Q_A.json, φιλτράροντας αποκλειστικά τις εγγραφές με έγκυρο και συμπληρωμένο πεδίο απάντησης (ANSWER), με αποτέλεσμα τη δημιουργία 608 έγκυρων δειγμάτων. Για κάθε δείγμα, απομονώθηκαν οι πρώτοι 200 χαρακτήρες της απάντησης και συντέθηκε ένα εμπλουτισμένο ερώτημα της μορφής f"{question}\nExpected answer context]: {answer}", το οποίο συνδυάστηκε με το ορθό έγγραφο (positive pair, label 1.0). Για την ενίσχυση της διακριτικής ικανότητας του μοντέλου, εφαρμόστηκε αρνητική δειγματοληψία με την τυχαία επιλογή 4 μη σχετικών εγγραφών ανά ερώτηση (NUM_NEGATIVES = 4), συγκροτώντας ένα τελικό σύνολο 3.040 δειγμάτων εκπαίδευσης, το οποίο

διαχωρίστηκε σε ποσοστό 90% για εκπαίδευση (2.736 δείγματα) και 10% για επικύρωση (304 δείγματα). Η εκπαίδευση εκτελέστηκε για 3 εποχές (EPOCHS = 3) με μέγεθος batch 16, μέγιστο μήκος ακολουθίας τα 512 tokens και φάση προθέρμανσης (warmup) 10%, ενώ η τελική αξιολόγηση μέσω του CrossEncoderRerankingEvaluator κατέγραψε άριστες επιδόσεις (MAP, MRR@10 και NDCG@10 ίσο με 1.0000) στα δεδομένα επικύρωσης, αποθηκεύοντας τα βάρη του μοντέλου (model.safetensors) στον κατάλογο techqa-reranker-v2 (βλ. Παράρτημα Γ) [10].

Ο κεντρικός πυρήνας της εφαρμογής και η διαχείριση των αιτημάτων υποστήριξης υλοποιήθηκαν ως ένα API βασισμένο στο πλαίσιο FastAPI (main.py), το οποίο σχεδιάστηκε για να παρέχει λύσεις σε πραγματικό χρόνο μέσω υβριδικής αναζήτησης και επανακατάταξης. Κατά την εκκίνηση της εφαρμογής, ο μηχανισμός lifespan ανέλαβε την αυτόματη φόρτωση του ευρετηρίου BM25 από τον κατάλογο /data/bm25s_index χωρίς τη φόρτωση του σώματος των κειμένων (load_corpus=False), καθώς και την αποσειριοποίηση των συνοδευτικών μεταδεδομένων από το αρχείο bm25_index.pkl. Παράλληλα, το σύστημα έλεγξε την ύπαρξη του βελτιστοποιημένου CrossEncoder στο κατάλογο /app/reranker_model, όπου σε περίπτωση επιτυχίας αρχικοποιεί το fine-tuned μοντέλο, ενώ σε αντίθετη περίπτωση ενεργοποιεί ως εναλλακτική λύση το γενικό μοντέλο cross-encoder/ms-marco-MiniLM-L-6-v2. Η αρχιτεκτονική του endpoint/search δέχεται αιτήματα βασισμένα στο σχήμα TicketQuery και εκτελεί τη διαδικασία σε τρία στάδια. Αρχικά, πραγματοποιείται σημασιολογική αναζήτηση στην ChromaDB χρησιμοποιώντας την συνάρτηση build_query_expansions(), η οποία παράγει 4 παραλλαγές του ερωτήματος για τη συλλογή των πρώτων 100 υποψηφίων (initial_k=100). Στο δεύτερο στάδιο, εκτελείται παράλληλη αναζήτηση λέξεων-κλειδιών μέσω της bm25_search(), η οποία αφαιρεί τα stopwords της αγγλικής γλώσσας και επιστρέφει επίσης 100 υποψήφια έγγραφα. Τα αποτελέσματα των 2 μεθόδων συγχωνεύονται και από-διπλασιάζονται (deduplication) μέσω ενός συνόλου (seen_ids), και η τελική ενοποιημένη λίστα τροφοδοτείται στον CrossEncoder μέσω της μεθόδου reranker.predict(), η οποία αναδιατάσσει δυναμικά τα έγγραφα βάσει της τελικής βαθμολογίας σχετικότητας, επιστρέφοντας τον προκαθορισμό αριθμό λύσεων (n_results).

Η αξιολόγηση και ο έλεγχος της ορθότητας του συνολικού συστήματος αναζήτησης πραγματοποιήθηκαν μέσω ενός αυτόνομου σεναρίου προσομοίωσης εικονικών χρηστών (psudo_users.py), το οποίο βασίστηκε αποκλειστικά σε ενσωματωμένες βιβλιοθήκες της Python, όπως οι urlib.request και tarfile. Ο ρόλος του υποσυστήματος αυτού ήταν να λειτουργήσει ως ένας εξωτερικός παράγοντας (bot) που αναπαράγει ρεαλιστικές συνθήκες υποβολής τεχνικών προβλημάτων, αντλώντας πραγματικά ερωτήματα χρηστών από το αρχείο dev_Q_A.json που βρίσκεται εντός του αρχείου TechQA.tar.gz. Το σενάριο περιέτρεξε τα δεδομένα, απομονώνοντας αποκλειστικά τα tickets που διέθεταν επιβεβαιωμένη απάντηση (ANSWERABLE == 'Y'). Για κάθε ticket, εξασφαλίστηκε η εγκυρότητα του κειμένου εισόδου μέσω του ελέγχου των πεδίων QUESTION_TEXT και QUESTION_TITLE, ενώ παράλληλα αποθηκεύτηκε το αναγνωριστικό της αναμενόμενης ορθής απάντησης (DOCUMENT) (βλ. Παράρτημα Δ). Στη συνέχεια, ο

προσομοιωτής κατασκεύασε ένα JSON payload με τον καθορισμένο αριθμό ζητούμενων αποτελεσμάτων (n_results = 3) και εκτέλεσε μια κλήση HHTP POST προς το τοπικό API. Κατά την λήψη της απάντησης, το σενάριο εξήγαγε τα IDs των προτεινόμενων τεχνικών λύσεων, ήλεγξε εάν το Ground Truth περιλαμβάνουν σε αυτά (is_correct) και ενημέρωσε τους αντίστοιχους μετρητές επιτυχίας ή αποτυχίας, εκτυπώνοντας αναλυτικά logs στην κονσόλα. Η διαδικασία ολοκληρώθηκε με την εμφάνιση μιας συγκεντρωτικής αναφοράς αποτελεσμάτων, η οποία υπολόγισε το τελικό ποσοστό ακρίβειας του συστήματος (System Accuracy) σε επίπεδο Top-N, παρέχοντας μια αντικειμενική μετρική της επιχειρησιακής του ετοιμότητας.



Εικόνα 3 - Αποτέλεσμα Μοντέλου Αναφοράς

Η ανάλυση των αποτελεσμάτων της αξιολόγησης κατέδειξε ότι η διαδικασία της αρχικής ανάκτησης υπήρξε επαρκής, καθώς το μέγεθος του συνόλου των υποψηφίων εγγράφων, το οποίο κυμάνθηκε μεταξύ 100 και 130 ανά ερώτημα, κρίθηκε ικανοποιητικό. Διαπιστώθηκε ότι σε όλες τις περιπτώσεις αστοχίας, το έγγραφο αναφοράς (Ground Truth) περιλαμβανόταν σταθερά στη λίστα των προτεινόμενων εγγράφων (DOC_IDS), γεγονός που επιβεβαίωσε ότι το πρόβλημα δεν εντοπίστηκε στην έλλειψη δεδομένων στο αρχικό pool. Αντιθέτως, η αδυναμία του συστήματος αποδόθηκε στον μηχανισμό reranker, ο οποίος απέτυχε να ιεραρχήσει την ορθή απάντηση εντός των τριών κορυφαίων θέσεων (top-3).

Κατά την εξέταση των προτύπων αποτυχίας, παρατηρήθηκε μια σαφής διαφοροποίηση στην απόδοση του συστήματος ανάλογα με τη φύση του ερωτήματος. Στις περιπτώσεις επιτυχίας, όπως στα ερωτήματα Q007, Q008 και Q012, διαπιστώθηκε ότι τα queries ήταν σύντομα, σαφή και δεν περιείχαν πληροφορικό «θόρυβο». Στον αντίποδα, οι περιπτώσεις αποτυχίας συσχετίστηκαν με ερωτήματα που περιείχαν εξαιρετικά εκτενή τεχνικά δεδομένα, όπως stack traces, μηνύματα σφαλμάτων και javacore dumps με δεκαεξαδικούς κώδικες. Η παρουσία αυτών των στοιχείων δυσχέρανε τη διαδικασία ιεράρχησης, με αποτέλεσμα το έγγραφο αναφοράς να χάσει τη θέση του στην τελική κατάταξη.

Ως πρωταρχικό τεχνικό αίτιο αυτής της αστοχίας αναγνωριστικέ ο περιορισμός των 512 tokens που επιβάλει το μοντέλο CrossEncoder (ms-marco-MiniLM-L-6-v2). Επειδή το μοντέλο δέχεται ως συνολική είσοδο το άθροισμα των tokens του ερωτήματος και του εγγράφου, η χρήση εκτενών javacore dumps και πολυσέλιδων τεχνικών κειμένων οδήγησε αναπόφευκτα στην περικοπή (truncation) της πληροφορίας. Συνεπώς, ο reranker περιόρισε την ανάλυσή του μόνο στα αρχικά τμήματα των δεδομένων, με αποτέλεσμα να μην «αναγνωριστούν» κρίσιμα σημεία της λύσης που βρίσκονταν στο μέσο ή στο τέλος των εγγράφων.

Επιπλέον, εκτιμήθηκε ότι η διαδικασία βελτιστοποίησης (fine-tuning) του reranker πιθανώς βασίστηκε σε απλουστευμένα ερωτήματα, όπως οι τίτλοι των θεμάτων του TechQA, γεγονός που περιόρισε την ικανότητα του μοντέλου να επεξεργάζεται δεδομένα με έντονο τεχνικό θόρυβο. Υποδείχθηκε ότι σε πραγματικές συνθήκες λειτουργίας (production), οι σύνθετες λεπτομέρειες και τα logs των αιτημάτων προκάλεσαν σύγχυση στον μηχανισμό κατάταξης. Η διαπίστωση αυτή ανέδειξε την ανάγκη για περαιτέρω εκπαίδευση του μοντέλου σε πιο ρεαλιστικά και «ακάθαρτα» σενάρια τεχνικής υποστήριξης, ώστε να διασφαλιστεί η ανθεκτικότητά του έναντι του θορύβου.

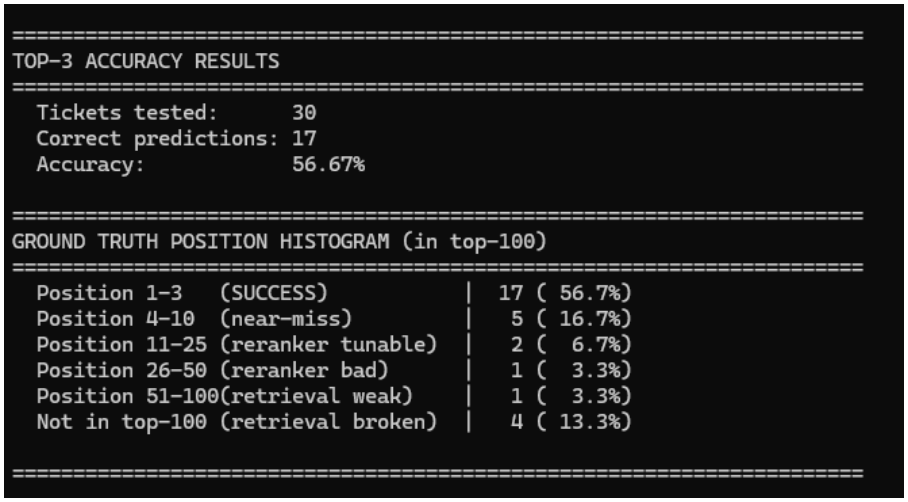
3.2 Προεπεξεργασία Ερωτημάτων και Στρατηγικές Φιλτραρίσματος Πληροφοριακού Θορύβου

Προκειμένου να αποφευχθεί η αυθαίρετη περικοπή της πληροφορίας, υιοθετήθηκε μια στρατηγική κατανομής των ορίων (caps), περιορίζοντας το ερώτημα στα 128 tokens και το έγγραφο στα 384 tokens. Με αυτόν τον τρόπο, διασφαλίστηκε η ορατότητα του μοντέλου σε κρίσιμα τμήματα αμφοτέρων των κειμένων, επιτρέποντας μια πιο ισορροπημένη αξιολόγηση της σχετικότητάς τους και αποφεύγοντας την απώλεια πληροφορίας που βρισκόταν μετά το σημείο περικοπής.

Στις περιπτώσεις όπου τα αιτήματα περιλαμβάναν εκτενή stack traces, επιλέχθηκε η διατήρηση μόνο των πλέον ουσιωδών στοιχείων, όπως ο τίτλος του ζητήματος, οι κωδικοί και τα μηνύματα σφαλμάτων μέσω κανονικών εκφράσεων (regex), καθώς και οι πρώτες προτάσεις της περιγραφής. Αυτή η διαδικασία καθαρισμού διασφάλισε ότι ο reranker τροφοδοτήθηκε με συμπυκνωμένη πληροφορία, αποφεύγοντας την υπολογιστική επιβάρυνση και τη σύγχυση από μη σχετικά τεχνικά δεδομένα.

Μια από τις πλέον καθοριστικές τροποποιήσεις υπήρξε η εφαρμογή της σύνθεσης βαθμολογιών (score fusion) αντί για την αποκλειστική βασιμότητα στα αποτελέσματα του reranker. Εφαρμόστηκε μια τεχνική συνδυασμού κατά το πρότυπο Reciprocal Rank Fusion (RRF), η οποία συνδύασε τη βαθμολογία του reranker με τις αρχικές θέσεις κατάταξης που προέκυψαν από τα μοντέλα embeddings και BM25. Η προσέγγιση αυτή βασίστηκε στη λογική ότι ένα έγγραφο που εμφανίζεται ψηλά σε πολλαπλές μεθόδους ανάκτησης είναι εξαιρετικά πιθανό να είναι σχετικό, ακόμη και αν ο reranker, λόγω του πληροφοριακού θορύβου, δεν του απέδωσε την υψηλότερη βαθμολογία.

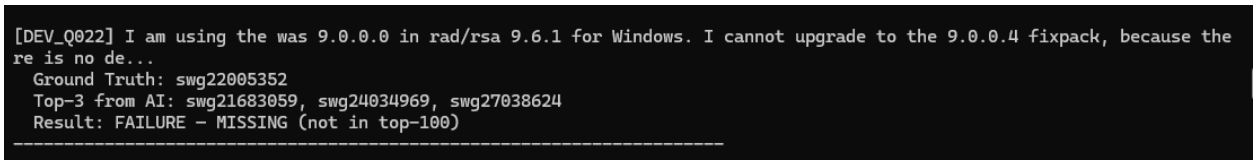
Στο ίδιο πλαίσιο, αναθεωρήθηκε η διαδικασία επέκτασης του ερωτήματος (query expansion), η οποία περιορίστηκε ή καταργήθηκε για μεγάλα σε έκταση αιτήματα, καθώς διαπιστώθηκε ότι τα γενικά προθέματα στα μεγάλα queries εμπόδιζαν τη σημασιολογική πληροφορία της αρχικής εισόδου. Επιπλέον, ενσωματώθηκε μια διαγνωστική διαδικασία, η οποία επέτρεψε τον εντοπισμό της ακριβούς θέσης του εγγράφου αναφοράς (Ground Truth) εντός των πρώτων 100 αποτελεσμάτων.



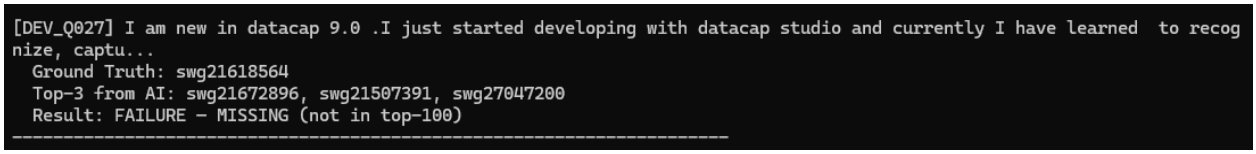
Εικόνα 4 - Αποτελέσματα Ανάκτησης έπειτα την επεξεργασία Ερωτήματος και Θορύβου

Η πρόοδος του συστήματος υπήρξε αξιοσημείωτη, καθώς το ποσοστό επιτυχίας αυξήθηκε από το 40% στο 56,67% μετά την εφαρμογή των προαναφερθέντων αλλαγών. Η ανάλυση του ιστογράμματος των αποτελεσμάτων προσέφερε έναν σαφή οδικό χάρτη για τις επόμενες βελτιώσεις, καταδεικνύοντας ότι το 56,7% των περιπτώσεων (17 tickets) κατετάγησαν επιτυχώς στις θέσεις 1-3. Παράλληλα, παρατηρήθηκε ότι ένα ποσοστό 16,7% (5 tickets) παρέμεινε στις θέσεις 4-10 («near-miss»), αποτελώντας άμεσα ανακτήσιμους στόχους, ενώ οι περιπτώσεις που κατετάγησαν στις θέσεις 11-50 (10%) υπέδειξαν την ανάγκη για περαιτέρω ρύθμιση ή βελτιστοποίηση του μηχανισμού επανακατάταξης (reranker). Ιδιαίτερα κρίσιμη διαπιστώθηκε η κατάσταση για το υπόλοιπο 16,6% των περιπτώσεων, οι οποίες βρέθηκαν είτε σε πολύ χαμηλές θέσεις είτε εντελώς εκτός της πρώτης εκατοντάδας, αποκαλύπτοντας δύο διακριτές κατηγορίες προβλημάτων.

Το πρώτο και σοβαρότερο ζήτημα αφορούσε την πλήρη απουσία τεσσάρων tickets 13,3%) από την πρώτη εκατοντάδα των αποτελεσμάτων. Η διαπίστωση αυτή κρίθηκε ως θεμελιώδους σημασίας, καθώς η μη συμπερίληψη του εγγράφου αναφοράς (Ground Truth - GT) στο αρχικό pool υποψηφίων καθιστά οποιαδήποτε μεταγενέστερη παρέμβαση στον reranker αναποτελεσματική. Μέσα από την εξέταση αυτών των αστοχιών (ενδεικτικά Q022, Q027, Q039), παρατηρήθηκε ότι τα ερωτήματα περιείχαν εξαιρετικά εξειδικευμένους κωδικούς προϊόντων και εκδόσεων firmware.



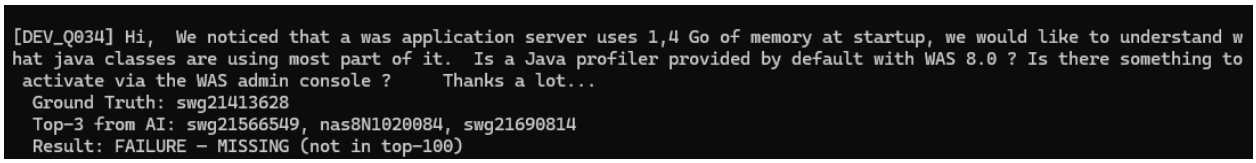
Εικόνα 5 - Μέρος του Ερωτήματος "Q022"



Εικόνα 6 - Μέρος του Ερωτήματος "Q027"



Εικόνα 7 - Μέρος του Ερωτήματος "Q039"



Εικόνα 8 - Μέρος του ερωτήματος "Q034"

Χαρακτηριστική υπήρξε η περίπτωση Q034, όπου η χρήση του ακρωνυμίου «was» (WebSphere Application Server) με πεζούς χαρακτήρες δεν αναγνωρίστηκε σημασιολογικά από το μοντέλο MiniLM. Εκτιμήθηκε ότι, ενώ ο αλγόριθμος BM25 θα μπορούσε να ανταποκριθεί καλύτερα σε τέτοιου είδους λεκτική αντιστοίχιση, η παράμετρος bm25_top_k=50 αποδείχθηκε περιορισμένη για τον τεράστιο όγκο των 801.998 εγγράφων της συλλογής.

Το δεύτερο ζήτημα εντοπίστηκε σε έξι περιπτώσεις (20%) όπου το έγγραφο αναφοράς συμπεριλήφθηκε μεν στο pool, αλλά ο reranker απέτυχε να το προωθήσει επαρκώς στην κορυφή της κατάταξης. Διαπιστώθηκαν συγκεκριμένα πρότυπα λανθασμένης ιεράρχησης, όπου το σύστημα έδωσε προτεραιότητα σε σελίδες λήψης διορθωτικών πακέτων (fix packs) αντί για τις σχετικές σελίδες τεχνικής υποστήριξης και επίλυσης προβλημάτων (troubleshooting), όπως συνέβη στην περίπτωση Q013. Επιπλέον, στην περίπτωση Q047 παρατηρήθηκε αδυναμία του συστήματος στη σημασιολογική ταύτιση (semantic matching) τεχνικών όρων, όπως η σύνδεση του «authorization code» με το «passport advantage». Παρά ταύτα, διαπιστώθηκε ότι αρκετές από αυτές τις περιπτώσεις (Q014, Q016 και Q033) κατετάγησαν σε θέσεις πολύ κοντά στην πρώτη τριάδα, γεγονός που υποδήλωσε ότι με στοχευμένες αρχιτεκτονικές παρεμβάσεις η συνολική ακρίβεια του συστήματος θα μπορούσε να βελτιωθεί περαιτέρω.

3.3 Μηχανισμοί Σύνθεσης Βαθμολογιών (Score Fusion) και Επανακατατάξης βάσει Τεχνικών Όρων (Overlap Scoring)

Στη συνέχεια της αναπτυξιακής διαδικασίας, η αναγνώριση των περιορισμών του σημασιολογικού μοντέλου embedding all-MiniLM-L6-v2) στην επεξεργασία εξειδικευμένων κωδικών προϊόντων της IBM οδήγησε στην απόφαση για ενίσχυση του αλγορίθμου BM25. Συγκεκριμένα, η παράμετρος bm25_top_k αυξήθηκε από τις 50 στις 150 μονάδες, καθώς διαπιστώθηκε ότι η μέθοδος αυτή λειτούργησε ως καθοριστική δικλείδα ασφαλείας για την ανάκτηση εγγράφων με ακριβείς ταυτίσεις όρων (exact matches), όπως «datacap», «jextract» ή «WAS 9.0.0.4». Με τη διεύρυνση του αριθμού των υποψηφίων εγγράφων από το BM25, επιδιώχθηκε η συμπερίληψη των περιπτώσεων που προηγουμένως απουσίαζαν από το αρχικό σύνολο ανάκτησης, διασφαλίζοντας ότι κρίσιμα τεχνικά αναγνωριστικά δεν θα παρακάμπτονται από τη σημασιολογική αναζήτηση.

Επίσης, απαιτήθηκε η αναβάθμιση και η ορθή παραμετροποίηση της υπολογιστικής υποδομής, με κύριο άξονα την πλήρη αξιοποίηση επιταχυντών υλικού (GPU). Αρχικά, διασφαλίστηκε η συμβατότητα του λογισμικού μέσω της χρήσης νεότερης έκδοσης της βιβλιοθήκης sentence-transformers (έκδοση 2.2.2 ή μεταγενέστερη). Στη συνέχεια, ρυθμίστηκε το περιβάλλον εικονικοποίησης (Docker Desktop μέσω υποσυστήματος WSL2) ώστε να επιτρέπει την άμεση επικοινωνία των containers με τους πυρήνες CUDA της κάρτας γραφικών. Η ενεργοποίηση της επεξεργασίας μέσω GPU αποτέλεσε καθοριστικό παράγοντα για τη βιωσιμότητα του έργου, καθώς συμπίεσε δραματικά τον απαιτούμενο χρόνο επεξεργασίας (ingestion) του συνόλου των 801.998 εγγράφων.

Κατά τη φάση της τεχνικής υλοποίησης, εντοπίστηκε μια δομική αδυναμία στην προεπιλεγμένη λειτουργία διανυσματοποίησης της βάσης δεδομένων (ChromaDB), η οποία εκτελούσε τις διαδικασίες στην κεντρική μονάδα επεξεργασίας (CPU) αγνοώντας τη διαθέσιμη υπολογιστική ισχύ της GPU. Προς επίλυση αυτού του ζητήματος, αναπτύχθηκε μια προσαρμοσμένη κλάση (custom GPUEmbeddingFunction), η οποία αναλάμβανε να φορτώσει ρητά τα μοντέλα SentenceTransformer και τον μηχανισμό επανακατάταξης (CrossEncoder) απευθείας στον επιταχυντή υλικού (device="cuda") (βλ. Παράρτημα Ε). Η εξάλειψη αυτού του εμποδίου επέτρεψε την περαιτέρω αλγοριθμική βελτιστοποίηση, όπως την αύξηση του μεγέθους των δεσμών επεξεργασίας (batch sizes).

Παράλληλα, αναπτύχθηκε και εφαρμόστηκε η εξειδικευμένη συνάρτηση extract_technical_tokens() (βλ. Παράρτημα ΣΤ), η οποία σχεδιάστηκε για την εξαγωγή της «τεχνικής υπογραφής» (technical signature) κάθε ερωτήματος. Η διαδικασία αυτή περιέλαβε την απομόνωση κρίσιμων στοιχείων, όπως αριθμοί εκδόσεων, αναγνωριστικά APAR, κωδικοί σφαλμάτων, ορολογίες σε μορφή CamelCase, καθώς και σπάνια ουσιαστικά που σχετίζονται με συγκεκριμένα προϊόντα (π.χ. Datapower, ConfigMgr). Ιδιαίτερη έμφαση δόθηκε στην αναγνώριση κρίσιμων ακρωνυμίων της IBM (όπως WAS, ODM, RAD, RSA) ανεξαρτήτως

πεζών ή κεφαλαίων χαρακτήρων, καθώς και στην ανίχνευση διαδρομών αρχείων (file paths), στοιχεία τα οποία αποτέλεσαν ισχυρούς δείκτες σχετικότητας στον τομέα της τεχνικής υποστήριξης [14].

Στο πλαίσιο αυτό, εισήχθη μια νέα συνιστώσα βαθμολόγησης, ο δείκτης επικάλυψης τεχνικών όρων (overlap_score), ο οποίος υπολόγισε το ποσοστό των τεχνικών οντοτήτων του ερωτήματος που εμφανίζονταν αυτούσια εντός του υποψήφιου εγγράφου. Η προσέγγιση αυτή επέτρεψε στο σύστημα να παρακάμπτει τις αστοχίες του μηχανισμού επανακατάταξης (reranker) σε περιπτώσεις όπου η σημασιολογική ομοιότητα προκαλούσε σύγχυση, δίνοντας προτεραιότητα σε έγγραφα με ακριβή λεκτική ταύτιση. Ως επακόλουθο, τα βάρη της διαδικασίας σύνθεσης (fusion) αναθεωρήθηκαν, υιοθετώντας μια νέα κατανομή: 0,35 για τον reranker, 0,35 για τον Reciprocal Rank Fusion (RRF) και 0,30 για τον δείκτη επικάλυψης.

```
======================================================================
TOP-3 ACCURACY RESULTS
======================================================================
  Tickets tested:      30
  Correct predictions: 19
  Accuracy:            63.33%

======================================================================
GROUND TRUTH POSITION HISTOGRAM (in top-100)
======================================================================
  Position 1-3   (SUCCESS)           |  19 ( 63.3%)
  Position 4-10  (near-miss)         |   3 ( 10.0%)
  Position 11-25 (reranker tunable)  |   1 (  3.3%)
  Position 26-50 (reranker bad)      |   4 ( 13.3%)
  Position 51-100(retrieval weak)    |   0 (  0.0%)
  Not in top-100 (retrieval broken)  |   3 ( 10.0%)

======================================================================
```

Εικόνα 9 - Αποτελέσματα Ανάκτησης με κατανομή βαρών 0,35/0,35/0,30 και χρήση finetuned reranker

```
======================================================================
TOP-3 ACCURACY RESULTS
======================================================================
  Tickets tested:      30
  Correct predictions: 19
  Accuracy:            63.33%

======================================================================
GROUND TRUTH POSITION HISTOGRAM (in top-100)
======================================================================
  Position 1-3   (SUCCESS)           |  19 ( 63.3%)
  Position 4-10  (near-miss)         |   2 (  6.7%)
  Position 11-25 (reranker tunable)  |   2 (  6.7%)
  Position 26-50 (reranker bad)      |   4 ( 13.3%)
  Position 51-100(retrieval weak)    |   1 (  3.3%)
  Not in top-100 (retrieval broken)  |   2 (  6.7%)

======================================================================
```

Εικόνα 10 - Αποτελέσματα Ανάκτησης με κατανομή βαρών 0,35/0,35/0,30 και χρήση generic reranker (ms-marco-MiniLM)

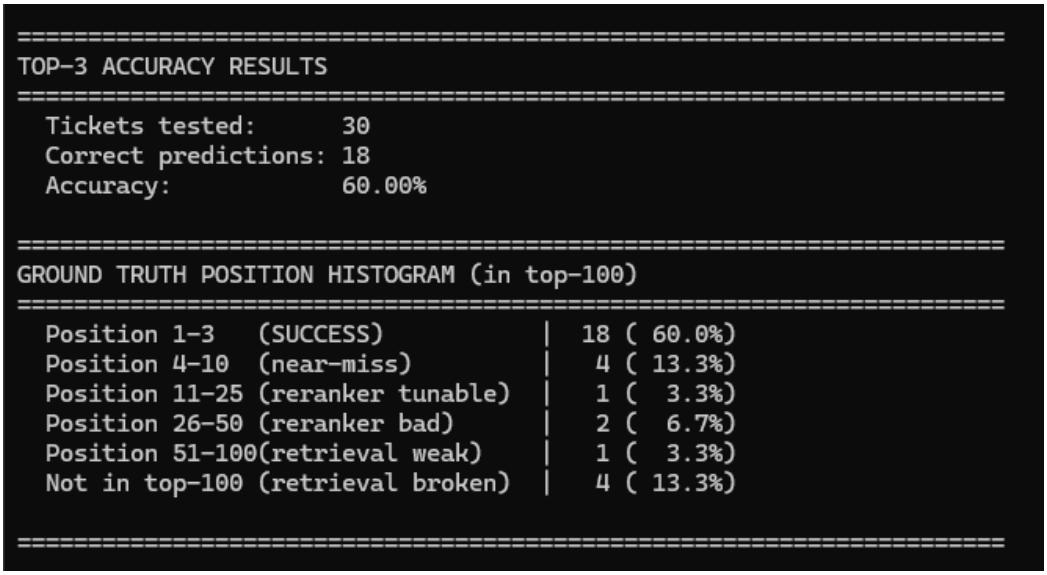
Η εφαρμογή των στοχευμένων αυτών βελτιώσεων, η πειραματική αξιολόγηση της νέας προσέγγισης, τόσο με τη χρήση του fine-tuned όσο και του generic μηχανισμού επανακατάταξης, κατέδειξε μια αύξηση στη συνολική απόδοση του συστήματος. Κατέστη σαφές ότι οι εκτεταμένες αλγοριθμικές παρεμβάσεις στη διαχείριση των βαρών αρκούσαν για να αντισταθμίσουν τη δομική αδυναμία του συγκεκριμένου μοντέλου ενσωμάτωσης να αποκωδικοποιήσει σε βάθος τη σημασιολογική πολυπλοκότητα των εξειδικευμένων τεχνικών εγγράφων. Όσο αφορά, η προσπάθεια εξόρυξης των τεχνικών όρων δεν άλλαξε την κατάταξη των εγγράφων. Ανάμεσα από τα 2 τρεξίματα, θα διατηρήσουμε την χρήση του finetuned reranker, καθώς καταφέρνει να «σηκώσει» τα έγγραφα τα οποία βρίσκονται στο πάνω μέρος του pool. Βάσει αυτών των διαπιστώσεων, συμπεράνθηκε ότι η περαιτέρω παραμετροποίηση της υφιστάμενης διάταξης είναι επαρκής και έδωσε κίνητρο να γίνει αλλαγή του σταδίου ανάκτησης. Για την υπέρβαση του συγκεκριμένου ορίου, κρίθηκε επιβεβλημένη η πλήρης αντικατάσταση του βασικού μοντέλου διανυσματικής αναπαράστασης (embedding model) με μια πιο σύγχρονη, υψηλότερης χωρητικότητας αρχιτεκτονική, η οποία θα πλαισιωθεί στρατηγικά από τον αντίστοιχο, προηγμένο μηχανισμό επανακατάταξης, θέτοντας έτσι νέες βάσεις για την επίτευξη της βέλτιστης ακρίβειας.

3.4 Αξιολόγηση και Επίδραση Εναλλακτικών Μοντέλων Διανυσματικών Αναπαραστάσεων

Η αντικατάσταση του μοντέλου διανυσματικής αναπαράστασης (embedding model) κρίθηκε αναγκαία προκειμένου να ξεπεραστούν οι εγγενείς σημασιολογική περιορισμοί του αρχικού συστήματος και να επιλυθούν αστοχίες που σχετίζονταν με την ελλιπή αναγνώριση τεχνικού λεξιλογίου και συσχετίσεων προϊόντων. Ως βέλτιστη εναλλακτική επιλέχθηκε η οικογένεια μοντέλων BGE, συγκεκριμένα το μοντέλα BAAI/bge-base-en-v1.5, το οποίο παρουσιάζει αποδεδειγμένα υψηλότερες επιδόσεις σε μετρικές αξιολόγησης διατηρώντας παράλληλα την ίδια διάσταση διανυσμάτων (384-dim). Η συγκεκριμένη αναβάθμιση στόχευε στη βαθύτερη κατανόηση περίπλοκων τεχνικών αντιστοιχιών, όπως η σύνδεση εργαλείων με τα αντίστοιχα λογισμικά, στοχεύοντας σε μια συνολική αύξηση της ακρίβειας του συστήματος σε επίπεδα μεταξύ 70% και 80%.

Η αξιολόγηση της αντικατάστασης του μοντέλου διανυσματικής αναπαράστασης (embedding model) αποκάλυψη μια μη αναμενόμενη συμπεριφορά του συστήματος ως προς την τελική του απόδοση. Η πειραματική εφαρμογή των μοντέλων της οικογένειας BGE (BGE-base και BGE-small) κατέδειξε ποσοστό ακρίβειας 60% κατά την μετρική Top-3 Accuracy. Αντιθέτως, η αρχική αρχιτεκτονική που βασιζόταν στο μοντέλο all-MiniLM-L6-v2 διατήρησε σαφές προβάδισμα, επιτυγχάνοντας ποσοστό ακρίβειας 63,33%, το οποίο αντιστοιχεί στην ορθή ανάκτηση 19 εκ των 30 ερωτημάτων του δείγματος αξιολόγησης (dev set) της συλλογής των 801.998 τεχνικών εγγράφων. Το εύρημα αυτό ανέτρεψε την αρχική υπόθεση ότι η χρήση μιας πιο σύγχρονης, υψηλότερης χωρητικότητας αρχιτεκτονικής θα μείωνε την απόσταση από το βέλτιστο

(performance celling). Ως εκ τούτου, αποφασίστηκε η οριστική επιστροφή και εδραίωση του μοντέλου all-MiniLM-L6-v2 ως του κεντρικού μηχανισμού σημασιολογικής αναζήτησης του υβριδικού συστήματος.



Εικόνα 11 - Αποτελέσματα Ανάκτησης έπειτα από χρήση BGE embedding model και BGE reranker

Η εξέταση των περιπτώσεων στις οποίες το σύστημα τοποθέτηση το ορθό έγγραφο στις θέσεις 4 έως 10 (Near miss) αποκάλυψε ζητήματα οριακών αποτυχιών ιεράρχησης. Στις περιπτώσεις αυτές, ενώ το αρχικό σύστημα ανάκτησης λειτούργησε επαρκώς εντάσσοντας τη σωστή λύση στο σύνολο των υποψηφίων (pool), ο μηχανισμός επανακατάταξης (reranker) απέτυχε να την προωθήσει στην τελική τριάδα. Το φαινόμενο αυτό συχνά αποδίδεται σε ασυμφωνία λεξιλογίου (vocabulary mismatch) [10] ή στην αδυναμία του συστήματος να αντιληφθεί πλήρως τις περίπλοκες σημασιολογικές συσχετίσεις τεχνικών εργαλείων, όπως για παράδειγμα ότι το «WebSphere Application Server» σχετίζεται άμεσα με εργαλεία όπως το «Java Health Center».

Η συνολική πορεία βελτίωσης του συστήματος από το αρχικό 40% στο 63,33% καταδεικνύει ότι η αύξηση της ακρίβειας προήλθε από τη συστηματική και στοχευμένη αντιμετώπιση πολλαπλών σημείων συμφόρησης. Η βελτιστοποίηση δεν εξαρτήθηκε μόνο από την ισχύ των διανυσματικών αναπαραστάσεων, αλλά απαίτησε μια σειρά από παρεμβάσεις: τον καθαρισμό των ερωτημάτων από τεχνικό θόρυβο, τη σύντηξη βαθμολογιών (score fusion) την αυστηρή ρύθμιση του αλγορίθμου BM25, καθώς και τη λειτουργία του δείκτη επικάλυψης τεχνικών όρων (overlap score). Η ασυμβατότητα και η χαμηλότερη απόδοση των μοντέλων BGE επιβεβαίωσε ότι σε σύνθετες αρχιτεκτονικές υβριδικής ανάκτησης, η απρόσκοπτη συνεργασία μεταξύ των επιμέρους σταδίων (retrieval και reranking) είναι συχνά κρισιμότερη από την απομονωμένη απόδοση ενός μοναδικού υποσυστήματος.

3.5 Πειραματικά Αποτελέσματα και Συγκριτική Ανάλυση για το Στάδιο Α

Προκειμένου να διασφαλιστεί η αξιοπιστία, η επαναληψιμότητα και η αυστηρή μεθοδολογική τεκμηρίωση της συγκριτικής ανάλυσης μεταξύ των εναλλακτικών μοντέλων διανυσματικής αναπαράστασης, αναπτύχθηκε και εφαρμόστηκε ένα εξειδικευμένο, αυτοματοποιημένο σενάριο αξιολόγησης (evaluate_full.py) [14]. Ο εν λόγω μηχανισμός σχεδιάστηκε για να εκτελεί μια πλήρη, «από άκρο σε άκρο» (end-to-end) αποτίμηση του υβριδικού συστήματος, αντλώντας το σύνολο των επιβεβαιωμένα απαντήσιμων ερωτημάτων (answerable questions) από το δείγμα (dev set) του TechQA και υποβάλλοντάς τα προγραμματιστικά στο κεντρικό API αναζήτησης. Κατά τη διάρκεια της εκτέλεσής του, το σενάριο αντιπαρέβαλε δυναμικά τις προτεινόμενες λύσεις με τα εκ των προτέρων γνωστά έγγραφα αναφοράς (ground truth), καταγράφοντας την ακριβή θέση ανάκτησης. Βάσει αυτής της διαδικασίας, υπολογίστηκε ένα ευρύ φάσμα καθιερωμένων μετρικών Ανάκτησης Πληροφορίας, συμπεριλαμβανομένης της Ακρίβειας σε πολλαπλά βάθη ανάκτησης (Top-1, Top-3, Top-5, Top-10) με χρήση τα διαστήματα εμπιστοσύνης 95% (Wilson score intervals), καθώς και των σύνθετων δεικτών Μέσης Αντίστροφης Κατάταξης (Mean Reciprocal Rank - MRR) και F1@K. Η συστηματική αυτή διεργασία κατέληξε στην αυτόματη παραγωγή ιστογραμμάτων κατανομής θέσεων και στην εξαγωγή των δεδομένων σε δομημένη μορφή (CSV) ανά αίτημα (per-ticket), παρέχοντας το αδιάσειστο και αντικειμενικό ποσοτικό υπόβαθρο επί του οποίου θεμελιώθηκε η επακόλουθη συγκριτική ανάλυση.

	A	B	C	D	E	F	G	H	I
1	qid	gt_id	position	top1	top3	top5	top10	f1_at_3	f1_at_10
2	DEV_Q000	swg24042191	32	0	0	0	0	0	0
3	DEV_Q002	swg21978390	3	0	1	1	1	5	1818
4	DEV_Q007	swg21625776	1	1	1	1	1	5	1818
5	DEV_Q008	swg21412061	1	1	1	1	1	5	1818
6	DEV_Q010	swg21317981	1	1	1	1	1	5	1818
7	DEV_Q011	swg21577379	1	1	1	1	1	5	1818
8	DEV_Q012	swg21959723	1	1	1	1	1	5	1818
9	DEV_Q013	swg21665766	7	0	0	0	1	0	1818
10	DEV_Q014	swg21138332	4	0	0	1	1	0	1818
11	DEV_Q016	swg21502095	3	0	1	1	1	5	1818
12	DEV_Q019	swg21700397	2	0	1	1	1	5	1818
13	DEV_Q021	swg21298897	5	0	0	1	1	0	1818
14	DEV_Q022	swg22005352	-1	0	0	0	0	0	0
15	DEV_Q023	swg21433278	1	1	1	1	1	5	1818
16	DEV_Q025	swg21959588	1	1	1	1	1	5	1818
17	DEV_Q027	swg21618564	-1	0	0	0	0	0	0
18	DEV_Q028	swg21975747	36	0	0	0	0	0	0
19	DEV_Q029	swg21496354	1	1	1	1	1	5	1818
20	DEV_Q030	swg21636533	1	1	1	1	1	5	1818

Εικόνα 12 - Στιγμιότυπο CSV αρχείου

Η τελική συγκριτική αξιολόγηση της Φάσης Α διεξήχθη επί ενός διευρυμένου συνόλου 160 απαντήσιμων ερωτημάτων (answerable questions) από το σύνολο δεδομένων του IBM TechQA. Σκοπός της πειραματικής αυτής δοκιμής ήταν η ποσοτική σύγκριση και η οριστική επιλογή του βέλτιστου μοντέλου διανυσματικής αναπαράστασης (embedding model) μεταξύ του αρχικού all-MiniLM-L6-v2 και του εναλλακτικού, νεότερης γενιάς, μοντέλου BGE.

```
Evaluating 160 answerable questions...
======================================================================
  [25/160] Top-3 so far: 52.0% | ETA: 3.6 min
  [50/160] Top-3 so far: 52.0% | ETA: 2.4 min
  [75/160] Top-3 so far: 46.7% | ETA: 1.7 min
  [100/160] Top-3 so far: 55.0% | ETA: 1.2 min
  [125/160] Top-3 so far: 53.6% | ETA: 0.7 min
  [150/160] Top-3 so far: 56.0% | ETA: 0.2 min

======================================================================
EVALUATION RESULTS — 160 questions, 3.1 min
======================================================================
  Top-1  Accuracy: 43.12%  (95% CI: 35.7% – 50.9%)  [69/160]  |  F1@1: 0.4313
  Top-3  Accuracy: 55.00%  (95% CI: 47.3% – 62.5%)  [88/160]  |  F1@3: 0.2750
  Top-5  Accuracy: 64.38%  (95% CI: 56.7% – 71.4%)  [103/160]  |  F1@5: 0.2146
  Top-10 Accuracy: 71.25%  (95% CI: 63.8% – 77.7%)  [114/160]  |  F1@10: 0.1295
  MRR (Mean Reciprocal Rank): 0.5208

======================================================================
F1@K BREAKDOWN (macro-averaged, single GT ανά query)
======================================================================
  Precision@K = 1/K (αν GT στα top-K), Recall@K = 1 (αν GT στα top-K)
  F1@1 : 0.4313  (max δυνατό: 1.0000, επιτεύχθηκε 43% του max)
  F1@3 : 0.2750  (max δυνατό: 0.5000, επιτεύχθηκε 55% του max)
  F1@5 : 0.2146  (max δυνατό: 0.3333, επιτεύχθηκε 64% του max)
  F1@10: 0.1295  (max δυνατό: 0.1818, επιτεύχθηκε 71% του max)

======================================================================
POSITION HISTOGRAM
======================================================================
  1–3         |   88 ( 55.0%) ############################
  4–10        |   26 ( 16.2%) ########
  11–25       |   11 (  6.9%) ###
  26–50       |    4 (  2.5%) #
  51–100      |    7 (  4.4%) ##
  missing     |   24 ( 15.0%) #######
```

Εικόνα 13 - Αποτελέσματα Συστήματος με BGE ως Embedding Model

Τα πειραματικά αποτελέσματα ανέδειξαν μια ενδιαφέρουσα διαφοροποίηση στη συμπεριφορά των δύο μοντέλων κατά την ιεράρχηση των αποτελεσμάτων. Συγκεκριμένα, το μοντέλο BGE παρουσίασε ελαφρώς υψηλότερη ακρίβεια στην απόλυτη πρώτη θέση (Top-1 Accuracy),), καταγράφοντας ποσοστό 43,12% (69 στα 160 ερωτήματα), έναντι 41,88% (67 στα 160 ερωτήματα) του MiniLM. Παράλληλα, το BGE κατέγραψε έναν ικανοποιητικό δείκτη Μέσης Αντίστροφης Κατάταξης (Mean Reciprocal Rank - MRR) ίσο με 0,5208. Ωστόσο, η απόδοσή του φθίνει σταδιακά καθώς διευρύνεται το παράθυρο αναζήτησης. Η ακρίβειά του στις τρεις πρώτες θέσεις (Top-3 Accuracy) διαμορφώθηκε στο 55,00%, ενώ στις πέντε πρώτες (Top-5 Accuracy) άγγιξε το 64,38%.

Στον αντίποδα, το αρχικό μοντέλο all-MiniLM-L6-v2 επέδειξε μεγαλύτερη σταθερότητα και ανώτερη ικανότητα ανάκλησης (recall) στις θέσεις που καθορίζουν τη λειτουργικότητα του συστήματος. Συγκεκριμένα, πέτυχε ποσοστό ορθής ανάκτησης 58,13% στις τρεις πρώτες θέσεις (Top-3) και 65,00% στις πέντε πρώτες (Top-5). Η υπεροχή του MiniLM στη μετρική Top-3 (58,13% έναντι 55,00% του BGE) αξιολογήθηκε ως αποφασιστικής σημασίας για την αρχιτεκτονική του έργου. Δεδομένου ότι ο ευφυής πράκτορας σχεδιάστηκε ώστε να τροφοδοτεί το Μεγάλο Γλωσσικό Μοντέλο (LLM) αποκλειστικά με τα τρία κορυφαία σε σχετικότητα έγγραφα προκειμένου να αποφευχθεί η υπερφόρτωση της μνήμης του (context window limit), η μεγιστοποίηση της πιθανότητας να βρίσκεται το έγγραφο αναφοράς (ground truth) εντός αυτής της μικρής λίστας αποτέλεσε το απόλυτο κριτήριο επιλογής.

```
Evaluating 160 answerable questions...
======================================================================
  [25/160] Top-3 so far: 60.0% | ETA: 4.9 min
  [50/160] Top-3 so far: 60.0% | ETA: 4.0 min
  [75/160] Top-3 so far: 54.7% | ETA: 3.2 min
  [100/160] Top-3 so far: 57.0% | ETA: 2.3 min
  [125/160] Top-3 so far: 57.6% | ETA: 1.3 min
  [150/160] Top-3 so far: 58.7% | ETA: 0.4 min

======================================================================
EVALUATION RESULTS — 160 questions, 6.1 min
======================================================================
  Top-1  Accuracy: 41.88%  (95% CI: 34.5% – 49.6%)  [67/160]  |  F1@1: 0.4188
  Top-3  Accuracy: 58.13%  (95% CI: 50.4% – 65.5%)  [93/160]  |  F1@3: 0.2906
  Top-5  Accuracy: 65.00%  (95% CI: 57.3% – 72.0%)  [104/160]  |  F1@5: 0.2167
  Top-10 Accuracy: 72.50%  (95% CI: 65.1% – 78.8%)  [116/160]  |  F1@10: 0.1318
  MRR (Mean Reciprocal Rank): 0.5262

======================================================================
F1@K BREAKDOWN (macro-averaged, single GT ανά query)
======================================================================
  Precision@K = 1/K (αν GT στα top-K), Recall@K = 1 (αν GT στα top-K)
  F1@1 : 0.4188  (max δυνατό: 1.0000, επιτεύχθηκε 42% του max)
  F1@3 : 0.2906  (max δυνατό: 0.5000, επιτεύχθηκε 58% του max)
  F1@5 : 0.2167  (max δυνατό: 0.3333, επιτεύχθηκε 65% του max)
  F1@10: 0.1318  (max δυνατό: 0.1818, επιτεύχθηκε 73% του max)

======================================================================
POSITION HISTOGRAM
======================================================================
  1-3        |   93 ( 58.1%) ##############################
  4-10       |   23 ( 14.4%) #######
  11-25      |    8 (  5.0%) ##
  26-50      |   11 (  6.9%) ###
  51-100     |    4 (  2.5%) #
  missing    |   21 ( 13.1%) ######
```

Εικόνα 14 - Αποτελέσματα Συστήματος με all-MiniLM-L6-v2 ως Embedding Model

Συμπερασματικά, η συγκριτική ανάλυση οδήγησε στην οριστική εδραίωση του all-MiniLM-L6-v2 ως του βασικού μοντέλου διανυσματικής αναπαράστασης για την παραγωγική λειτουργία του συστήματος. Η επιβεβαιωμένη ικανότητά του να ανακτά το ορθό έγγραφο εντός της κορυφαίας τριάδας σε ποσοστό σχεδόν 60% επί ενός εξαιρετικά απαιτητικού δείγματος 160 ερωτημάτων με έντονο τεχνικό θόρυβο, σήμανε την επιτυχή ολοκλήρωση της Φάσης Α. Με την οριστικοποίηση και βελτιστοποίηση της υβριδικής ροής

ανάκτησης (Hybrid Retrieval Pipeline), τέθηκαν οι απαραίτητες και στέρεες βάσεις για τη μετάβαση στη Φάση Β. Σε αυτό το επόμενο στάδιο, το μοντέλο Llama-3-8B-Instruct θα κληθεί να αξιοποιήσει τις υψηλής ακρίβειας πληροφορίες που του παρέχει το MiniLM, με στόχο την παραγωγή και σύνθεση τελικών, αυτοματοποιημένων τεχνικών λύσεων.

4. Ενσωμάτωση και εξειδίκευση μεγάλων γλωσσικών μοντέλων (Στάδιο Β)

Μετά την ολοκλήρωση και τη σταθεροποίηση του υβριδικού μηχανισμού ανάκτησης, η αναπτυξιακή προσπάθεια μετατοπίστηκε στο δεύτερο διακριτό στάδιο του συστήματος, το οποίο αφορούσε την προσθήκη του παραγωγικού επιπέδου (generation level). Ενώ το πρώτο στάδιο διασφάλιζε τον εντοπισμό των σχετικών τεχνικών εγγράφων (technotes), το δεύτερο στάδιο ανέλαβε τη σύνθεση μιας συνεκτικής και εφαρμόσιμης λύσης, μέσω της ενσωμάτωσης ενός μεγάλου γλωσσικού μοντέλου (Large Language Model - LLM), το οποίο λειτουργεί αποκλειστικά επί τη βάσει των ανακτηθέντων εγγράφων. Με τον τρόπο αυτό, το σύστημα μετασχηματίστηκε από έναν μηχανισμό ανάκτησης πληροφορίας σε έναν ολοκληρωμένο βοηθό επίλυσης περιστατικών, ικανό να παρέχει δομημένες οδηγίες αντιμετώπισης προς τον μηχανικό υποστήριξης.

Κατά τη μετάβαση στο στάδιο αυτό, αναδείχθηκε ότι η πλέον κρίσιμη πρόκληση δεν ήταν η παραγωγή σωστών λύσεων στις περιπτώσεις όπου η γνωσιακή βάση περιείχε την απάντηση, αλλά η ικανότητα του μοντέλου να αναγνωρίζει τις περιπτώσεις στις οποίες η βάση δεν διέθετε τη λύση και, ως εκ τούτου, να απέχει αντί να παράγει μια εσφαλμένη αλλά φαινομενικά αξιόπιστη απάντηση. Η συμπεριφορά αυτή, δηλαδή η αυτεπίγνωση των ορίων της διαθέσιμης γνώσης, αναγνωρίστηκε ως ουσιώδης προϋπόθεση για την αξιοπιστία ενός αυτόνομου συστήματος τεχνικής υποστήριξης, καθώς η παραπλανητική βεβαιότητα σε ένα περιβάλλον παραγωγής (production) ενέχει σαφώς υψηλότερο κόστος από μια απλή παραπομπή του περιστατικού σε ανθρώπινο χειριστή. Στη βάση αυτής της παραδοχής, η ανάπτυξη του σταδίου Β διαρθρώθηκε σε τρεις διαδοχικές προσεγγίσεις: την αρχιτεκτονική ενσωμάτωση του βασικού μοντέλου, την εισαγωγή ενός ευρετικού μηχανισμού πύλης εμπιστοσύνης (heuristic gate), και τελικώς την εξειδίκευση του μοντέλου μέσω της μεθόδου QLoRA με στόχο τη διδασκαλία της συμπεριφοράς αποχής.

Η πρόκληση της αποχής εντάσσεται σε ένα ευρύτερο και θεμελιώδες ζήτημα των μεγάλων γλωσσικών μοντέλων, εκείνο της παραγωγής ευλογοφανών αλλά αβάσιμων απαντήσεων (hallucination). Ένα γλωσσικό μοντέλο, εκπαιδευμένο να προβλέπει το πιθανότερο επόμενο τμήμα κειμένου, τείνει εγγενώς να συνθέτει μια απάντηση ακόμη και όταν δεν διαθέτει επαρκή τεκμηρίωση, καθώς η άρνηση απάντησης δεν αποτελεί φυσική έκβαση της γλωσσικής μοντελοποίησης. Σε ένα σύστημα ανάκτησης-επαυξημένης παραγωγής (Retrieval - Augmented Generation), το φαινόμενο αυτό μετριάζεται μεν από την παρουσία των ανακτηθέντων εγγράφων, δεν εξαλείφεται όμως: όταν η ανάκτηση αποτύχει να εντοπίσει το ορθό έγγραφο, το μοντέλο εξακολουθεί να διαθέτει πέντε φαινομενικά σχετικά έγγραφα επί των οποίων μπορεί να στηρίξει μια εσφαλμένη λύση.

Η αντιμετώπιση του ζητήματος αυτού μέσω της αποχής, αντί μέσω της απλής επιδίωξης υψηλότερης ακρίβειας, αποτελεί συνειδητή σχεδιαστική επιλογή. Η ικανότητα ενός συστήματος να αναγνωρίζει τα όρια

της γνώσης του και να παραπέμπει σε ανθρώπινο χειριστή, γνωστή στη βιβλιογραφία ως επιλεκτική πρόβλεψη (selective prediction) [21, 22], μετατρέπει ένα δυνητικά επικίνδυνο σφάλμα σε μια ελεγχόμενη και ασφαλή κλιμάκωση. Η παρούσα εργασία αντιμετωπίζει την αποχή όχι ως δευτερεύον χαρακτηριστικό αλλά ως κεντρικό ποιοτικό στόχο, καθώς σε ένα λειτουργικό περιβάλλον τεχνικής υποστήριξης η αξιοπιστία ενός αυτόνομου συστήματος κρίνεται εξίσου από το τι επιλέγει να μην απαντήσει όσο και από την ορθότητα όσων απαντά.

Πρέπει να σημειωθεί ότι η αρχιτεκτονική ανάκτησης-επαυξημένης παραγωγής επιλέχθηκε ακριβώς επειδή προσφέρει έναν φυσικό μηχανισμό τεκμηρίωσης: κάθε παραγόμενη λύση μπορεί, καταρχήν, να αντιστοιχιστεί σε συγκεκριμένα έγγραφα της γνωσιακής βάσης. Η ιδιότητα αυτή είναι κρίσιμη για ένα σύστημα υποστήριξης, όπου η δυνατότητα ελέγχου της προέλευσης μιας λύσης από τον ανθρώπινο μηχανικό αποτελεί προϋπόθεση εμπιστοσύνης. Τα τρία διαδοχικά βήματα που ακολουθούν: η ενσωμάτωση του βασικού μοντέλου, η ευρετική πύλη και η εξειδίκευση, διευρύνουν σταδιακά κατά πόσο η ιδιότητα αυτή αρκεί από μόνη της ή απαιτεί την πρόσθετη διδασκαλία της συμπεριφοράς αποχής.

4.1 Αρχιτεκτονική Ενσωμάτωση και Containerization του Μοντέλου Llama-3-8B-Instruct

Για την υλοποίηση του παραγωγικού επιπέδου επιλέχθηκε το μοντέλο Llama-3-8B-Instruct, το οποίο ενσωματώθηκε στην αρχιτεκτονική μικροϋπηρεσιών (microservices) του συστήματος μέσω του εργαλείου εξυπηρέτησης Ollama. Η επιλογή αυτή εξυπηρέτησε τη λογική της πλήρους απομόνωσης των επιμέρους συνιστωσών, καθώς το μοντέλο εγκαταστάθηκε ως αυτοτελής υπηρεσία (container) εντός της διάταξης Docker Compose [17] δίπλα στη διανυσματική βάση δεδομένων (Chroma DB) και στην κεντρική υπηρεσία διεπαφής προγραμματισμού εφαρμογών (API). Η εσωτερική επικοινωνία μεταξύ των containers πραγματοποιήθηκε αποκλειστικά μέσω του δικτύου του Docker, με την υπηρεσία του μοντέλου να είναι προσβάσιμη από την υπόλοιπη διάταξη μέσω του ονόματος υπηρεσίας (service name), γεγονός που εξασφάλισε ένα αυτοτελές και αναπαραγωγίμο περιβάλλον χωρίς εξωτερικές εξαρτήσεις.

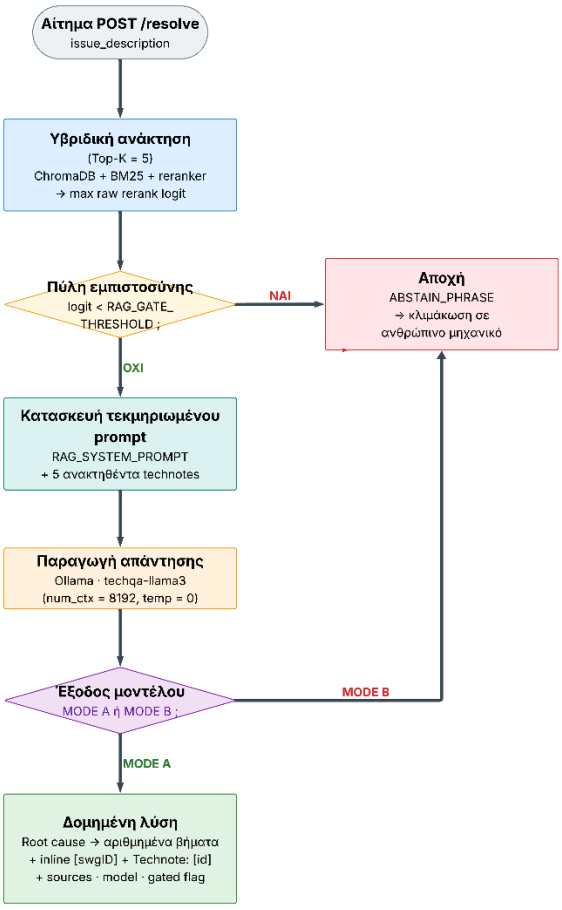
Κατά την παραμετροποίηση της υπηρεσίας του μοντέλου, διαπιστώθηκε ότι το προεπιλεγμένο μήκος του παραθύρου συμφραζόμενων (context window) των 4.096 tokens ήταν ανεπαρκές για τις απαιτήσεις της αρχιτεκτονικής RAG [24], δεδομένου ότι το κάθε ερώτημα συνοδευόταν από πέντε πλήρη τεχνικά έγγραφα ως πλαίσιο. Προς αντιμετώπιση του περιορισμού αυτού, το μήκος του παραθύρου αυξήθηκε ρητά στις 8.192 μονάδες (num_ctx = 8192), ώστε να διασφαλιστεί ότι το σύνολο του ανακτηθέντος πλαισίου θα ήταν διαθέσιμο στο μοντέλο κατά τη διαδικασία σύνθεσης, χωρίς αποκοπή κρίσιμων τμημάτων της τεκμηρίωσης.

Ο πυρήνας του παραγωγικού επιπέδου υλοποιήθηκε μέσω ενός νέου σημείου διεπαφής (endpoint), του /resolve, εντός της κεντρικής υπηρεσίας διεπαφής (main.py), το οποίο ενορχηστρώνει την πλήρη ροή

επίλυση ενός περιστατικού. Συγκεκριμένα, το σημείο αυτό καλεί καταρχάς τον υφιστάμενο μηχανισμό ανάκτησης, στη συνέχεια συγκροτεί ένα εμπλουτισμένο με το ανακτηθέν πλαίσιο ερώτημα (grounded prompt), και τελικώς προωθεί το ερώτημα αυτό στο γλωσσικό μοντέλο, επιστρέφοντας τη δεδομένη απάντηση συνοδευόμενη από τα αναγνωριστικά των εγγράφων στα οποία αυτή βασίστηκε. Καθοριστικό ρόλο στη διάρθρωση της συμπεριφοράς του μοντέλου διαδραμάτισε η σχεδίαση ενός αυστηρού συστημικού μηνύματος (system prompt), ορισμένο στον κώδικα ως RAG_SYSTEM_PROMPT, το οποίο επέβαλε στο μοντέλο την υιοθέτηση μιας εκ δύο αμοιβαία αποκλειόμενων λειτουργειών:

a) Είτε της λύσης παραγωγής (Mode A), οπότε η απάντηση όφειλε να ακολουθεί μια σταθερή δομή αποτελούμενη από μια συνοπτική διάγνωση της γενεσιουργού αιτίας, αριθμημένα βήματα αντιμετώπισης και τη ρητή παραπομπή στα αναγνωριστικά των τεχνικών εγγράφων.
b) Είτε της αποχής (Mode B), οπότε το μοντέλο όφειλε να επιστρέψει αποκλειστικά μια προκαθορισμένη κλιμάκωση προς ανθρώπινο μηχανικό.

Η ρητή αυτή διχοτόμηση απέβλεπε στην αποτροπή της ανάμειξης των δύο λειτουργιών, φαινόμενο το οποίο θα υπονόμευε τη σαφήνεια και την αξιοπιστία της εξόδου του συστήματος.



Σχήμα 12 - Διάγραμμα Αρχιτεκτονικής /resolve

Επιπροσθέτως, στο πλαίσιο της πρώτης απόπειρας διαχείρισης της συμπεριφοράς αποχής, εισήχθη ένας ευρετικός μηχανισμός πύλης εμπιστοσύνης ανάκτησης (retrieval-confidence gate), ο οποίος σχεδιάστηκε ώστε να παραμετροποιείτε και να ενεργοποιείτε μέσω μεταβλητών περιβάλλοντος (environment variables). Ο μηχανισμός αυτός, παρενέβαινει πριν από την κλήση του γλωσσικού μοντέλου, υπολογίζοντας τη μέγιστη ακατέργαστη βαθμολογία εμπιστοσύνης του μηχανισμού επανακατάταξης (max raw reranked logit) επί των υποψηφίων εγγράφων και, εφόσον αυτή υπολειπόταν ενός προκαθορισμένου κατωφλίου (RAG_GATE_THRESHOLD), επέστρεφε αυτομάτως τη φράση αποχής, παρακάμπτοντας εξ ολοκλήρου το κόστος της παραγωγής. Η επιλογή της ακατέργαστης βαθμολογίας (logit), αντί της κανονικοποιημένης, κρίθηκε ουσιώδης, καθώς η πρώτη διατηρεί συκγρισιμότητα μεταξύ διαφορετικών ερωτημάτων, σε αντίθεση με τη δεύτερη η οποία υπολογίζεται σχετικά ως προς το εκάστοτε ερώτημα.

Η επιλογή του Ollama ως εργαλείου εξυπηρέτησης, έναντι μιας εξωτερικής υπηρεσίας νέφους, υπαγορεύθηκε από τρεις παράγοντες. Πρώτον, τη διασφάλιση του απορρήτου, καθώς τα περιστατικά τεχνικής υποστήριξης ενδέχεται να περιέχουν ευαίσθητες πληροφορίες που δεν επιτρέπεται να εξέλθουν του τοπικού περιβάλλοντος. Δεύτερον, την αναπαραγωγιμότητα και τον έλεγχο των εκδόσεων, δεδομένου ότι μια εξωτερική υπηρεσία ενδέχεται να μεταβάλει το υποκείμενο μοντέλο χωρίς προειδοποίηση, υπονομεύοντας τη συγκρισιμότητα των πειραμάτων. Τρίτον, το μηδενικό λειτουργικό κόστος ανά κλήση, το οποίο επέτρεψε τη διεξαγωγή εκτεταμένων αξιολογήσεων με εκατοντάδες κλήσεις χωρίς οικονομικό περιορισμό.

Η κατασκευή του εμπλουτισμένου ερωτήματος (prompt) ακολούθησε μια αυστηρά δομημένη μορφή. Το σύστημα συνθέτει ένα ενιαίο κείμενο που περιλαμβάνει την περιγραφή του περιστατικού και, εν συνεχεία, τα πέντε ανακτηθέντα τεχνικά έγγραφα, καθένα προσδιορισμένο ρητά με το αναγνωριστικό και τον τίτλο του. Η οριοθέτηση αυτή επιτρέπει στο μοντέλο να παραπέμπει με ακρίβεια στην πηγή κάθε βήματος της λύσης, καθιστώντας εφικτή την αλγοριθμική επαλήθευση της τεκμηρίωσης. Το συστημικό μήνυμα, το οποίο προηγείται, επιβάλλει τη χρήση αποκλειστικά των παρεχόμενων εγγράφων και απαγορεύει την επίκληση εξωτερικής γνώσης, περιορίζοντας έτσι το πεδίο επί του οποίου το μοντέλο μπορεί να σφάλει.

Η απόκριση του σημείου διεπαφής δεν περιορίζεται στην παραγόμενη λύση αλλά περιλαμβάνει και δομημένα μεταδεδομένα: τον κατάλογο των εγγράφων που χρησιμοποιήθηκαν με τις βαθμολογίες τους, το όνομα του μοντέλου, καθώς και ένδειξη του αν το περιστατικό απορρίφθηκε από τον μηχανισμό πύλης. Η επιστροφή αυτής της δομημένης πληροφορίας, πέραν του ελεύθερου κειμένου, αποδείχθηκε ουσιώδης για τα επόμενα στάδια, καθώς επέτρεψε τόσο την αυτοματοποιημένη αξιολόγηση όσο και, αργότερα, τη διαμόρφωση της πολιτικής κλιμάκωσης του αυτόνομου πράκτορα επί αντικειμενικών κριτηρίων.

Ως προς τον ευρετικό μηχανισμό πύλης, η τοποθέτησή του πριν από το στάδιο της παραγωγής εξυπηρετεί διπλό σκοπό. Αφενός, παρέχει μια πρώτη γραμμή άμυνας έναντι της επικίνδυνης

συμπεριφοράς, απορρίπτοντας περιστατικά για τα οποία η ανάκτηση δεν επέστρεψε κανένα επαρκώς σχετικό έγγραφο. Αφετέρου, εξοικονομεί υπολογιστικούς πόρους, αποφεύγοντας την ενεργοποίηση του γλωσσικού μοντέλου (μη χρήσιμη λειτουργία αγωγού), στις περιπτώσεις χαμηλής εμπιστοσύνης. Η χρήση της ακατέργαστης βαθμολογίας του μηχανισμού επανακατάταξης ήταν κρίσιμη, καθώς μόνο αυτή διατηρεί συγκρίσιμη κλίμακα μεταξύ διαφορετικών ερωτημάτων, επιτρέποντας τον ορισμό ενός καθολικού κατωφλίου.

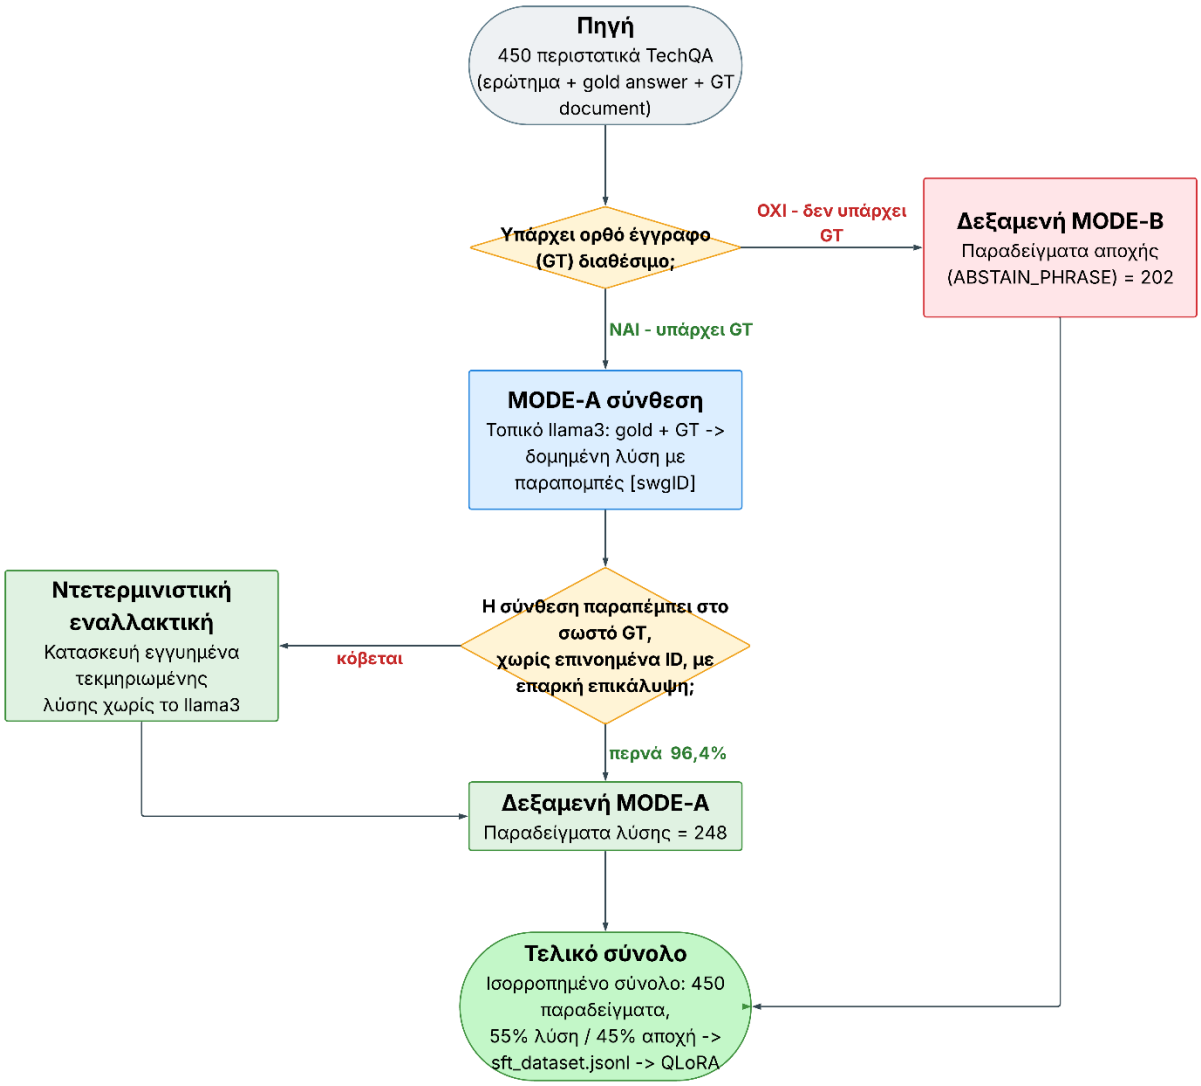
Η αυστηρή διχοτόμηση του συστημικού μηνύματος σε δύο αμοιβαία αποκλειόμενες λειτουργίες δεν ήταν σχεδιαστική λεπτομέρεια αλλά ουσιώδης απαίτηση. Για παράδειγμα, αν επιτρεπόταν η ανάμειξη λύσης και αποχής, μια απάντηση που προτείνει βήματα αλλά ταυτόχρονα εκφράζει αβεβαιότητα, με αποτέλεσμα να ήταν τόσο διφορούμενο τόσο για τον άνθρωπο όσο και για την κάθε μεταγενέστερη αυτοματοποιημένη επεξεργασία. Η επιβολή μιας σταθερής, προκαθορισμένης φράσης αποχής, ήταν εξίσου κρίσιμη, καθώς κατέστησε δυνατή την αλγοριθμική αναγνώριση της απόφασης αποχής από τα επόμενα στάδια του συστήματος, χωρίς ανάγκη ερμηνείας ελεύθερου κειμένου.

4.2 Εξειδίκευση Παραμέτρων στο Τεχνικό Πεδίο (Domain-Specific Fine-Tuning) μέσω της Μεθόδου QLoRA

Η πειραματική αξιολόγηση του βασικού μοντέλου, σε συνδυασμό με τον ευρετικό μηχανισμό πύλης, ανέδειξε μια θεμελιώδη αδυναμία η οποία υπαγόρευσε τη μετάβαση σε προσέγγιση εξειδίκευσης. Συγκεκριμένα, διαπιστώθηκε ότι το μη εξειδικευμένο μοντέλο Llama-3-8B-Instruct σχεδόν ουδέποτε απείχε από την παραγωγή απάντησης, με αποτέλεσμα να παράγει με υψηλή βεβαιότητα εσφαλμένες λύσεις στη συντριπτική πλειονότητα των περιπτώσεων όπου το ορθό έγγραφο απουσίαζε από το ανακτηθέν πλαίσιο. Παράλληλα, η ανάλυση του ευρετικού μηχανισμού πύλης αποκάλυψε ότι οι κατανομές της βαθμολογίας εμπιστοσύνης για τις περιπτώσεις παρουσίας και απουσίας του ορθού εγγράφου επικαλύπτονταν σε σημαντικό βαθμό, γεγονός που καθιστούσε αδύνατο τον αξιόπιστο διαχωρισμό των «βέβαιων παραπλανητικών» εγγράφων (confident distractors) μέσω ενός απλού κατωφλίου. Η διαπίστωση αυτή, η οποία συνιστά ένα αξιοσημείωτο αρνητικό αποτέλεσμα, τεκμηρίωσε ότι η εμπιστοσύνη ανάκτησης αποτελεί μεν αναγκαία, όχι όμως και ικανή συνθήκη για την ορθή αποχή, και συνακόλουθα ανέδειξε την ανάγκη για την υιοθέτηση μιας *διδασκόμενης* συμπεριφοράς αποχής (learned abstention), σε αντιδιαστολή με την ευρετική.

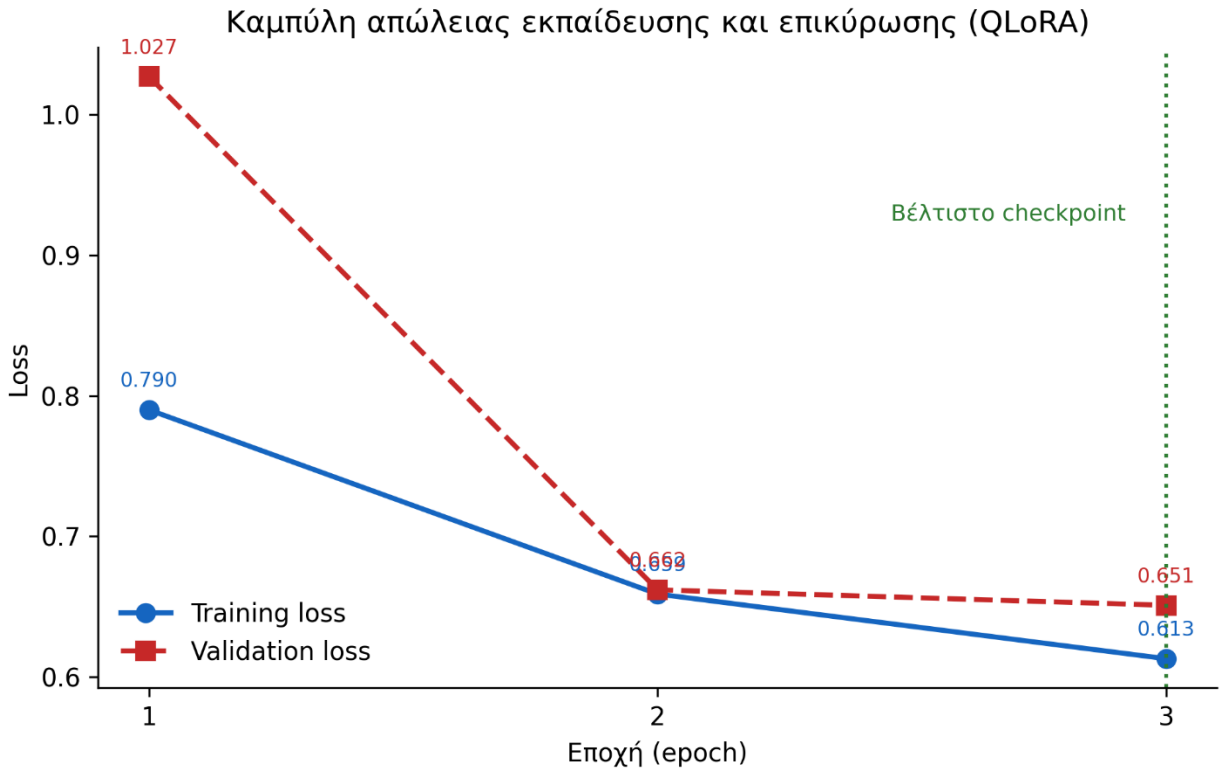
Προς τον σκοπό αυτό, επιλέχθηκε η μέθοδος της αποδοτικής ως προς τις παραμέτρους προσαρμογής QLoRA (Quantized Low-Rank Adaptation) [15,16], η οποία επιτρέπει την εξειδίκευση ενός μοντέλου οκτώ δισεκατομμυρίων παραμέτρων υπό τους περιορισμούς καταναλωτικού υλικού. Θεμελιώδης προϋπόθεση για την εφαρμογή της μεθόδου ήταν η κατασκευή ενός κατάλληλου συνόλου δεδομένων εποπτευόμενης εκπαίδευσης (Supervised Fine-Tuning dataset) [23], το οποίο κατασκευάστηκε μέσω ειδικού σεναρίου

(build_sft_dataset.py). Το σύνολο αυτό συγκροτήθηκε από 450 περιστατικά του συνόλου εκπαίδευσης και ενσωμάτωσε δύο τύπους παραδειγμάτων. Για τις περιπτώσεις όπου το ορθό έγγραφο ήταν παρόν, οι δομημένοι στόχοι (targets) της λειτουργίας παραγωγής λύσης συντέθηκαν από το τοπικό μοντέλο Llama-3-8B με βάση τις πρότυπες απαντήσεις (gold answers) και το αντίστοιχο τεχνικό έγγραφο, ενώ κάθε παραγόμενος στόχος υποβλήθηκε σε φιλτράρισμα πιστότητας (faithfulness filter) ώστε να διασφαλιστεί η απουσία επινοημένων αναγνωριστικών και η τεκμηρίωση κάθε βήματος. Αντιστοίχως, για τις περιπτώσεις απουσίας του ορθού εγγράφου, ως στόχος ορίστηκε η φράση αποχής, εν μέσω ρεαλιστικών παραπλανητικών εγγράφων στο πλαίσιο. Η τελική σύνθεση του συνόλου προέκυψε ισορροπημένη, με ποσοστό επιτυχούς σύνθεσης 96,4% και κατανομή περίπου 55% παραδειγμάτων λύσης έναντι 45% παραδειγμάτων αποχής, αναλογία η οποία παρείχε επαρκές σήμα για την εκμάθηση της συμπεριφοράς αποχής χωρίς να απαιτηθεί τεχνητή επαύξηση των δεδομένων.



Σχήμα 13 - Pipeline (Αγωγός) SFT Dataset

Η ίδια η διαδικασία της εκπαίδευσης υλοποιήθηκε με τετραδική κβαντικοποίηση (4-bit NF4) του βασικού μοντέλου, με την προσαρμογή να εφαρμόζεται μέσω προσαρμογέων χαμηλής τάξης (LoRA) [15] επί του συνόλου των γραμμικών προβολών, με τάξη r = 16 και συντελεστή κλίμακας α = 32. Ιδιαίτερη μέριμνα δόθηκε στην εφαρμογή της συνάρτησης απώλειας αποκλειστικά επί των tokens της απάντησης, μέσω της απόκρυψης (masking) του συστημικού μηνύματος και του ερωτήματος του χρήστη, ώστε το μοντέλο να διδαχθεί τη συμπεριφορά παραγωγής και όχι την απομνημόνευση του σταθερού πλαισίου. Η εκπαίδευση διεξήχθη για τρεις εποχές (epochs) σε υποδομή νέφους (Kaggle), μέσω του Notebook (qlora_finetune_llama3.ipynb) (βλ. Παράρτημα Z) με επιταχυντή τύπου T4, ενώ η παρακολούθηση της απώλειας επικύρωσης (validation loss) κατέδειξε την ομαλή σύγκλιση του μοντέλου και χωρίς ένδειξη υπερπροσαρμογής (overfitting), καθώς η απώλεια επικύρωσης εξακολουθούσε να μειώνεται έως την τρίτη εποχή· ως εκ τούτου, μέσω του μηχανισμού αυτόματης επιλογής του βέλτιστου σημείου ελέγχου (best checkpoint), διατηρήθηκε το στιγμιότυπο της τρίτης εποχής, το οποίο παρουσίασε την ελάχιστη απώλεια επικύρωσης.



Σχήμα 14 - Καμπύλη απώλειας εκπαίδευσης (QLoRA)

Ολοκληρώνοντας την διαδικασία, ο εκπαιδευμένος προσαρμογέας ενσωματώθηκε εκ νέου στην αρχιτεκτονική εξυπηρέτησης. Λόγω των περιορισμών της διαθέσιμης μνήμης του τοπικού συστήματος, η οποία δεν επαρκούσε για τη συγχώνευση (merge) του πλήρους μοντέλου σε ακρίβεια fp16, υιοθετήθηκε μια πιο ελαφριά προσέγγιση: μετατράπηκε αποκλειστικά ο προσαρμογέας σε μορφή GGUF (μέσω του

βοηθητικού σεναρίου μετατροπής του llama.cpp convert_lora_to_gguf.py) [25] και εφαρμόστηκε κατά τον χρόνο εκτέλεσης (runtime) επί του βασικού κβαντικοποιημένου μοντέλου, μέσω ενός αρχείου ορισμού του Ollama (Modelfile). Η προσέγγιση αυτή, πέραν της αντιμετώπισης του περιορισμού μνήμης, εναρμονιζόταν εννοιολογικά με τη λογική της αρχιτεκτονικής, καθώς διατηρούσε σαφή διαχωρισμό μεταξύ του αναλλοίωτου βασικού μοντέλου και του διδαγμένου προσαρμογέα, ο οποίος ενσωματώνει αποκλειστικά την εξειδικευμένη συμπεριφορά. Το τελικό εξειδικευμένο μοντέλο (techqa-llama3) εγκαταστάθηκε εντός της υπηρεσίας Ollama της διάταξης, καθιστώντας το σύνολο του συστήματος πλήρως αυτοτελές.

Η μέθοδο QLoRA συνδυάζει δύο τεχνικές που από κοινού καθιστούν εφικτή την εξειδίκευση ενός μοντέλου οκτώ δισεκατομμυρίων παραμέτρων σε υλικό καταναλωτικού επιπέδου. Η πρώτη, η προσαρμογή χαμηλής τάξης (Low-Rank Adaptation) [15,16], παγώνει τα βάρη του βασικού μοντέλου και εισάγει μικρούς, εκπαιδεύσιμους πίνακες χαμηλής τάξης στις γραμμικές προβολές· έτσι, αντί να ενημερώνονται δισεκατομμύρια παράμετροι, εκπαιδεύεται μόλις ένα κλάσμα της τάξης του ενός τοις εκατό. Η δεύτερη, η τετραδική κβαντικοποίηση (4-bit quantization), αποθηκεύει τα παγωμένα βάρη σε ακρίβεια τεσσάρων δυαδικών ψηφίων, μειώνοντας δραστικά το αποτύπωμα μνήμης και επιτρέποντας την ολοκλήρωση της εκπαίδευσης εντός των περιορισμών ενός μοναδικού επιταχυντή.

Η επιλογή του συγκεκριμένου βασικού μοντέλου, του Llama-3-8B-Instruct, βασίστηκε στην ισορροπία μεταξύ ικανότητας και υπολογιστικών απαιτήσεων: ένα μοντέλο αυτού του μεγέθους είναι αρκετά ικανό για την παραγωγή δομημένων τεχνικών λύσεων, παραμένοντας ταυτόχρονα διαχειρίσιμο σε υλικό καταναλωτικού επιπέδου. Κρίσιμο ήταν επίσης ότι το βασικό μοντέλο επί του οποίου εφαρμόστηκε η εξειδίκευση ταυτιζόταν με εκείνο που εξυπηρετούσε το σύστημα, διασφαλίζοντας ότι η διδαγμένη συμπεριφορά μεταφερόταν χωρίς αναντιστοιχία μεταξύ των συνθηκών εκπαίδευσης και εκτέλεσης.

Η κατασκευή του συνόλου εκπαίδευσης βασίστηκε σε μια προσέγγιση απόσταξης γνώσης (knowledge distillation), κατά την οποία η ουσία της λύσης προερχόταν από τις πρότυπες απαντήσεις του TechQA, ενώ η δομημένη μορφή παραγόταν από το ίδιο το τοπικό μοντέλο. Η προσέγγιση αυτή ενείχε έναν εγγενή κίνδυνο: αν το μοντέλο παρήγαγε βήματα ή αναγνωριστικά μη τεκμηριωμένα στην πρότυπη απάντηση, το σύνολο εκπαίδευσης θα δίδασκε ακριβώς τη συμπεριφορά που η εργασία επιδίωκε να εξαλείψει. Προς αποφυγή αυτού, κάθε παραγόμενος στόχος υποβλήθηκε σε αυστηρό φίλτρο πιστότητας που απαιτούσε την παραπομπή στο ορθό έγγραφο, την απουσία επινοημένων αναγνωριστικών και έναν ελάχιστο βαθμό λεκτικής επικάλυψης με την τεκμηρίωση, δηλαδή, όσοι στόχοι δεν πληρούσαν τα κριτήρια αντικαθίσταντο από μια ντετερμινιστική, εγγυημένα τεκμηριωμένη εναλλακτική.

Η ισορροπία του συνόλου μεταξύ παραδειγμάτων λύσης και παραδειγμάτων αποχής, περίπου 55% προς 45%, ήταν καθοριστική για την επιτυχία της εκπαίδευσης. Ένα σύνολο κυριαρχούμενο από παραδείγματα λύσης θα ενίσχυε την τάση του μοντέλου να απαντά πάντοτε, ενώ η επαρκής παρουσία παραδειγμάτων

αποχής δίδαξε στο μοντέλο ότι η άρνηση απάντησης αποτελεί εξίσου έγκυρη και επιθυμητή έξοδο. Επιπλέον, η εφαρμογή της συνάρτησης απώλειας αποκλειστικά επί των tokens της απάντησης, με απόκρυψη του συστημικού μηνύματος και του ερωτήματος, διασφάλισε ότι το μοντέλο δεν σπατάλησε χωρητικότητα στην απομνημόνευση του σταθερού, επαναλαμβανόμενου πλαισίου, εστιάζοντας αντ' αυτού στην εκμάθηση της επιθυμητής συμπεριφοράς.

Η εκπαίδευση διεξήχθη σε υποδομή νέφους με επιταχυντή περιορισμένης μνήμης, γεγονός που κατέστησε αναγκαία τη λεπτομερή διαχείριση των πόρων, όπως τη μείωση του κατακερματισμού της μνήμης και τη μεταφορά ενδιάμεσων ενεργοποιήσεων. Η παρακολούθηση της απώλειας επικύρωσης κατέδειξε ομαλή σύγκλιση, με τον ρυθμό βελτίωσης να εξομαλύνεται προς το τέλος της εκπαίδευσης. Ο εκπαιδευμένος προσαρμογέας, μεγέθους ελάχιστου κλάσματος του πλήρους μοντέλου, ενσωματώθηκε εν συνεχεία στην αρχιτεκτονική εξυπηρέτησης και εφαρμόστηκε επί του βασικού κβαντικοποιημένου μοντέλου κατά τον χρόνο εκτέλεσης, διατηρώντας σαφή διαχωρισμό μεταξύ του αναλλοίωτου βασικού μοντέλου και της διδαγμένης συμπεριφοράς.

Η μετάβαση στη διδασκόμενη αποχή δικαιολογήθηκε από ένα σαφές αρνητικό αποτέλεσμα που προέκυψε κατά την ανάλυση του ευρετικού μηχανισμού πύλης. Η κατανομή της βαθμολογίας εμπιστοσύνης για τα περιστατικά στα οποία το ορθό έγγραφο είχε ανακτηθεί επικαλυπτόταν ουσιωδώς με την αντίστοιχη κατανομή για τα περιστατικά στα οποία απουσίαζε. Η επικάλυψη αυτή συνεπάγεται ότι δεν υφίσταται κατώφλι ικανό να διαχωρίσει αξιόπιστα τις δύο κατηγορίες, καθώς οποιαδήποτε τιμή θα απέρριπτε ταυτόχρονα και ορθά περιστατικά. Το εύρημα τεκμηρίωσε ότι η εμπιστοσύνη ανάκτησης αποτελεί αναγκαία μεν αλλά όχι ικανή συνθήκη για την ορθή αποχή, αναδεικνύοντας την ανάγκη για μια πιο εκλεπτυσμένη κρίση ενσωματωμένη στο ίδιο το μοντέλο.

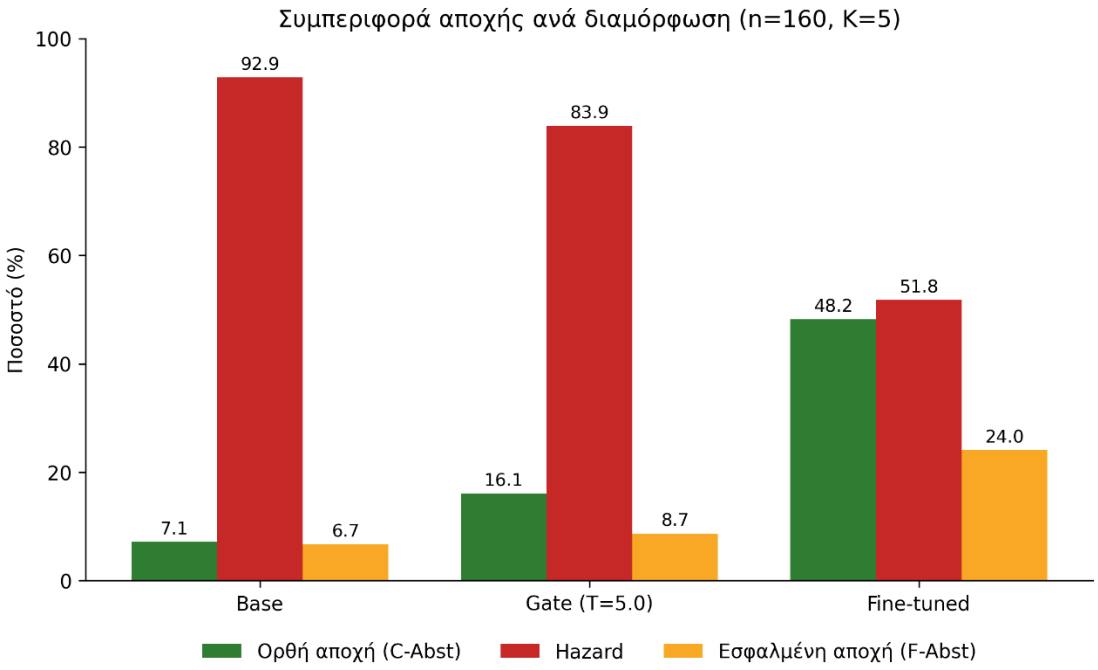
Οι παράμετροι της προσαρμογής επιλέχθηκαν με γνώμονα το μέγεθος και τη φύση του συνόλου εκπαίδευσης. Η τάξη των προσαρμοστικών πινάκων και ο συντελεστής κλίμακας ορίστηκαν σε μέτριες τιμές, επαρκείς για την εκμάθηση μιας συμπεριφοράς χωρίς την εισαγωγή υπερβολικής χωρητικότητας που θα ευνοούσε την υπερπροσαρμογή (overfitting) σε ένα σχετικά μικρό σύνολο μερικών εκατοντάδων παραδειγμάτων. Ο κίνδυνος υπερπροσαρμογής (overfitting), εγγενής σε τόσο περιορισμένα δεδομένα, αντιμετωπίστηκε μέσω της αυτόματης επιλογής του σημείου ελέγχου με την ελάχιστη απώλεια επικύρωσης, διασφαλίζοντας ότι το τελικό μοντέλο διατηρούσε την ικανότητα γενίκευσης και δεν είχε απομνημονεύσει τα παραδείγματα εκπαίδευσης.

4.3 Αποτελέσματα και Αξιολόγηση της Απόδοσης του Γλωσσικού Μοντέλου για το Στάδιο Β

Προκειμένου αξιολόγηση του παραγωγικού επιπέδου, μέσω ειδικού μηχανισμού αξιολόγησης (evaluate_generation.py), διεξήχθη επί συνόλου 160 επιλύσιμων περιστατικών, με σταθερή παράμετρο

ανάκτησης K = 5, και οργανώθηκε ως συγκριτικό πείραμα τριών διακριτών διαμορφώσεων: του βασικού μοντέλου χωρίς παρέμβαση (base), του βασικού μοντέλου ενισχυμένου με τον ευρετικό μηχανισμό πύλης σε κατώφλι T = 5,0 (gate) και του εξειδικευμένου μέσω QLoRA μοντέλου (fine-tuned). Καθοριστικής σημασίας για την εγκυρότητα της σύγκρισης υπήρξε το γεγονός ότι η ανάκτηση παρέμεινε απολύτως σταθερή και στις τρεις διαμορφώσεις, με την ανάκληση recall@5 να ανέρχεται πανομοιότυπα στο 65,0% (104 εκ των 160 περιστατικών με το ορθό έγγραφο εντός πλαισίου). Το γεγονός αυτό διασφάλισε ότι κάθε παρατηρούμενη διαφορά στην απόδοση οφειλόταν αποκλειστικά στο παραγωγικό επίπεδο και όχι σε μεταβολές του σταδίου ανάκτησης, καθιστώντας το πείραμα ένα ελεγχόμενο συγκριτικό σχήμα.

Οι κρίσιμες μετρικές αξιολόγησης εστίασαν στην ικανότητα ορθής διαχείρισης της αβεβαιότητας. Ως ορθή αποχή (correct abstention) ορίστηκε η αποχή του μοντέλου στις περιπτώσεις απουσίας του ορθού εγγράφου, ενώ ως επικίνδυνη συμπεριφορά (hazard) ορίστηκε η αντίστροφη περίπτωση, δηλαδή η παραγωγή απάντησης παρά την απουσία της ορθής τεκμηρίωσης. Συμπληρωματικά, καταγράφηκαν η εσφαλμένη αποχή (false abstention) στις περιπτώσεις παρουσίας του ορθού εγγράφου, καθώς και η πιστότητα (faithfulness), εκφρασμένη ως το ποσοστό των απαντήσεων που δεν περιείχαν επινοημένα αναγνωριστικά εγγράφων.

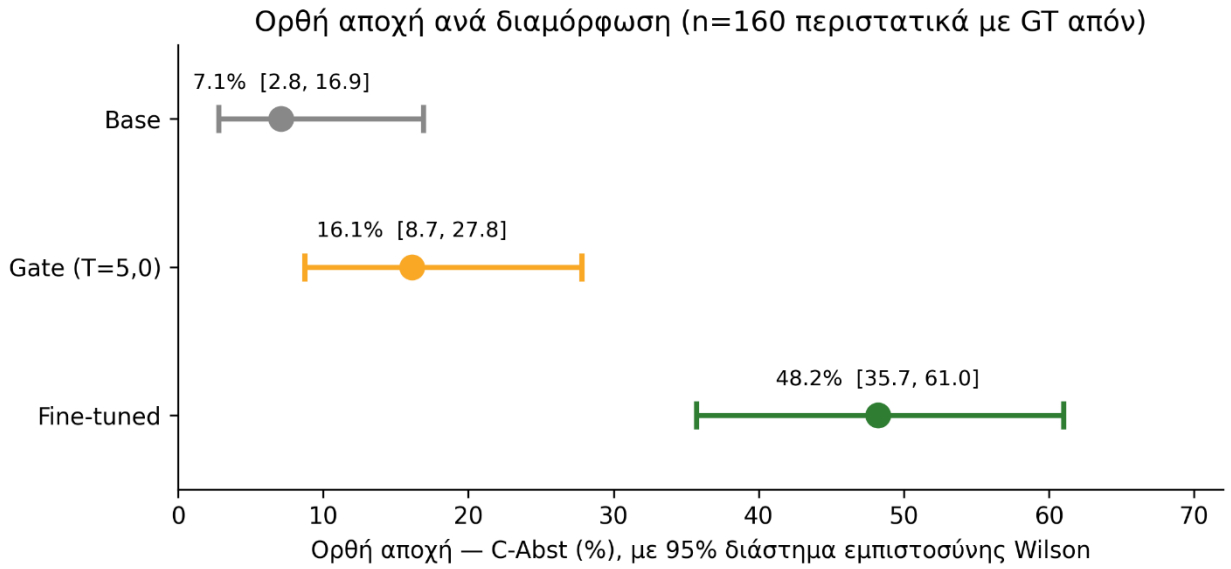


Σχήμα 15 - Συμπεριφορά αποχής ανά διαμόρφωση (C-Abst/Hazard/F-Abst)

Τα αποτελέσματα κατέδειξαν μια σαφή και μονότονη βελτίωση κατά μήκος των τριών διαμορφώσεων. Ως προς την ορθή αποχή (C-Abst), το βασικό μοντέλο (base) σημείωσε ποσοστό μόλις 7,1%, ο ευρετικός μηχανισμός πύλης (Gate) το ανέβασε στο 16,1%, ενώ το εξειδικευμένο μοντέλο (Fine-Tuned) το εκτόξευσε στο 48,2%. Αντιστοίχως, η επικίνδυνη συμπεριφορά (Hazard) μειώθηκε δραστικά από το 92,9% του

βασικού μοντέλου (base) στο 83,9% με τον μηχανισμό πύλης (Gate), και τελικώς στο 51,8% με το εξειδικευμένο μοντέλο (Fine-Tuned). Είναι κρίσιμο να επισημανθεί ότι οι διορθωμένες μετρήσεις των διαμορφώσεων base και gate αναπαρήγαγαν με ακρίβεια τις προγενέστερες τιμές αναφοράς, γεγονός που επιβεβαίωσε την ορθότητα και την αναπαραγωγιμότητα της πειραματικής μεθοδολογίας.

Η στατιστική ανάλυση των αποτελεσμάτων, μέσω του υπολογισμού των διαστημάτων εμπιστοσύνης κατά Wilson σε επίπεδο 95% [19,20], προσέδωσε περαιτέρω βάθος στην ερμηνεία. Διαπιστώθηκε ότι τα διαστήματα εμπιστοσύνης του βασικού μοντέλου και του ευρετικού μηχανισμού πύλης επικαλύπτονταν, γεγονός που καθιστά τη βελτίωση που επέφερε ο μηχανισμός πύλης στατιστικά μη σημαντική στο συγκεκριμένο μέγεθος δείγματος και ενισχύει το προαναφερθέν συμπέρασμα περί των εγγενών περιορισμών της ευρετικής προσέγγισης. Αντιθέτως, το διάστημα εμπιστοσύνης του εξειδικευμένου μοντέλου δεν επικαλυπτόταν με κανένα εκ των δύο, τεκμηριώνοντας ότι η βελτίωση της διδασκόμενης συμπεριφοράς αποχής ήταν αναμφισβήτητα σημαντική.



Σχήμα 16 - Ορθή Αποχή με 95% διάστημα Εμπιστοσύνης Wilson

Η βελτίωση αυτή δεν υπήρξε άνευ κόστους, καθώς η αύξηση της αποχής συνοδεύτηκε από άνοδο του ποσοστού εσφαλμένης αποχής (F-Abst), από το 6,7% του βασικού μοντέλου (base) στο 24,0% του εξειδικευμένου (Fine-Tuned). Ωστόσο, η αξιολόγηση του συμβιβασμού αυτού οφείλει να λαμβάνει υπόψη την ασυμμετρία του κόστους στο συγκεκριμένο πεδίο εφαρμογής: μια εσφαλμένη αποχή επιφέρει απλώς την παραπομπή του περιστατικού σε ανθρώπινο μηχανικό, ήτοι ένα κόστος χρόνου, ενώ μια επικίνδυνη συμπεριφορά συνεπάγεται την παροχή μιας εσφαλμένης λύσης με πλήρη βεβαιότητα, ενδεχομένως οδηγώντας σε λανθασμένες ενέργειες εντός περιβάλλοντος παραγωγής. Υπό αυτό το πρίσμα, η αποτροπή είκοσι τριών επικίνδυνων συμπεριφορών έναντι δεκαοκτώ περιττών κλιμακώσεων συνιστά ένα ευνοϊκό ισοζύγιο, δεδομένης της βαρύτητας του σφάλματος που αποφεύγεται. Εξίσου σημαντικό είναι ότι η

ενίσχυση της αποχής δεν επήλθε εις βάρος της πιστότητας, η οποία διατηρήθηκε (85,2% έναντι 88,9%), υποδηλώνοντας ότι το μοντέλο δεν κατέφυγε σε επινόηση αναγνωριστικών προκειμένου να αποφύγει την αποχή.

Μετρική	Base	Gate (T=5.0)	Fine-Tuned
Ανάκληση	65.0%	65.0%	65.0%
Συνολική Αποχή	6.9%	11.2%	32.5%
Ορθή Αποχή (C-Abst)	7.1%	16.1%	48.2%
Επικίνδυνη Αποχή (Hazard)	92.9%	83.9%	51.8%
Εσφαλμένη Αποχή (F- Abst)	6.7%	8.7%	24.0%
Faithfulness	85.2%	87.3%	88.9%
Hallucination	14.8%	12.7%	11.1%
Rouge-L (Συνολικά)	0.164	0.180	0.270
Rouge-L (GT εντός)	0.187	0.211	0.314
Rouge-L (GT εκτός)	0.120	0.117	0.151

Πίνακας 1 - Σύγκριση Μετρικών ανά Διαμόρφωση με K = 5

Τέλος, για λόγους επιστημονικής ακρίβειας, κρίθηκε σκόπιμη η επισήμανση δύο επιφυλάξεων ως προς την ερμηνεία των αποτελεσμάτων. Πρώτον, η παρατηρούμενη αύξηση της μετρικής ROUGE-L (από 0,187 σε 0,314 για τις περιπτώσεις παρουσίας του ορθού εγγράφου) αποδίδεται εν μέρει στη στιλιστική συγγένεια (stylistic alignment) και όχι αποκλειστικά στην ουσιαστική ορθότητα, δεδομένου ότι οι στόχοι εκπαίδευσης συντέθηκαν εξ ορισμού με βάση τις πρότυπες απαντήσεις. Δεύτερον, μέσω τριών αθέλητων επαναλήψεων της ίδιας διαμόρφωσης, καταγράφηκε μια εκτίμηση της διακύμανσης μεταξύ εκτελέσεων (run to run variance) της τάξης ±5 ποσοστιαίων μονάδων στις μετρικές αποχής, γεγονός που τεκμηριώνει τη μη ντετερμινιστική φύση της παραγωγής ακόμη και υπό μηδενική θερμοκρασία (temperature = 0). Συνολικά, τα ευρήματα του σταδίου Β επιβεβαίωσαν με σαφήνεια τη θεμελιώδη θέση της παρούσας εργασίας: ότι η διδασκόμενη συμπεριφορά αποχής υπερτερεί ουσιωδώς της ευρετικής πύλης εμπιστοσύνης, επιτυγχάνοντας δραστική μείωση της επικίνδυνης συμπεριφοράς επί σταθερής βάσης ανάκτησης και χωρίς υποβάθμιση της πιστότητας.

Η μεθοδολογία αξιολόγησης σχεδιάστηκε ώστε να απομονώνει τη συνεισφορά του παραγωγικού επιπέδου. Το σύνολο των 160 περιστατικών ταξινομήθηκε, για κάθε διαμόρφωση, ανάλογα με το αν το ορθό έγγραφο περιλαμβανόταν στα πέντε ανακτηθέντα ή όχι. Επειδή η ανάκτηση παρέμεινε πανομοιότυπη και στις τρεις διαμορφώσεις, η διάκριση αυτή ήταν σταθερή, επιτρέποντας την απόδοση κάθε διαφοράς στην απόδοση αποκλειστικά στο μοντέλο παραγωγής και μετατρέποντας μια σύγκριση ευάλωτη σε συγχύσεις σε ένα καθαρά ελεγχόμενο πείραμα.

Οι μετρικές ορίστηκαν με γνώμονα να επαληθεύονται. Η πιστότητα υπολογίστηκε αλγοριθμικά, ελέγχοντας κάθε αναγνωριστικό που επικαλείται η απάντηση έναντι ενός καταλόγου έγκυρων προθεμάτων και έναντι των πραγματικά ανακτηθέντων εγγράφων, ώστε να εντοπίζονται τα επινοημένα αναγνωριστικά. Η ομοιότητα με την πρότυπη απάντηση αποτιμήθηκε μέσω της μετρικής ROUGE-L, η οποία μετρά τη μακρύτερη κοινή υποακολουθία και είναι κατάλληλη για δομημένο κείμενο. Η ρητή διάκριση των μετρικών ανάμεσα σε περιστατικά με παρόν και απόν ορθό έγγραφο επέτρεψε την ποσοτικοποίηση της κεντρικής υπόθεσης, δηλαδή ότι η ποιότητα της ανάκτησης καθορίζει την ορθότητα της παραγωγής.

Χαρακτηριστικό της υπόθεσης αυτής είναι το εύρημα ότι η ομοιότητα των απαντήσεων με τις πρότυπες ήταν ουσιωδώς υψηλότερη στα περιστατικά όπου το ορθό έγγραφο είχε ανακτηθεί, σε σχέση με εκείνα όπου απουσίαζε. Η διαφορά αυτή ποσοτικοποιεί άμεσα τη σχέση ανάκτησης και παραγωγής: όταν το κατάλληλο έγγραφο βρίσκεται στο πλαίσιο, το μοντέλο παράγει λύση κοντινή στην πρότυπη, ενώ όταν απουσιάζει, η ποιότητα της παραγωγής υποβαθμίζεται αναπόφευκτα, ανεξαρτήτως της ικανότητας του μοντέλου. Το εύρημα αυτό υπογραμμίζει ότι η βελτίωση της ανάκτησης και η διδασκαλία της αποχής είναι συμπληρωματικές και όχι εναλλακτικές κατευθύνσεις.

Για τη στατιστική αξιολόγηση της σημαντικότητας των διαφορών χρησιμοποιήθηκε το διάστημα εμπιστοσύνης κατά Wilson (βλ. Παράρτημα Η). Η επιλογή του έναντι της απλής κανονικής προσέγγισης ήταν σκόπιμη, καθώς το διάστημα Wilson παρέχει αξιόπιστα όρια ακόμη και για μικρά δείγματα και για ποσοστά κοντά στα άκρα, όπου η κανονική προσέγγιση αποτυγχάνει. Η ανάλυση κατέδειξε ότι τα διαστήματα εμπιστοσύνης του βασικού μοντέλου (base) και του ευρετικού μηχανισμού πύλης (gate) επικαλύπτονταν, καθιστώντας τη βελτίωση του δεύτερου στατιστικά μη σημαντική, ενώ το διάστημα του εξειδικευμένου μοντέλου διαχωριζόταν σαφώς, τεκμηριώνοντας μια αναμφισβήτητη βελτίωση.

Η ερμηνεία του συμβιβασμού μεταξύ ορθής και εσφαλμένης αποχής οφείλει να λαμβάνει υπόψη την ασυμμετρία του κόστους στο πεδίο εφαρμογής. Μια εσφαλμένη αποχή (F-Abst) συνεπάγεται απλώς την ενασχόληση ενός μηχανικού με ένα περιστατικό που θα μπορούσε να είχε λυθεί αυτόματα, δηλαδή ένα κόστος χρόνου· αντιθέτως, μια επικίνδυνη συμπεριφορά συνεπάγεται την παροχή μιας εσφαλμένης λύσης που ενδέχεται να εφαρμοστεί σε ένα σύστημα παραγωγής. Η προσέγγιση της διδασκόμενης αποχής εντάσσεται στο ευρύτερο ερευνητικό ρεύμα της επιλεκτικής πρόβλεψης και της βαθμονόμησης της αβεβαιότητας, διαφοροποιούμενη ωστόσο ως προς το ότι η απόφαση αποχής δεν επιβάλλεται εκ των υστέρων μέσω ενός κατωφλίου, αλλά ενσωματώνεται στη συμπεριφορά του ίδιου του μοντέλου μέσω της εξειδίκευσης.

Η επιλογή του βάθους ανάκτησης, δηλαδή του αριθμού των εγγράφων που παρέχονται ως πλαίσιο, αποδείχθηκε καθοριστική για την ισορροπία του συστήματος. Ένας μικρός αριθμός εγγράφων αυξάνει τον κίνδυνο να μην περιληφθεί καθόλου το ορθό έγγραφο, ενώ ένας μεγάλος αριθμός εισάγει πλήθος άσχετων εγγράφων που όχι μόνο δεν βοηθούν αλλά ενθαρρύνουν το μοντέλο να παραθέτει αδιακρίτως πολλαπλές

παραπομπές, αυξάνοντας την επικίνδυνη συμπεριφορά (hazard). Η τιμή των πέντε εγγράφων προέκυψε ως το εμπειρικό σημείο ισορροπίας, προσφέροντας επαρκή κάλυψη χωρίς την υποβάθμιση που επιφέρει η υπερβολική διεύρυνση του πλαισίου.

Η σοβαρότητα του προβλήματος που η εργασία επιχειρεί να αντιμετωπίσει αποτυπώνεται στη συμπεριφορά του βασικού, μη εξειδικευμένου μοντέλου, το οποίο σχεδόν ουδέποτε απείχε από την παραγωγή απάντησης. Ακόμη και στις περιπτώσεις όπου το ορθό έγγραφο απουσίαζε πλήρως από το ανακτηθέν πλαίσιο, το βασικό μοντέλο (base) παρήγαγε με πλήρη βεβαιότητα μια δομημένη λύση στη συντριπτική πλειονότητα των περιπτώσεων. Η διαπίστωση αυτή κατέδειξε ότι η ικανότητα παραγωγής ευλογοφανούς κειμένου, χωρίς τη διδασκαλία της αποχής, συνιστά ενεργό κίνδυνο και όχι απλώς ελλιπές χαρακτηριστικό, θεμελιώνοντας την αναγκαιότητα ολόκληρης της προσπάθειας εξειδίκευσης.

5. Αυτοματοποιημένη ροή εργασίας και διεπαφή χρήστη (Στάδιο Γ)

Το τρίτο και τελικό στάδιο της ανάπτυξης απέβλεπε στη μετάβαση του συστήματος από ένα μεμονωμένο σημείο διεπαφής επίλυσης σε έναν αυτόνομο πράκτορα ενσωματωμένο σε μια πραγματική πλατφόρμα διαχείρισης περιστατικών Ενώ τα προηγούμενα στάδια είχαν εδραιώσει και αξιολογήσει την ικανότητα του συστήματος να παράγει τεκμηριωμένες λύσεις και να απέχει όταν απαιτείται , το στάδιο αυτό εξέτασε τη λειτουργεία του συστήματος υπό συνθήκες που προσομοιώνουν ένα παραγωγικό περιβάλλον τεχνικής υποστήριξης, όπου τα περιστατικά καταφθάνουν tickets και το σύστημα καλείται να το διαχειριστεί χωρίς ανθρώπινη παρέμβαση, με εξαίρεση τις περιπτώσεις, όπου η ίδια η αβεβαιότητά του υπαγορεύει την κλιμάκωση.

Ως πλατφόρμα επιλέχθηκε το Jira, το οποίο αποτελεί το πιο διαδεδομένο εργαλείο διαχείρισης περιστατικών στην βιομηχανία λογισμικού. Συγκεκριμένα, η αξιολόγηση δεν πραγματοποιήθηκε πλέον σε ένα συνθετικό σύνολο δεδομένων, αλλά σε ένα ρεύμα πραγματικών εισιτηρίων. Η διαχείριση των εισιτηρίων έγινε μέσω των επίσημων διεπαφών προγραμματισμού (REST API) της πλατφόρμας, μέσω ενός εξειδικευμένου προγράμματος-πελάτη (jira_client.py).

5.1 Ανάπτυξη Μηχανισμού Προσομοίωσης Επιχειρησιακού Φόρτου μέσω Εικονικών Χρηστών

Για την αξιολόγηση του συστήματος υπό συνθήκες που προσομοιώνουν ένα πραγματικό επιχειρησιακό περιβάλλον, αναπτύχθηκε ένας μηχανισμός προσομοίωσης φόρτου βασισμένος σε εικονικούς χρήστες (pseudo users), υλοποιημένος στο σενάριο pseudo_users_jira.py. Ο μηχανισμός αυτός αντλεί πραγματικά ερωτήματα από το σύνολο ανάπτυξης του TechQA και τα καταχωρεί ως περιστατικά (tickets) στην πλατφόρμα Jira μέσω της διεπαφής προγραμματισμού (REST API), προσομοιώνοντας την υποβολή αιτημάτων υποστήριξης από πραγματικούς τελικούς χρήστες. Με τον τρόπο αυτό, το σύστημα δεν δέχεται συνθετικές κλήσεις αλλά ένα ρεύμα αυθεντικών περιστατικών, όπως θα συνέβαινε σε μια λειτουργική υπηρεσία υποστήριξης.

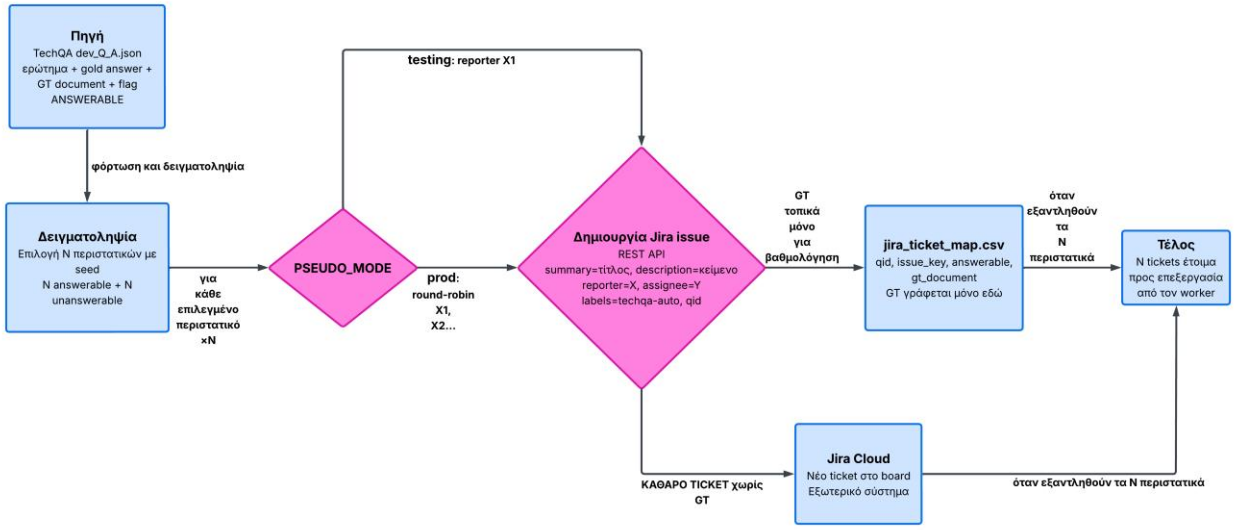
Ο μηχανισμός σχεδιάστηκε ώστε να υποστηρίζει δύο λειτουργίες:

a) ***Στη λειτουργία δοκιμής (testing)*** τα περιστατικά προέρχονται από έναν μοναδικό εικονικό χρήστη.

b) ***Στη λειτουργία παραγωγής (prod)*** τα περιστατικά κατανέμονται κυκλικά μεταξύ πολλών εικονικών χρηστών, αναπαράγοντας πιο ρεαλιστικά την πολλαπλή προέλευση των αιτημάτων σε ένα πραγματικό περιβάλλον.

Κάθε περιστατικό φέρει ένα πραγματικό ερώτημα, το οποίο μπορεί να είναι είτε επιλύσιμο (answerable), δηλαδή να αντιστοιχεί σε τεκμηριωμένη λύση εντός του συστήματος απέναντι σε περιστατικά για τα οποία δεν υφίσταται λύση.

Καθοριστική σχεδιαστική αρχή του μηχανισμού αποτέλεσε η πλήρης απομόνωση της ορθής απάντησης (ground truth) από την πλατφόρμα. Το ορθό έγγραφο κάθε ερωτήματος δεν καταχωρείται ποτέ στο Jira, αλλά διατηρείται αποκλειστικά σε τοπικό αρχείο αντιστοίχισης (jira_ticket_map.csv) και αξιοποιείται μόνο εκ των υστέρων, κατά τη βαθμολόγηση της απόδοσης. Με τον τρόπο αυτό διασφαλίζεται ότι ο αυτόνομος πράκτορας λειτουργεί ακριβώς όπως θα λειτουργούσε σε πραγματικές συνθήκες, χωρίς προνομιακή γνώση της ορθής λύσης.



Σχήμα 17 - Διάγραμμα ροής δημιουργίας ticket

Work	Assignee	Reporter	Priority	Status
~~SCRUM-384~~ Want to find out if Microsoft Edge is support...	IOANNIS MANTZAK...	Psudo User 2	Medium	Resolved
~~SCRUM-383~~ Importing Asset GL Errors	IOANNIS MANTZAK...	Psudo User 1	Medium	Resolved
~~SCRUM-382~~ Java.io.NotSerializableException in WAS	IOANNIS MANTZAK...	Psudo User 2	Medium	Resolved
~~SCRUM-381~~ How to change the maximum string length fo...	IOANNIS MANTZAK...	Psudo User 1	Medium	Resolved
~~SCRUM-380~~ Cannot open module in exclusive edit - (no s...	IOANNIS MANTZAK...	Psudo User 2	Medium	Resolved
SCRUM-379 Additional steps to apply fix pack to Decision...	IOANNIS MANTZAK...	Psudo User 1	Medium	In Progress

Εικόνα 15 - Δημιουργία ticket από πολλαπλούς reporters

Η επιλογή του συνόλου δεδομένων TechQA ως πηγής των περιστατικών δεν ήταν τυχαία. Το σύνολο αυτό αποτελείται από πραγματικά ερωτήματα τεχνικής υποστήριξης που συνοδεύονται από επίσημα τεχνικά έγγραφα (technotes) της IBM, γεγονός που το καθιστά ιδιαιτέρως αντιπροσωπευτικό ενός

πραγματικού επιχειρησιακού περιβάλλοντος υποστήριξης λογισμικού. Σε αντίθεση με συνθετικά ή γενικού σκοπού σύνολα ερωταποκρίσεων, τα ερωτήματα του TechQA χαρακτηρίζονται από την τεχνική τους πολυπλοκότητα, τη χρήση εξειδικευμένης ορολογίας και την αναφορά σε συγκεκριμένες εκδόσεις προϊόντων, στοιχεία που προσδίδουν στην προσομοίωση υψηλό βαθμό ρεαλισμού.

Κατά τη δημιουργία κάθε περιστατικού, ο μηχανισμός αντλεί από το εκάστοτε ερώτημα τον τίτλο και το πλήρες κείμενο, τα οποία αντιστοιχίζονται στα αντίστοιχα πεδία του ticket του Jira, δηλαδή στη σύνοψη και στην περιγραφή. Η αντιστοίχιση αυτή διασφαλίζει ότι το ticket που φθάνει στον αυτόνομο πράκτορα είναι ισοδύναμο με εκείνο που θα υπέβαλε ένας πραγματικός χρήστης, χωρίς καμία προεπεξεργασία ή εμπλουτισμό που θα διευκόλυνε τεχνητά το σύστημα. Με τον τρόπο αυτό, η δυσκολία που αντιμετωπίζει ο πράκτορας είναι πανομοιότυπη με εκείνη ενός μηχανικού που λαμβάνει το περιστατικό εκ του μηδενός.

Η διάκριση μεταξύ των δύο λειτουργιών, δοκιμής και παραγωγής, εξυπηρετεί διαφορετικές ανάγκες της πειραματικής διαδικασίας. Η λειτουργία δοκιμής, με έναν μοναδικό εικονικό χρήστη, είναι κατάλληλη για τη γρήγορη επαλήθευση της ορθής λειτουργίας του βρόχου, ενώ η λειτουργία παραγωγής, με την κυκλική κατανομή των περιστατικών σε πολλαπλούς εικονικούς χρήστες, αναπαράγει τη ρεαλιστική εικόνα μιας υπηρεσίας που δέχεται αιτήματα από διαφορετικές πηγές ταυτόχρονα. Η δεύτερη λειτουργία είναι επίσης απαραίτητη για την ορθή απεικόνιση του φόρτου στον πίνακα διαχείρισης, όπου κάθε αίτημα εμφανίζεται με τον υποβάλλοντα χρήστη του.

Η αρχή της απομόνωσης της ορθής απάντησης, πέραν του ρεαλισμού που προσδίδει, έχει και ουσιώδη μεθοδολογική σημασία. Αν το ορθό έγγραφο ήταν διαθέσιμο στον πράκτορα, ακόμη και έμμεσα, η αξιολόγηση θα υπέφερε από διαρροή πληροφορίας (information leakage) και τα αποτελέσματα δεν θα αντικατόπτριζαν την πραγματική ικανότητα του συστήματος υπό συνθήκες άγνοιας. Η αυστηρή διατήρηση του ορθού εγγράφου σε τοπικό αρχείο, εκτός της εμβέλειας του πράκτορα, εγγυάται ότι κάθε απόφαση αυτόματης επίλυσης ή κλιμάκωσης λαμβάνεται αποκλειστικά βάσει της πληροφορίας που θα ήταν διαθέσιμη και σε ένα πραγματικό περιβάλλον παραγωγής.

Τέλος, η συνειδητή ανάμειξη επιλύσιμων και μη επιλύσιμων περιστατικών στο ρεύμα των αιτημάτων επιδιώκει να αναπαραγάγει την πραγματικότητα μιας υπηρεσίας υποστήριξης, όπου ένα μέρος των εισερχόμενων αιτημάτων δεν έχει τεκμηριωμένη λύση στη διαθέσιμη γνωσιακή βάση. Η παρουσία των μη επιλύσιμων περιστατικών είναι κρίσιμη, διότι μόνο μέσω αυτών μπορεί να αξιολογηθεί ουσιαστικά η συμπεριφορά αποχής του συστήματος· ένα ρεύμα αποκλειστικά επιλύσιμων περιστατικών θα απέκρυπτε το πλέον κρίσιμο ποιοτικό χαρακτηριστικό του, δηλαδή την ικανότητά του να αναγνωρίζει τα όρια της γνώσης του.

Για την διασφάλιση της αναπαραγωγιμότητας, η επιλογή των ερωτημάτων από το σύνολο ανάπτυξης βασίστηκε σε καθορισμένο σπόρο τυχαιότητας (seed), ώστε η ίδια σύνθεση περιστατικών να μπορεί να ανακατασκευαστεί σε επόμενες εκτελέσεις. Η δυνατότητα αυτή είναι σημαντική για την επιστημονική

εγκυρότητα, καθώς επιτρέπει τόσο την επαλήθευση των αποτελεσμάτων όσο και τη σύγκριση διαφορετικών διαμορφώσεων επί ακριβώς του ίδιου συνόλου εισερχόμενων περιστατικών, απομονώνοντας την επίδραση των μεταβολών του συστήματος από εκείνη της τυχαίας επιλογής των δεδομένων.

5.2 Ενοποίηση με Πλατφόρμες Διαχείρισης Έργου (Jira Service Desk Integration) και Αυτοματοποιημένες Ροές

Η ενοποίηση με το Jira υλοποιήθηκε μέσω ενός αυτόνομου πράκτορα επεξεργασίας (worker, jira_worker.py), ο οποίος ενσωματώθηκε ως μόνιμη υπηρεσία στην ίδια διάταξη μικροϋπηρεσιών (Docker Compose) με το υπόλοιπο σύστημα, διατηρώντας την αρχή του αυτοτελούς περιβάλλοντος. Ο πράκτορας ανιχνεύει περιοδικά (pooling) τα νέα περιστατικά μέσω ερωτημάτων JQL, ανακτά την περιγραφή κάθε περιστατικού, καλεί το σημείο διεπαφής /resolve και εφαρμόζει την απόφαση του γράφοντας πίσω στο ticket. Η προσέγγιση της περιοδικής ανίχνευσης προτιμήθηκε έναντι των δικτυακών κλήσεων επανάκλησης (webhooks), καθώς οι τελευταίες θα απαιτούσαν τη δημόσια έκθεση ενός σημείου διεπαφής στο διαδίκτυο, κάτι που αντέβαινε στην τοπική και αυτοτελή φύση της ανάπτυξης.

Θεμελιώδης σχεδιαστική αρχή αποτέλεσε η παραδοχή ότι, σε ένα πραγματικό περιβάλλον, το σύστημα δεν έχει πρόσβαση στην ορθή απάντηση τη στιγμή της επεξεργασίας και, επομένως, δεν μπορεί να γνωρίζει αν μια παραγόμενη λύση είναι εσφαλμένη. Ως εκ τούτου, η πολιτική κλιμάκωσης διατυπώθηκε αποκλειστικά επί ενδείξεων επαληθεύσιμων κατά τον χρόνο εκτέλεσης: ένα περιστατικό κλιμακώνεται σε ανθρώπινο μηχανικό εφόσον το μοντέλο δηλώνει το ίδιο αποχή (η διδασκόμενη συμπεριφορά MODE B), ή εφόσον η εμπιστοσύνη ανάκτησης υπολείπεται του κατωφλίου του μηχανισμού πύλης, ή εφόσον η απάντηση δεν παραπέμπει σε κανένα έγκυρο τεχνικό έγγραφο ή επικαλείται αναγνωριστικό που δεν περιλαμβάνεται στα ανακτηθέντα (έλεγχος πιστότητας). Ο τελευταίος έλεγχος συνιστά πρόσθετη δικλείδα ασφαλείας, εντοπίζοντας φαινομενικά τεκμηριωμένες αλλά μη στηριζόμενες απαντήσεις.

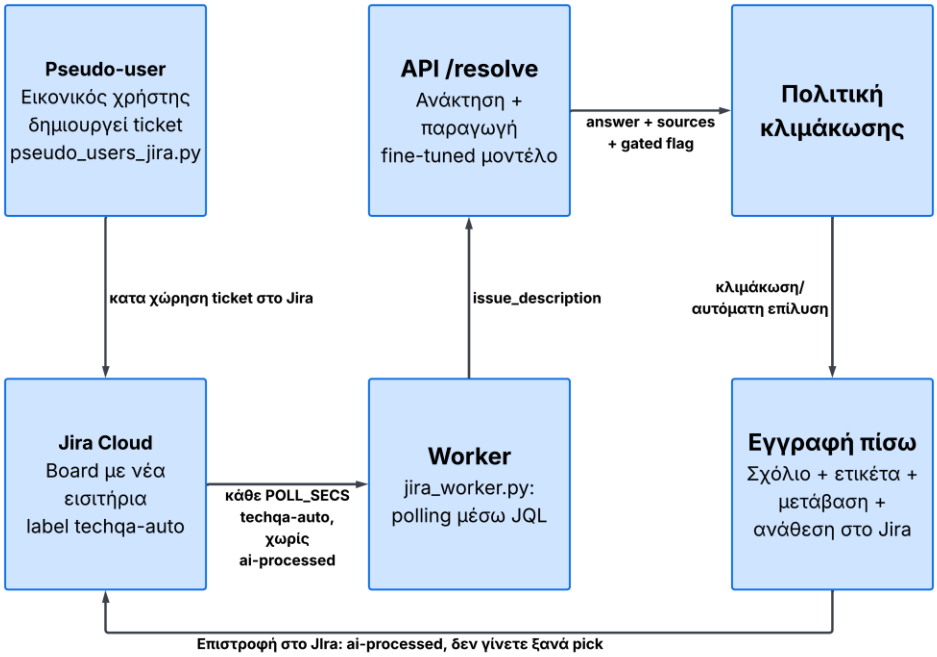
Κατά την εγγραφή των αποτελεσμάτων, εφαρμόστηκε διαχωρισμός της πληροφορίας ανάλογα με τον αποδέκτη της. Κάθε περιστατικό λαμβάνει δύο διακριτά σχόλια:

a) ένα δημόσιο, ορατό στον χρήστη, με είτε την καθαρή δομημένη λύση είτε μια συνοπτική ειδοποίηση ανάθεσης σε μηχανικό.
b) ένα εσωτερικό, με περιορισμένη ορατότητα στον ρόλο του μηχανικού, το οποίο περιέχει το πλήρες σύνολο των διαγνωστικών.

Ο περιορισμός υλοποιήθηκε μέσω του μηχανισμού ρόλων της πλατφόρμας, αναθέτοντας τους εικονικούς χρήστες στον ρόλο απλού μέλους και τον μηχανικό στον ρόλο διαχειριστή· έτσι, ο διαχωρισμός δεν αποτελεί σύμβαση αλλά επιβάλλεται από την ίδια την πλατφόρμα. Παράλληλα, κάθε περιστατικό ανατίθεται στον μηχανικό υποστήριξης, ενώ η διάκριση μεταξύ αυτόματα επιλυμένων και κλιμακωμένων

περιστατικών αποτυπώνεται μέσω ετικετών, επιτρέποντας το φιλτράρισμα όσων απαιτούν ανθρώπινη προσοχή.

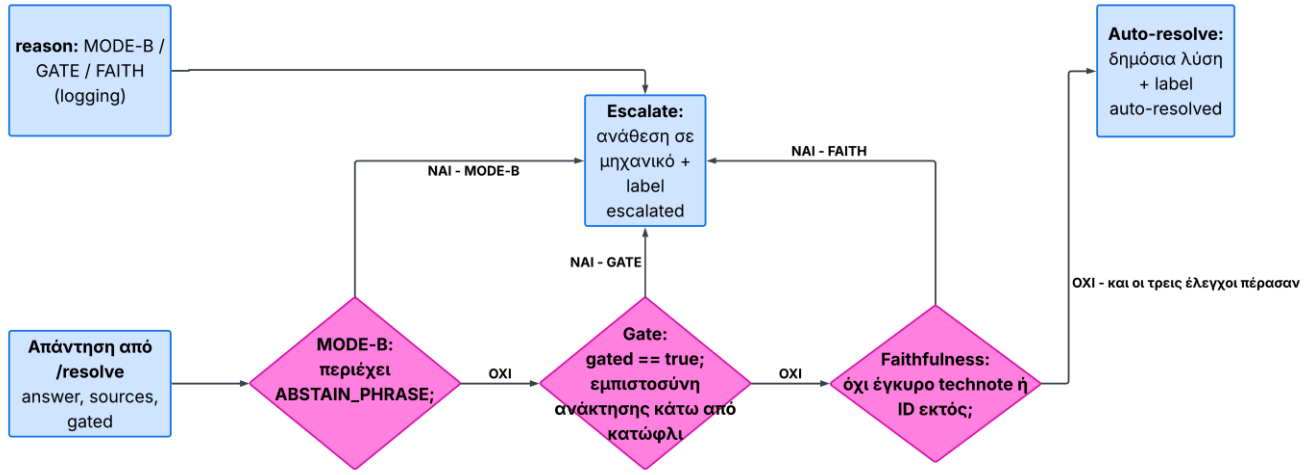
Η υλοποίηση του μηχανισμού ανίχνευσης βασίστηκε σε ερωτήματα στη γλώσσα αναζήτησης του Jira (JQL), τα οποία επιλέγουν τα περιστατικά που φέρουν τη χαρακτηριστική ετικέτα των αυτόματα δημιουργημένων εισιτηρίων και δεν έχουν ακόμη επεξεργαστεί. Η χρήση ετικετών ως δείκτη της κατάστασης επεξεργασίας εξασφαλίζει την αδιαλειψία (idempotency) του βρόχου [8,11], δηλαδή, ένα περιστατικό που έχει ήδη επεξεργαστεί λαμβάνει μια ετικέτα ολοκλήρωσης και αποκλείεται από τα επόμενα ερωτήματα, αποτρέποντας τη διπλή επεξεργασία ακόμη και αν ο πράκτορας κάνει επανεκκίνηση. Ο σχεδιασμός αυτός καθιστά τον βρόχο ανθεκτικό σε διακοπές και επανεκκινήσεις, χαρακτηριστικό απαραίτητο για μια μόνιμη υπηρεσία παρασκηνίου.



Σχήμα 18 - Αυτόνομος βρόχος

Η επικοινωνία με την πλατφόρμα πραγματοποιήθηκε αποκλειστικά μέσω της επίσημης διεπαφής προγραμματισμού (REST API), χωρίς εξωτερικές βιβλιοθήκες, γεγονός που περιόρισε τις εξαρτήσεις του συστήματος. Η σύγχρονη έκδοση της διεπαφής απαιτεί τη διατύπωση του περιεχομένου των σχολίων και των περιγραφών σε μια δομημένη μορφή εγγράφου (Atlassian Document Format), αντί απλού κειμένου, ενώ η αναζήτηση των περιστατικών γίνεται μέσω ενός ειδικού σημείου διεπαφής με σελιδοποίηση των αποτελεσμάτων. Η ορθή διαχείριση αυτών των τεχνικών ιδιαιτεροτήτων ήταν απαραίτητη για την αξιόπιστη λειτουργία της ενοποίησης.

Ο έλεγχος πιστότητας, ο τρίτος από τους μηχανισμούς κλιμάκωσης, αξίζει ιδιαίτερης αναφοράς ως προς την υλοποίησή του. Ο πράκτορας (AI-Agent), μέσω ειδικής συνάρτησης (cited_ids()) (βλ. Παράρτημα Θ), εξάγει από την παραγόμενη απάντηση το σύνολο των αναγνωριστικών που αυτή επικαλείται και τα αντιπαραβάλλει με τα αναγνωριστικά των εγγράφων που πράγματι ανακτήθηκαν. Εάν η απάντηση δεν επικαλείται κανένα έγκυρο αναγνωριστικό, ή εάν επικαλείται αναγνωριστικό που δεν περιλαμβάνεται στα ανακτηθέντα, το περιστατικό κλιμακώνεται. Ο έλεγχος αυτός πραγματοποιείται αμιγώς κατά τον χρόνο εκτέλεσης, χωρίς καμία γνώση της ορθής απάντησης, και αποτελεί μια αντικειμενική δικλείδα κατά της παραγωγής μη στηριζόμενων λύσεων.



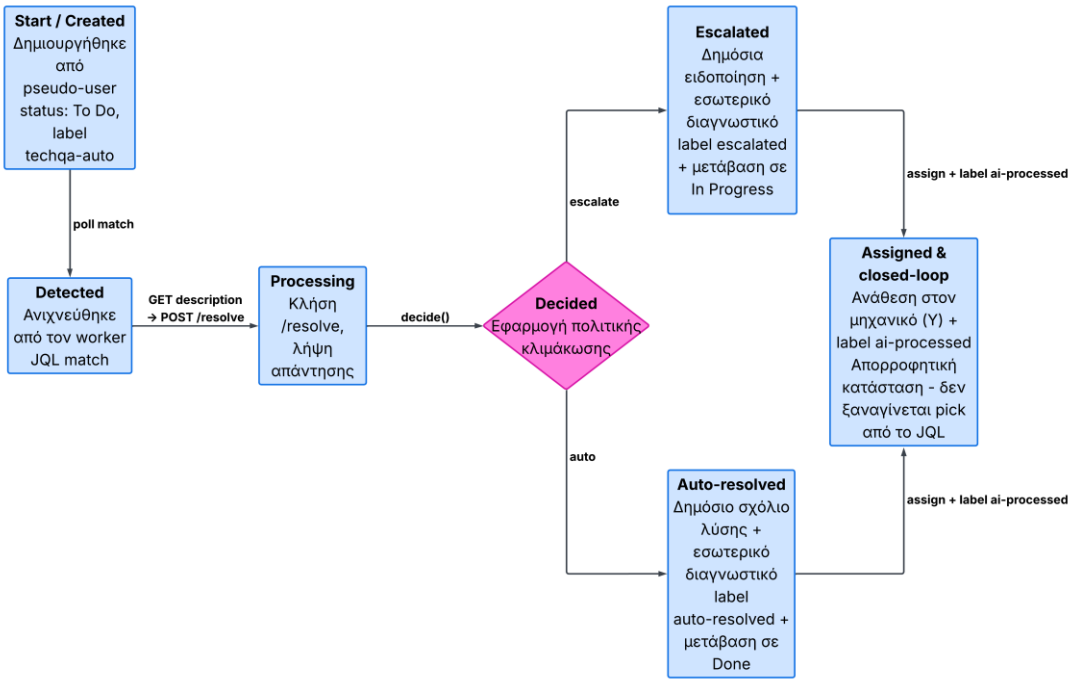
Σχήμα 19 - Διάγραμμα πολιτικής κλιμάκωσης

Ο διαχωρισμός της ορατότητας των σχολίων στηρίχθηκε σε μια σημαντική διάκριση μεταξύ των τύπων έργων της πλατφόρμας. Ενώ τα εξειδικευμένα έργα εξυπηρέτησης πελατών διαθέτουν εγγενή διάκριση μεταξύ εσωτερικών και δημόσιων σχολίων, στα κοινά έργα διαχείρισης η ίδια λειτουργικότητα επιτυγχάνεται μέσω του περιορισμού της ορατότητας ενός σχολίου σε συγκεκριμένο ρόλο του έργου. Η υλοποίηση ανέθεσε τους εικονικούς χρήστες στον ρόλο του απλού μέλους και τον μηχανικό στον ρόλο του διαχειριστή, ώστε το σχόλιο με τα διαγνωστικά να είναι τεχνικά αδύνατο να προβληθεί από τον τελικό χρήστη.

Το σύνολο των ενεργειών που εκτελεί ο πράκτορας για κάθε περιστατικό συγκροτεί μια πλήρη μηχανή καταστάσεων (state machine): το ticket δημιουργείται, ανιχνεύεται, επεξεργάζεται, λαμβάνει δημόσιο και εσωτερικό σχόλιο, ανατίθεται στον μηχανικό, επισημαίνεται με την κατάλληλη ετικέτα κατάστασης και μεταβαίνει στην αντίστοιχη φάση της ροής εργασίας. Επειδή τα ονόματα των μεταβάσεων ενδέχεται να διαφέρουν ανά έργο, ο πράκτορας σχεδιάστηκε ώστε να τα ανιχνεύει δυναμικά και να προσαρμόζεται, εξασφαλίζοντας τη φορητότητα της υλοποίησης σε διαφορετικές διαμορφώσεις της πλατφόρμας.

Ως μόνιμη υπηρεσία παρασκηνίου, ο πράκτορας λειτουργεί συνεχώς, ανιχνεύοντας νέα περιστατικά σε τακτά χρονικά διαστήματα χωρίς ανθρώπινη εποπτεία. Ο τρόπος αυτός λειτουργίας αναπαράγει πιστά τη

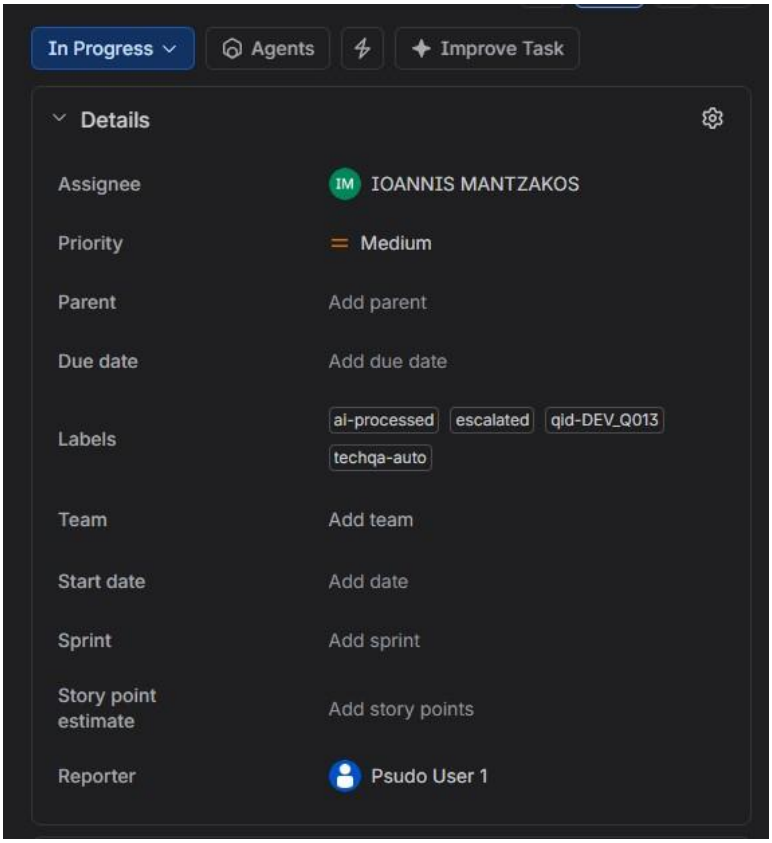
λογική ενός αυτοματοποιημένου συστήματος υποστήριξης πρώτης γραμμής, το οποίο επεξεργάζεται τα εισερχόμενα αιτήματα καθώς αυτά καταφθάνουν. Η ενσωμάτωσή του στην ίδια διάταξη μικροϋπηρεσιών με το υπόλοιπο σύστημα επιτρέπει την εκκίνησή του ταυτόχρονα με τις υπόλοιπες υπηρεσίες, καθιστώντας ολόκληρο τον αυτόνομο βρόχο διαθέσιμο με μια ενιαία εντολή.



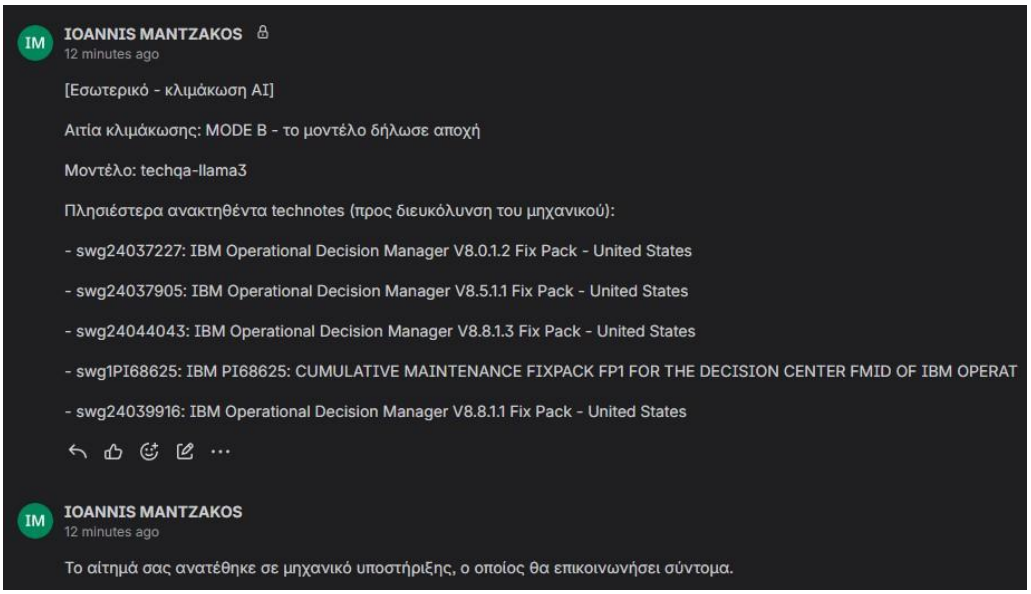
Σχήμα 20 - Μηχανή καταστάσεων (κύκλος ζωής ticket)

Το δημόσιο σχόλιο σχεδιάστηκε με ιδιαίτερη προσοχή ως προς το περιεχόμενο που φθάνει στον τελικό χρήστη. Στην περίπτωση της αυτόματης επίλυσης, ο χρήστης λαμβάνει αποκλειστικά την καθαρή, δομημένη λύση, χωρίς καμία αναφορά στον εσωτερικό συλλογισμό του συστήματος, στα ανακτηθέντα έγγραφα ή στο μοντέλο που τη συνέθεσε. Στην περίπτωση της κλιμάκωσης, ο χρήστης λαμβάνει μια συνοπτική και ουδέτερη ειδοποίηση ανάθεσης σε μηχανικό, χωρίς καμία ένδειξη ότι το σύστημα απέτυχε να παραγάγει λύση. Ο σχεδιασμός αυτός διαφυλάσσει την εμπειρία του χρήστη και την επαγγελματική εικόνα της υπηρεσίας.

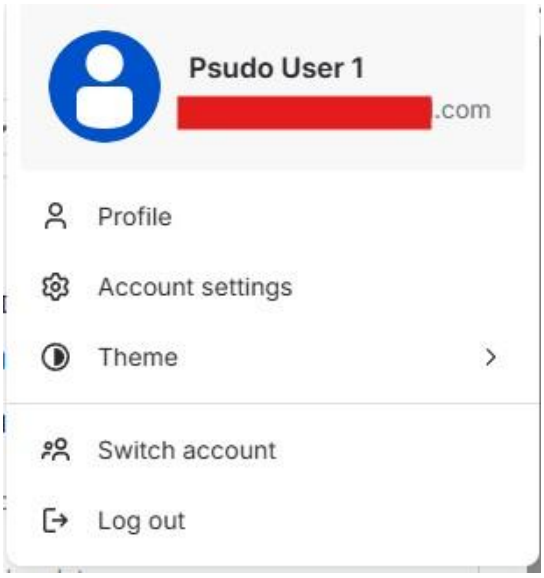
Η μοντελοποίηση των ρόλων ολοκληρώνεται με τη διάκριση μεταξύ του υποβάλλοντος χρήστη και του μηχανικού επίλυσης. Κάθε περιστατικό φέρει ως υποβάλλοντα έναν εικονικό χρήστη και ανατίθεται στον μηχανικό υποστήριξης, αναπαράγοντας τη βασική δομή ρόλων μιας πραγματικής υπηρεσίας. Η ανάθεση κάθε περιστατικού στον μηχανικό, ανεξαρτήτως του αν επιλύθηκε αυτόματα ή κλιμακώθηκε, εξυπηρετεί την ενιαία εποπτεία της ροής εργασίας μέσω του πίνακα διαχείρισης, όπου η διάκριση των περιπτώσεων που απαιτούν ενέργεια γίνεται με βάση τις ετικέτες κατάστασης και όχι τον υπεύθυνο.



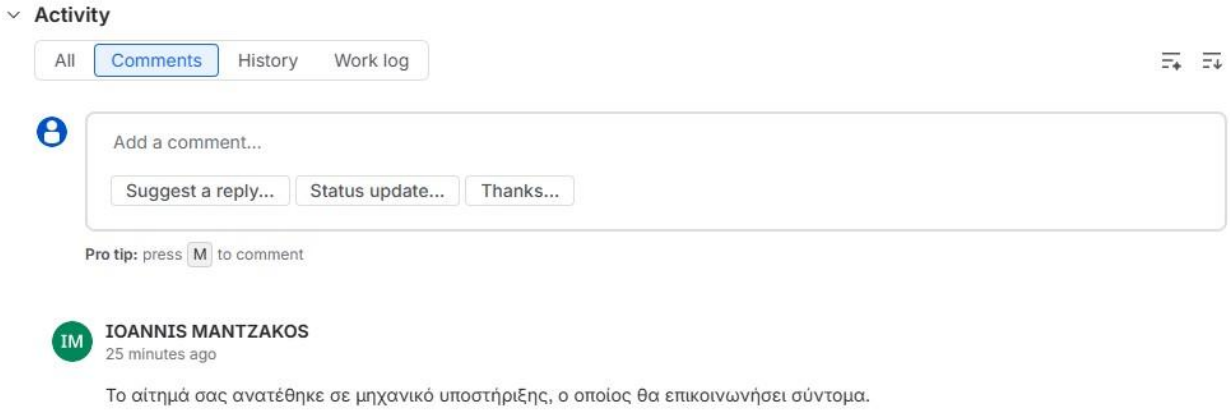
Εικόνα 16 - Κατάσταση και Λεπτομέρειες ticket



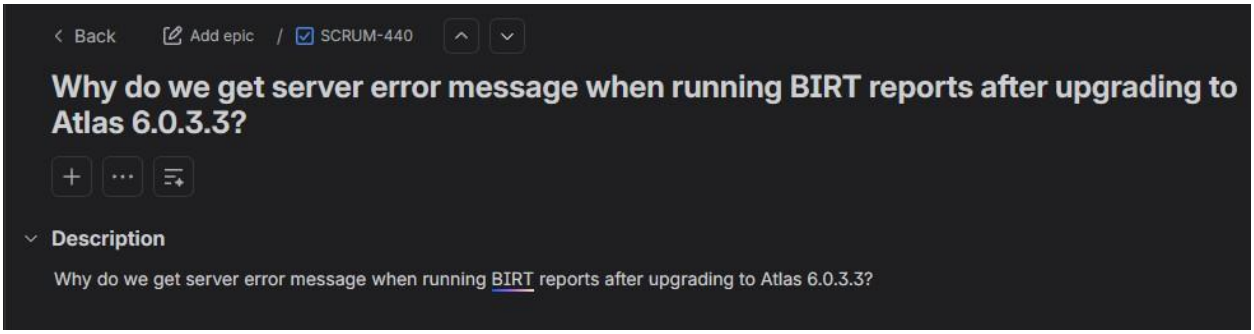
Εικόνα 17 – «Σκέψη» και Κλιμάκωση από τον AI Agent / Εσωτερικό σχόλιο



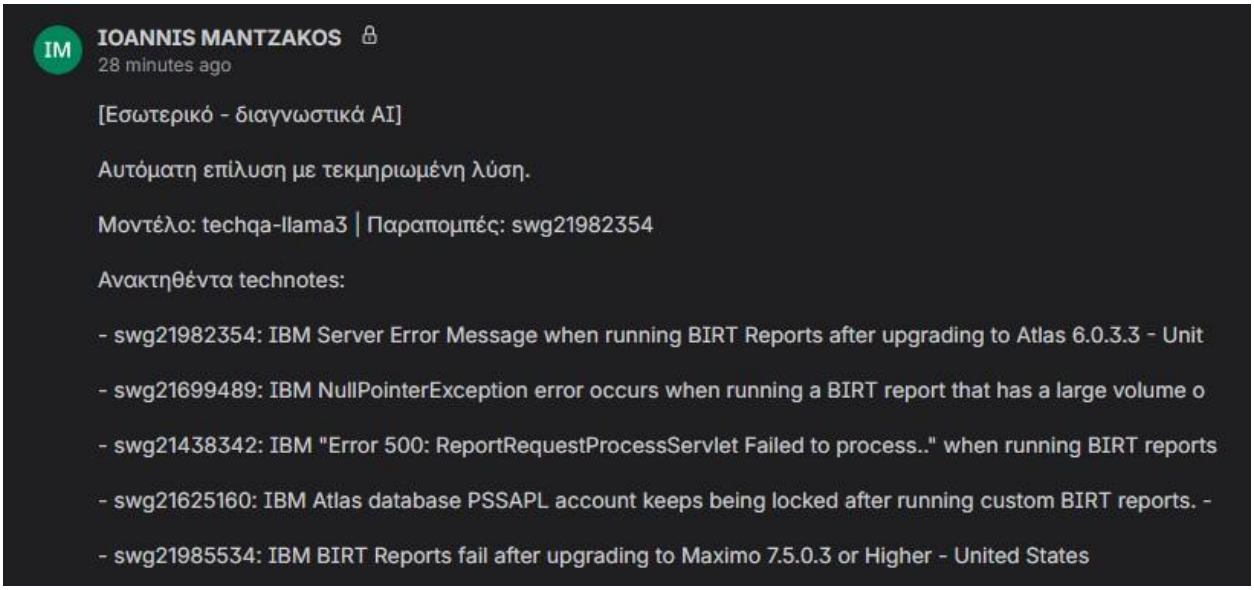
Εικόνα 18 - Σύνδεση με λογαριασμό pseudo user



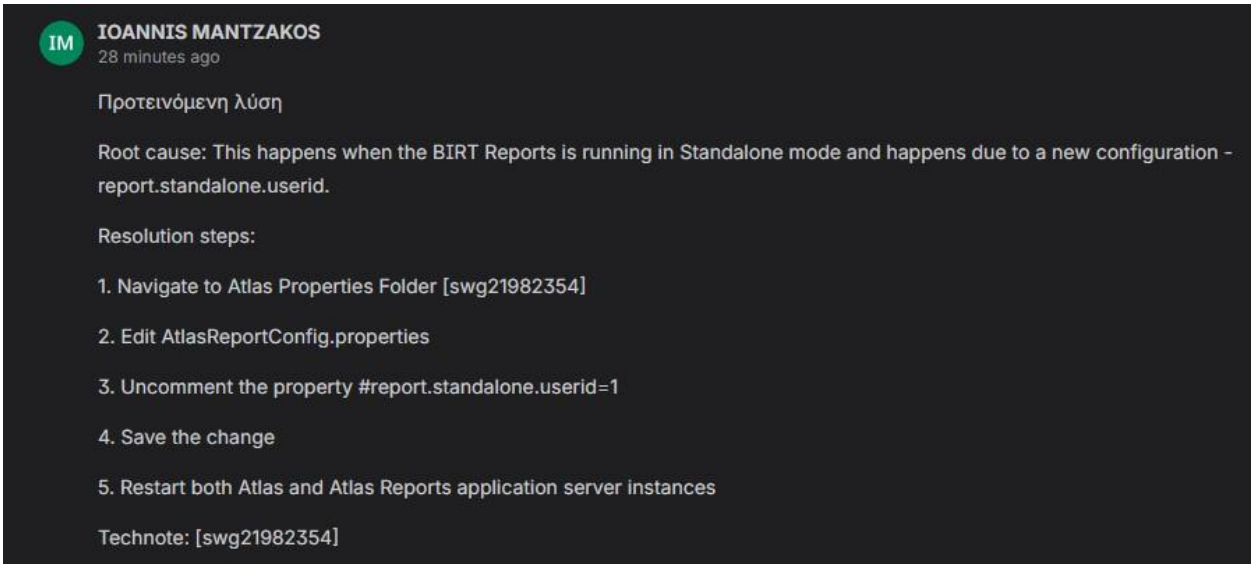
Εικόνα 19 - Απάντηση κλιμάκωσης προς pseudo user



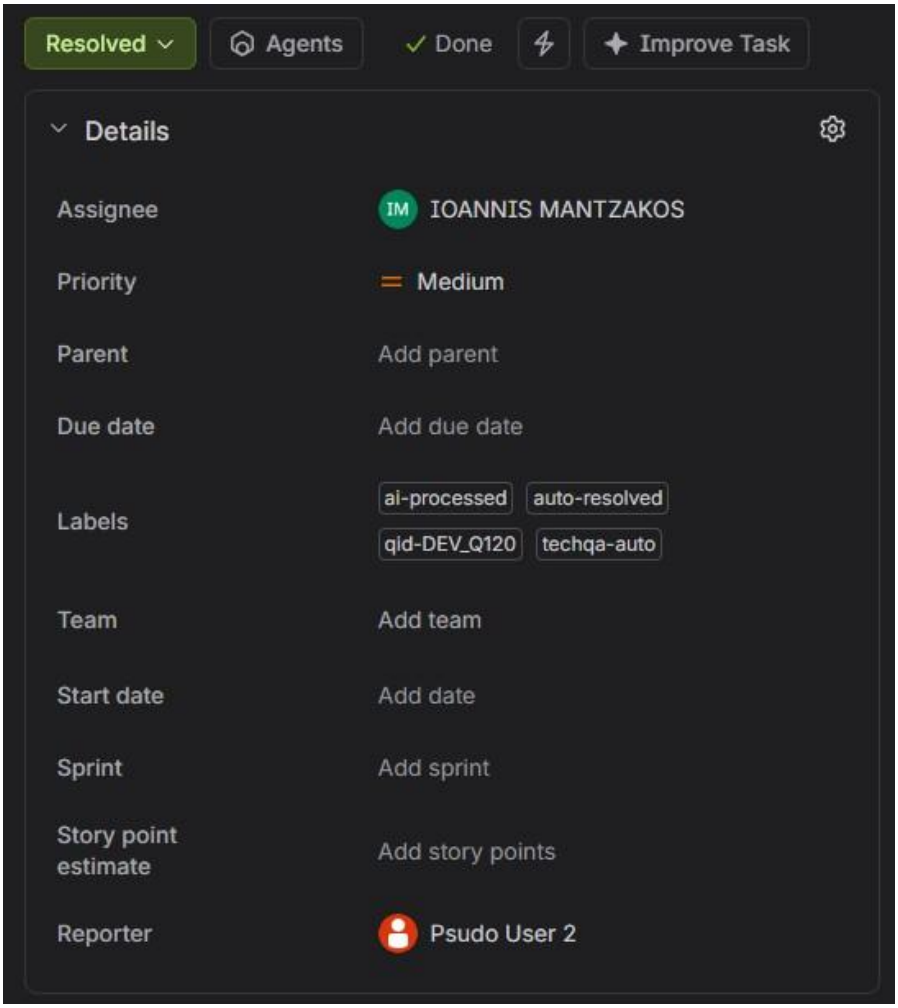
Εικόνα 20 - Στιγμιότυπο τίτλου και περιγραφής Ticket



Εικόνα 21 - "Σκέψη" AI Agent / Εσωτερικό σχόλιο



Εικόνα 22 - Απάντηση του AI-Agent προς τον χρήστη



Εικόνα 23 - Auto Resolve του ticket

5.3 Αποτελέσματα και Αξιολόγηση Λειτουργικότητας για το Στάδιο Γ

Η αξιολόγηση της λειτουργικότητας του βρόχου διεξήχθη επί συνόλου 200 περιστατικών, εκ των οποίων τα 160 αντλήθηκαν από επιλύσιμα ερωτήματα και τα 40 από μη επιλύσιμα, ώστε το δείγμα να είναι άμεσα συγκρίσιμο με την αξιολόγηση του Σταδίου Β. Το σύστημα λειτούργησε καθ' όλη τη διάρκεια με το εξειδικευμένο μέσω QLoRA μοντέλο. Από τα 200 περιστατικά, το 62,0% επιλύθηκε αυτόματα και το 38,0% κλιμακώθηκε σε ανθρώπινο μηχανικό.

Η διαπίστωση προκύπτει από τη χαρτογράφηση των αποτελεσμάτων στο πλαίσιο των μετρικών του Σταδίου Β. Ταξινομώντας κάθε περιστατικό ανάλογα με το αν το ορθό έγγραφο ανακτήθηκε (GT – Present) ή όχι (GT - Missing), η ορθή αποχή ανήλθε στο 50,0%, το hazard στο 50,0% και η εσφαλμένη κλιμάκωση στο 26,9%. Τα ποσοστά αυτά συμπίπτουν σχεδόν απόλυτα με τις τιμές που είχαν μετρηθεί στο ελεγχόμενο περιβάλλον του Σταδίου Β, επικυρώνοντας ότι η συμπεριφορά του συστήματος στο παραγωγικό περιβάλλον ταυτίζεται με εκείνη που τεκμηριώθηκε στο ελεγχόμενο πείραμα.

Ιδιαίτερη σημασία έχει η ανάλυση ανά τύπο περιστατικού. Το σύστημα κλιμάκωσε το 33,8% των επιλύσιμων έναντι του 55,0% των μη επιλύσιμων περιστατικών, κλιμακώνοντας δηλαδή σε σαφώς υψηλότερο ποσοστό τα εγγενώς άλυτα, γεγονός που καταδεικνύει ότι η συμπεριφορά αποχής συσχετίζεται ορθά με τη δυσκολία του περιστατικού και δεν είναι τυχαία. Ως προς την ποιότητα των αυτόματων επιλύσεων, το 60,6% των αυτόματα επιλυμένων περιστατικών με ανακτημένο το ορθό έγγραφο παρέπεμψε πράγματι στο σωστό τεχνικό έγγραφο. Τέλος, ως προς τις αιτίες κλιμάκωσης, η συντριπτική πλειονότητα (97,4%) οφειλόταν στη διδασκόμενη αποχή, ενώ ο έλεγχος πιστότητας ενεργοποιήθηκε στο υπόλοιπο 2,6%, εντοπίζοντας περιπτώσεις που η αποχή δεν είχε καλύψει.

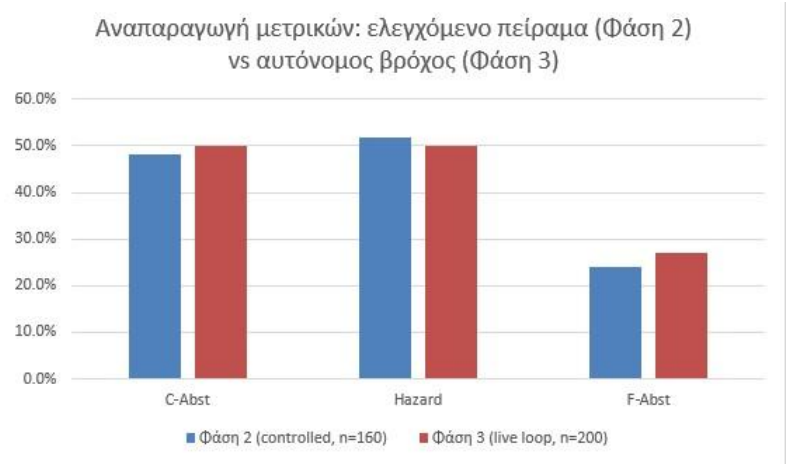
Μετρική	Τιμή
Συνολική Έκβαση	
Αυτόματη Επίλυση	62.0% (124/200)
Κλιμάκωση	38.0% (76/200)
Χαρτογράφηση	
Ορθή Αποχή (C-Abst)	50.0% (48/96)
Hazard	50.0% (48/96)
Εσφαλμένη Κλιμάκωση	26.9% (28/104)
Ορθή auto	60.6% (63/104)
Αιτίες Κλιμάκωσης	
MODE-B (διδασκόμενη αποχή)	97.4% (74/76)
FAITH (έλεγχος πιστότητας)	2.6% (2/76)
Ανά τύπο περιστατικού	
Answerable Κλιμάκωση	33.8% (54/160)
Unanswerable Κλιμάκωση	55.0% (22/40)

Πίνακας 2 - Πίνακας αποτελεσμάτων n=200

Η βαθμολόγηση των αποτελεσμάτων πραγματοποιήθηκε, μέσω ειδικού σεναρίου (jira_report.py), μέσω της συνένωσης δύο τοπικών αρχείων: του αρχείου αντιστοίχισης που παρήγαγαν οι εικονικοί χρήστες, το οποίο περιέχει το ορθό έγγραφο κάθε περιστατικού, και του αρχείου καταγραφής του πράκτορα (jira_worker_log.csv), το οποίο περιέχει την απόφαση, τις παραπομπές και τα ανακτηθέντα έγγραφα για κάθε ticket. Η σύνδεση των δύο αρχείων μέσω του αναγνωριστικού του εισιτηρίου επέτρεψε την ανακατασκευή της πλήρους εικόνας κάθε περιστατικού και την ταξινόμησή του σύμφωνα με τις μετρικές του Σταδίου Β, χωρίς το ορθό έγγραφο να έχει επηρεάσει σε καμία στιγμή τη λειτουργία του πράκτορα.

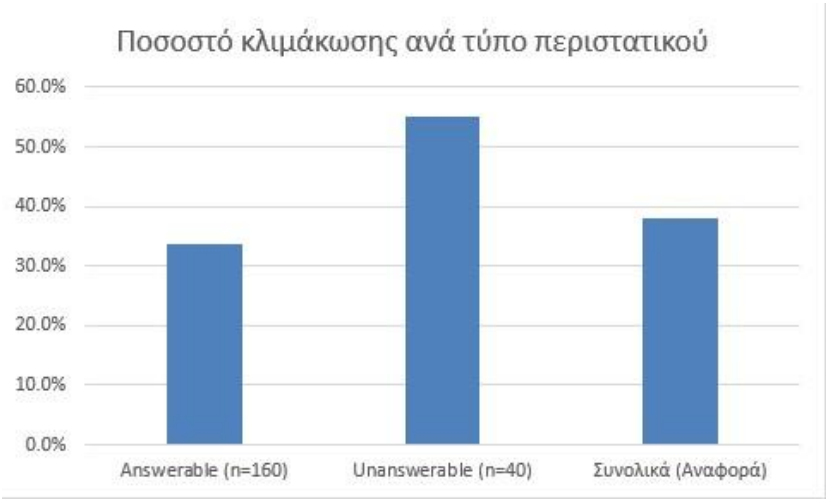
Η σχεδόν απόλυτη σύμπτωση των ποσοστών του βρόχου με εκείνα του ελεγχόμενου πειράματος του Σταδίου Β έχει βαρύνουσα σημασία και χρήζει ερμηνείας. Το γεγονός ότι η ορθή αποχή και το hazard

προσγειώθηκαν αμφότερα στο 50%, εντός του τεκμηριωμένου εύρους της Φάσης Β, καταδεικνύει ότι η μετάβαση από ένα απομονωμένο περιβάλλον αξιολόγησης σε ένα πλήρες, διασυνδεδεμένο σύστημα παραγωγής δεν επέφερε καμία υποβάθμιση της συμπεριφοράς. Πρόκειται για μια μη τετριμμένη διαπίστωση, καθώς η ενσωμάτωση πολλαπλών συνιστωσών εισάγει συχνά απρόβλεπτες αλληλεπιδράσεις που αλλοιώνουν την απόδοση· η απουσία τέτοιας αλλοίωσης πιστοποιεί τη σταθερότητα του σχεδιασμού.



Σχήμα 21 - Αναπαραγωγή μετρικών: ελεγχόμενο πείραμα (Φάση 2) εναντίων αυτόνομος βρόχος (Φάση 3)

Η ανάλυση ανά τύπο περιστατικού προσφέρει μια επιπλέον, λεπτομερέστερη επιβεβαίωση της ορθής λειτουργίας. Το γεγονός ότι το σύστημα κλιμάκωσε το 55,0% των μη επιλύσιμων περιστατικών έναντι μόλις του 33,8% των επιλύσιμων δείχνει ότι η συμπεριφορά αποχής δεν είναι ούτε τυχαία ούτε ομοιόμορφη, αλλά συσχετίζεται ουσιαστικά με την πραγματική δυσκολία του περιστατικού. Το σύστημα, δηλαδή, εκδηλώνει μια μορφή διακριτικής ικανότητας, αναγνωρίζοντας εμμέσως ότι τα εγγενώς άλυτα περιστατικά είναι πιθανότερο να απαιτούν ανθρώπινη παρέμβαση, παρότι ουδέποτε του γνωστοποιήθηκε ρητά ποια περιστατικά ανήκουν σε ποια κατηγορία.



Σχήμα 22 - Ποσοστό κλιμάκωσης ανά τύπο περιστατικού

Το εναπομείναν ποσοστό hazard, αν και υποδιπλάσιο εκείνου του βασικού μοντέλου, παραμένει το κύριο όριο του συστήματος και αξίζει συγκεκριμένης ανάλυσης. Χαρακτηριστική είναι η περίπτωση ενός μη επιλύσιμου περιστατικού για το οποίο το σύστημα παρήγαγε μια πλήρως δομημένη λύση, με αναλυτικά βήματα και παραπομπή σε ένα τεχνικό έγγραφο που είχε μεν ανακτηθεί αλλά αφορούσε διαφορετικό ζήτημα. Η απάντηση αυτή πέρασε τον έλεγχο πιστότητας, καθώς το επικαλούμενο αναγνωριστικό υπήρχε πράγματι στα ανακτηθέντα έγγραφα, παρότι το περιεχόμενό της ήταν ουσιαστικά εσφαλμένο. Το παράδειγμα αυτό αποτυπώνει με σαφήνεια το όριο του ελέγχου πιστότητας, ο οποίος επαληθεύει την προέλευση μιας παραπομπής αλλά όχι τη σημασιολογική της καταλληλόλητάς.

Ο ρόλος του ελέγχου πιστότητας, παρά τη μικρή του συνεισφορά στο σύνολο των κλιμακώσεων, δεν πρέπει να υποτιμηθεί. Το γεγονός ότι το 2,6% των κλιμακώσεων οφειλόταν αποκλειστικά σε αυτόν σημαίνει ότι ένα μικρό αλλά υπαρκτό ποσοστό επικίνδυνων απαντήσεων εντοπίστηκε και αποτράπηκε από έναν μηχανισμό ανεξάρτητο της διδασκόμενης αποχής. Σε ένα σύστημα όπου κάθε αποτραπείσα εσφαλμένη λύση έχει σημασία, η προσθετική αυτή κάλυψη δικαιολογεί πλήρως την ύπαρξη του ελέγχου, ο οποίος λειτουργεί ως δεύτερη, ανεξάρτητη γραμμή άμυνας πέραν της κρίσης του ίδιου του μοντέλου.

Αιτία	Ποσοστό	Πλήθος
MODE-B (διδασκόμενη αποχή)	97.4%	74
FAITH (έλεγχος Πιστότητας)	2.6%	2

Πίνακας 3 - Πίνακας Αιτιών Κλιμάκωσης

Τέλος, οφείλει να σημειωθεί ότι η επαναληψιμότητα του βρόχου υπόκειται στην ίδια μη ντετερμινιστική συμπεριφορά που παρατηρήθηκε και στο Στάδιο Β. Επαναλαμβανόμενες εκτελέσεις της ίδιας διαμόρφωσης αποδίδουν ελαφρώς διαφορετικά ποσοστά, εντός ενός στενού εύρους, γεγονός που οφείλεται στη μη ντετερμινιστική φύση της παραγωγής των γλωσσικών μοντέλων ακόμη και υπό μηδενική θερμοκρασία. Η διαπίστωση αυτή, μολονότι δεν αναιρεί τη σαφήνεια των συμπερασμάτων, υπαγορεύει τη συνετή ερμηνεία των αποτελεσμάτων ως ποσοστών εντός ενός αναμενόμενου εύρους και όχι ως απολύτως ακριβών τιμών.

Σε επίπεδο συνολικής λειτουργικής απόδοσης, το γεγονός ότι το 62,0% των περιστατικών επιλύθηκε αυτόματα και μόλις το 38,0% απαίτησε ανθρώπινη παρέμβαση αποτυπώνει την πρακτική αξία του συστήματος. Σε ένα πραγματικό περιβάλλον, μια τέτοια αναλογία θα σήμαινε ότι σχεδόν τα δύο τρίτα του φόρτου εργασίας διεκπεραιώνονται χωρίς ανθρώπινη εμπλοκή, απελευθερώνοντας τους μηχανικούς ώστε να επικεντρωθούν στα πραγματικά δύσκολα ή αβέβαια περιστατικά. Η αξία αυτή, ωστόσο, τελεί υπό την προϋπόθεση της ασφαλούς διαχείρισης του εναπομείναντος κινδύνου.

Ως προς την ποιότητα των απαντήσεων που φθάνουν στον χρήστη, το γεγονός ότι το 60,6% των αυτόματα επιλυμένων περιστατικών με ανακτημένο το ορθό έγγραφο παρέπεμψε στο σωστό τεχνικό έγγραφο συνιστά μια ουσιαστική ένδειξη ορθότητας. Το υπόλοιπο ποσοστό αντιστοιχεί σε περιπτώσεις

όπου, αν και το ορθό έγγραφο ήταν διαθέσιμο, το μοντέλο στήριξε την απάντησή του σε διαφορετική πηγή, γεγονός που δεν συνεπάγεται κατ' ανάγκη εσφαλμένη λύση αλλά υποδηλώνει περιθώριο βελτίωσης στην ακρίβεια της τεκμηρίωσης. Η μετρική αυτή προσφέρει έναν αντικειμενικό δείκτη της αξιοπιστίας των αυτόματων επιλύσεων, πέραν της απλής καταμέτρησής τους.

Συνολικά, η αξιολόγηση της λειτουργικότητας του Σταδίου Γ πιστοποιεί ότι ο αυτόνομος βρόχος δεν αποτελεί απλώς μια τεχνική επίδειξη ενοποίησης, αλλά ένα λειτουργικό σύστημα του οποίου η συμπεριφορά είναι μετρήσιμη, ερμηνεύσιμη και συνεπής με τα ευρήματα των προηγούμενων σταδίων. Η διατήρηση των ποιοτικών χαρακτηριστικών του συστήματος κατά τη μετάβαση από το ελεγχόμενο περιβάλλον αξιολόγησης σε ρεαλιστικές συνθήκες λειτουργίας αποτελεί το κύριο επίτευγμα του σταδίου αυτού.

6. Συνολική προσομοίωση και συμπεράσματα

6.1 End-to-End Προσομοίωση σε Περιβάλλον Παραγωγής

Η ολοκληρωμένη προσομοίωση σε περιβάλλον παραγωγής συνίστατο στη λειτουργία του συνολικού συστήματος ως ενιαίου, διασυνδεδεμένου αγωγού (pipeline). Ένα περιστατικό, από τη στιγμή της δημιουργίας του από έναν εικονικό χρήστη, διέρχεται αυτόνομα από όλα τα στάδια: την υβριδική ανάκτηση των σχετικών τεχνικών εγγράφων, την τεκμηριωμένη παραγωγή απάντησης από το εξειδικευμένο μοντέλο, την απόφαση κλιμάκωσης βάσει της πολιτικής αποχής, και τελικώς την εγγραφή του αποτελέσματος στην πλατφόρμα Jira. Η ροή αυτή ολοκληρώνεται χωρίς καμία ανθρώπινη παρέμβαση, ενοποιώντας τα τρία στάδια της εργασίας σε ένα ενιαίο λειτουργικό σύστημα.

Η προσομοίωση σε πλήρη κλίμακα κατέδειξε δύο πράγματα:

a) ***Την αξιοπιστία του αγωγού***: το σύστημα διαχειρίστηκε το σύνολο των περιστατικών αυτόνομα, δρομολογώντας ορθά κάθε περιστατικό είτε προς αυτόματη επίλυση είτε προς κλιμάκωση.
b) ***Τη συμπεριφορά***: που είχε μετρηθεί για κάθε συνιστώσα μεμονωμένα διατηρείται όταν όλες οι συνιστώσες λειτουργούν από κοινού σε ρεαλιστικό περιβάλλον.

Η διαπίστωση αυτή αποτελεί την ισχυρότερη ένδειξη ότι το σύστημα δεν συνιστά απλώς μια ακολουθία επιμέρους επικυρωμένων τμημάτων, αλλά ένα συνεκτικό σύνολο του οποίου η συμπεριφορά είναι προβλέψιμη και σταθερή.

Πέραν της λειτουργικής ορθότητας, η ολοκληρωμένη προσομοίωση ανέδειξε και τη σημασία της αρχιτεκτονικής αυτοτέλειας του συστήματος. Το γεγονός ότι το σύνολο των συνιστωσών (η ανάκτηση η παραγωγή, το γλωσσικό μοντέλο και ο πράκτορας ενοποίησης), λειτουργεί εντός μιας ενιαίας, τοπικής διάταξης, χωρίς εξάρτηση από εξωτερικές υπηρεσίες, προσδίδει στο σύστημα δύο ουσιώδεις ιδιότητες:

a) ***την αναπαραγωγιμότητα***, καθώς ολόκληρη η προσομοίωση μπορεί να αναπαραχθεί σε διαφορετικό υπολογιστικό περιβάλλον χωρίς μεταβολές.
b) ***τη διατήρηση του απορρήτου***, καθώς κανένα δεδομένο περιστατικού δεν εξέρχεται του ελεγχόμενου περιβάλλοντος.

Οι ιδιότητες αυτές, αν και δεν αποτελούν αντικείμενο ποσοτικής αξιολόγησης, είναι κρίσιμες για την πρακτική εφαρμογή ενός τέτοιου συστήματος σε πραγματικές συνθήκες.

Το χαρακτηριστικό που επιβεβαιώθηκε κατά την προσομοίωση είναι η ακολουθιακή επεξεργασία των περιστατικών από τον πράκτορα, με κάθε περιστατικό να απαιτεί χρόνο της τάξης ολίγων δευτερολέπτων για την ολοκλήρωση του πλήρους κύκλου ανάκτησης και παραγωγής. Ο ρυθμός αυτός, αν και δεν αποτέλεσε αντικείμενο βελτιστοποίησης στο πλαίσιο της παρούσας εργασίας, κρίνεται επαρκής για έναν μηχανισμό διαλογής πρώτης γραμμής, όπου η αυτόματη διεκπεραίωση ακόμη και με μικρή καθυστέρηση

υπερτερεί σαφώς της αναμονής για ανθρώπινη παρέμβαση, σε ένα παραγωγικό περιβάλλον υψηλού φόρτου.

6.2 Ανάλυση Αποτελεσμάτων, Συμπεράσματα και Μελλοντικές Επεκτάσεις

Η παρούσα εργασία ανέπτυξε ένα αυτόνομο σύστημα επίλυσης περιστατικών τεχνικής υποστήριξης, διαρθρωμένο σε τρία στάδια: την υβριδική ανάκτηση πληροφορίας, την παραγωγή τεκμηριωμένων λύσεων με διδασκόμενη συμπεριφορά αποχής, και την ενσωμάτωση σε αυτόνομο βρόχο διαχείρισης περιστατικών. Το κεντρικό συμπέρασμα της εργασίας είναι ότι η διδασκόμενη συμπεριφορά αποχής (learned abstention), η οποία επιτεύχθηκε μέσω εξειδίκευσης του γλωσσικού μοντέλου, υπερτερεί ουσιωδώς της ευρετικής πύλης εμπιστοσύνης για την ασφαλή επίλυση περιστατικών.

Η υπεροχή αυτή τεκμηριώθηκε ποσοτικά και επί σταθερής βάσης ανάκτησης. Στη διαδοχή βασικού μοντέλου, ευρετικής πύλης και εξειδικευμένου μοντέλου, η ορθή αποχή (C- Abst) αυξήθηκε από 7,1% σε 16,1% και τελικώς σε περίπου 50%, ενώ η επικίνδυνη συμπεριφορά (Hazard) μειώθηκε από 92,9% σε 83,9% και τελικώς σε περίπου 50%, χωρίς υποβάθμιση της πιστότητας. Η στατιστική ανάλυση κατέδειξε ότι η βελτίωση της ευρετικής πύλης δεν ήταν σημαντική, ενώ εκείνη του εξειδικευμένου μοντέλου ήταν αναμφισβήτητη. Η ενσωμάτωση στο Jira επιβεβαίωσε ότι η συμπεριφορά αυτή διατηρείται και σε παραγωγικό περιβάλλον.

Οφείλει, εντούτοις, να επισημανθεί το εναπομείναν όριο του συστήματος. Το ποσοστό hazard της τάξης του 50% σημαίνει ότι περίπου τα μισά από τα περιστατικά για τα οποία δεν ανακτήθηκε η ορθή τεκμηρίωση λαμβάνουν, παρ' όλα αυτά, μια αυτόματη και ενδεχομένως εσφαλμένη απάντηση. Το όριο αυτό οφείλεται κυρίως στο ότι ο έλεγχος πιστότητας δεν μπορεί να ανιχνεύσει απαντήσεις που εδράζονται σε ανακτηθέντα αλλά άσχετα έγγραφα. Παρ' όλα αυτά, το ποσοστό αυτό αντιστοιχεί σε υποδιπλασιασμό έναντι του βασικού μοντέλου (92,9%), γεγονός που τεκμηριώνει την ουσιαστική συνεισφορά της διδασκόμενης αποχής.

Πέραν των τεχνικών αυτών κατευθύνσεων, η παρούσα εργασία αφήνει ανοιχτά ορισμένα ευρύτερα ερωτήματα που άπτονται της αξιόπιστης ανάπτυξης αυτόνομων συστημάτων. Ένα από αυτά αφορά τη δυναμική προσαρμογή της πολιτικής κλιμάκωσης ανάλογα με το κόστος του εκάστοτε πεδίου: σε περιβάλλοντα όπου το κόστος μιας εσφαλμένης λύσης είναι εξαιρετικά υψηλό, το σύστημα θα μπορούσε να ρυθμιστεί ώστε να κλιμακώνει πιο συντηρητικά, θυσιάζοντας μέρος της αυτοματοποίησης προς όφελος της ασφάλειας. Η αντίστροφη ρύθμιση θα ήταν κατάλληλη για περιβάλλοντα χαμηλού διακυβεύματος, όπου η ταχύτητα διεκπεραίωσης υπερτερεί.

Ένα δεύτερο ερώτημα αφορά την αξιολόγηση της ποιότητας των αυτόματων επιλύσεων πέρα από την τυπική παραπομπή στο ορθό έγγραφο. Ενώ η παρούσα εργασία αποτίμησε την ορθότητα μέσω αντικειμενικών, αλγοριθμικά επαληθεύσιμων κριτηρίων, μια πληρέστερη εικόνα θα απαιτούσε την ανθρώπινη αξιολόγηση της πραγματικής χρησιμότητας των παραγόμενων λύσεων από έμπειρους

μηχανικούς. Η ενσωμάτωση μιας τέτοιας ανατροφοδότησης, πέραν της βελτίωσης του μοντέλου, θα επέτρεπε και τη συνεχή παρακολούθηση της απόδοσης του συστήματος σε παραγωγή, κλείνοντας τον βρόχο μεταξύ αυτόματης λειτουργίας και ανθρώπινης εποπτείας.

Αξίζει επίσης να σημειωθεί ότι, αν και η παρούσα υλοποίηση αξιολογήθηκε επί του συνόλου TechQA και των τεχνικών εγγράφων της IBM [7,12,13], η αρχιτεκτονική και η πολιτική αποχής δεν είναι εξαρτημένες από το συγκεκριμένο πεδίο. Η ίδια προσέγγιση θα μπορούσε να εφαρμοστεί σε οποιαδήποτε γνωσιακή βάση τεχνικής τεκμηρίωσης, υπό την προϋπόθεση της ύπαρξης ενός αντίστοιχου συνόλου εκπαίδευσης για την εξειδίκευση της συμπεριφοράς αποχής, γεγονός που καθιστά τη μεθοδολογία μεταφέρσιμη σε ευρύτερα περιβάλλοντα τεχνικής υποστήριξης πέραν του συγκεκριμένου πεδίου εφαρμογής.

Συμπερασματικά, η εργασία κατέδειξε ότι ένα σύστημα ανάκτησης-επαυξημένης παραγωγής, εφοδιασμένο με διδασκόμενη συμπεριφορά αποχής, μπορεί να λειτουργήσει ως αξιόπιστος αυτόνομος πράκτορας τεχνικής υποστήριξης, διεκπεραιώνοντας αυτόματα την πλειονότητα των περιστατικών και κλιμακώνοντας με ασφάλεια τα υπόλοιπα και συνιστά μια αρχή σχεδίασης εφαρμόσιμη σε ένα ευρύ φάσμα αυτόνομων συστημάτων που καλούνται να δράσουν υπό αβεβαιότητα.

Βιβλιογραφία

[1] J. I. Akerele, A. Uzoka, P. U. Ojukwu, J. Olamijuwon, “Reducing IT Service Downtime through Data-Driven Incident Management and Root Cause Analysis”, International Journal Of Engineering Research And Development, vol. 20, no. 11, pp. 1120-1126, 2024.

[2] S. S. Wang, U. Franke, “Enterprise IT service downtime cost and risk transfer in a supply chain”, Operations Management Research, pp. 94-98, 2020.

[3] C. Collins, D. Dennehy, K. Conboy, P. Mikalef “Artificial intelligence in information systems research: A systematic literature review and research agenda”, International Journal of Information Management, pp. 1-17, 2021.

[4] K. Ofosu-Ampong, “Artificial intelligence research: A review on dominant themes, methods, frameworks and future research directions” Telematics and Informatics Reports, pp. 1-17, 2024.

[5] S. 0. Kuyoro, O. Awodele, F. A. Ibikunle and S. B. Abel, “Information Retrieval: An Overview”, International Journal of Advanced Research in Computer Science, vol. 3, no. 4, pp. 334-385, 2009.

[6] S. Robertson and H. Zaragoza, “The Probabilistic Relevance Framework: BM25 and Beyond”, Foundations and Trends in Information Retrieval, vol. 3, no.4, pp. 334-385, 2009.

[7] V. Castelli et al., “The TechQA Dataset”, IBM, 2019.

[8] S. Russel, P. Norvig, Τεχνητή Νοημοσύνη Μια σύγχρονη προσέγγιση, 4η έκδ. Εκδόσεις Κλειδάριθμος, 2021.

[9] P. N. Tan, M. Steinbach, A. Karpatne, V. Kumar, Εισαγωγή στην Εξόρυξη Δεδομένων, 2η έκδ. Εκδόσεις Τζιόλα, 2024.

[10] C. D. Manning, P. Raghavan, H. Schütze, Εισαγωγή στην ανάκτηση πληροφοριών, Εκδόσεις Κλειδάριθμος, 2012.

[11] Λ. Ηλιάδης, Α. Παπαλωνίδας, Υπολογιστική Νοημοσύνη & Ευφυείς Πράκτορες, Εκδόσεις Τζιόλα, 2021.

[12] IBM, “The TechQA dataset”, GitHub. [Online]. Available: GitHub - IBM/techqa: The TechQA dataset -- http://ibm.biz/Tech_QA · GitHub.

[13] R. Jagtap, “tech-qa dataset”, HuggingFace. [Online]. Available: rojagtap/tech-qa · Datasets at Hugging Face.

[14] NVIDIA, “TechQA-RAG-Eval dataset”, HuggingFace. [Online]. Available: nvidia/TechQA-RAG-Eval · Datasets at Hugging Face.

[15] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in Advances in Neural Information Processing Systems (NeurIPS), 2023.

[16] D. Merkel, "Docker: Lightweight Linux containers for consistent development and deployment," Linux Journal, vol. 2014, no. 239, art. 2, 2014.

[17] Ollama, "Ollama: Run large language models locally." [Online]. Available: https://ollama.com.

[18] E. B. Wilson, "Probable inference, the law of succession, and statistical inference," Journal of the American Statistical Association, vol. 22, no. 158, pp. 209–212, 1927.

[19] L. D. Brown, T. T. Cai, and A. DasGupta, "Interval estimation for a binomial proportion," Statistical Science, vol. 16, no. 2, pp. 101–133, 2001.

[20] R. El-Yaniv and Y. Wiener, "On the foundations of noise-free selective classification," Journal of Machine Learning Research, vol. 11, pp. 1605–1641, 2010.

[21] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in Advances in Neural Information Processing Systems (NeurIPS), 2017.

[22] Information Technology Intelligence Consulting (ITIC), "Reliability and Hourly Cost of Downtime Trends Survey," 2017. [Online]. Available: Hourly Downtime Tops $300K for 81% of Firms; 33% of Enterprises Say Downtime Costs >$1M – Information Technology Intelligence Consulting.

[23] L. Ouyang et al. , "Training language models to follow instructions with human feedback", in Advances in Neural Information Processing Systems (NeurIPS), vol. 35, pp. 27730–27744, 2022.

[24] E. Karakurt, A. Akbulut, "Retrieval-Augmented Generation (RAG) and Large Language Models (LLMs) for Enterprise Knowledge Management and Document Automation: A Systematic Literature Review", Applied Sciences, vol. 16, no. 1, Art. no. 368, 2025.

[25] ggml-org, "llama.cpp", GitHub [Online]. Available: llama.cpp/convert_lora_to_gguf.py at master · ggml-org/llama.cpp.

Παράρτημα

Δεδομένης της έκτασης του πηγαίου κώδικα που απαιτήθηκε για την ανάπτυξη της εφαρμογής, η πλήρης ενσωμάτωσή του στο παρόν τεύχος παραλείπεται. Κατά συνέπεια, εντός του κειμένου γίνετε αναφορά σε μερικά τμήματά του. Το σύνολο της υλοποίησης φιλοξενείται σε αποθετήριο της πλατφόρμας GitHub, στο οποίο παρέχεται πρόσβαση μέσω του παρακάτω συνδέσμου. Σημειώνεται πως η εν λόγω πλατφόρμα αποτέλεσε βασικό εργαλείο κατά τη διαδικασία της υλοποίησης, διευκολύνοντας τη διαχείριση, την παρακολούθηση των αλλαγών και τη γενικότερη οργάνωση της Διπλωματικής Εργασίας.

GitHub Repository Link

Παράρτημα Α

Συνάρτηση collect_ground_truth_ids() αρχείου ingest.py

```
def collect_ground_truth_ids(tar) -> set[str]:
    dev_member = next(
        (m for m in tar.getmembers() if m.name.endswith("dev_Q_A.json")), None
    )
    if not dev_member:
        print("WARNING: dev_Q_A.json not found.")
        return set()
    f      = tar.extractfile(dev_member)
    qa_data = json.load(f)
    ids = {item["DOCUMENT"] for item in qa_data
            if item.get("ANSWERABLE") == "Y" and item.get("DOCUMENT")}
    print(f"Ground Truth: {len(ids)} unique IDs.")
    return ids
```

Παράρτημα Β

Notebook δημιουργίας BM25s index και BM25 index pkl (pickle) αρχείου

```
!pip install -q bm25s

import os

# Find the path to the dataset

for root, dirs, files in os.walk('/kaggle/input'):

    for f in files:

        fpath = os.path.join(root, f)

        size  = os.path.getsize(fpath) / (1024**3)

        print(f'{fpath}: {size:.2f} GB')

# -- Path Setup ---------------------------------------------

# Adjust as needed based on the output above

TOKENS_PATH  = '/kaggle/input/datasets/yiannisman/bge-bm25-tokens-testing/bm25_tokens.jsonl'

BM25S_DIR    = '/kaggle/working/bm25s_index'

METADATA_PATH = '/kaggle/working/bm25_index.pkl'


print(f'Tokens file exists: {os.path.exists(TOKENS_PATH)}')

print(f'Size: {os.path.getsize(TOKENS_PATH)/1024**3:.2f} GB')

import json

import pickle

import gc

import bm25s


REPORT_EVERY = 100_000

# -- Step 1: Loading ONLY the tokens ------------------------------

print('Step 1: Loading tokens...')

all_tokens = []

total      = 0


with open(TOKENS_PATH, 'r', encoding='utf-8') as f:

    for line in f:

        record = json.loads(line)
```

```
        all_tokens.append(record['tokens'])
        total += 1
        if total % REPORT_EVERY == 0:
            print(f'  ...{total} loaded tokens')

print(f'{total} documents loaded.')
# -- Step 2: Building BM25 index ----------------
print('Step 2: Building BM25 index...')
retriever = bm25s.BM25()
retriever.index(all_tokens)
del all_tokens
gc.collect()
print('BM25 index was created!')
# -- Step 3: Save index -------------------------------------------
print(f'Step 3: Save index -> {BM25S_DIR}...')
os.makedirs(BM25S_DIR, exist_ok=True)
retriever.save(BM25S_DIR, corpus=None)
del retriever
gc.collect()
print('Index saved!')

# Show files
for fname in os.listdir(BM25S_DIR):
    size = os.path.getsize(os.path.join(BM25S_DIR, fname)) / (1024**2)
    print(f'  {fname}: {size:.1f} MB')
# -- Step 4: Uploading and storing IDs/docs/metas ----------------------
# Now the memory is free of tokens
print('Step 4: Uploading IDs, documents, and metadata...')
all_ids, all_docs, all_metas = [], [], []

with open(TOKENS_PATH, 'r', encoding='utf-8') as f:
    for i, line in enumerate(f):
        record = json.loads(line)
```

```
        all_ids.append(record['id'])
        all_docs.append(record['doc'])
        all_metas.append(record['meta'])
        if (i + 1) % REPORT_EVERY == 0:
            print(f'  ...{i+1} entries')

print(f'Saving metadata -> {METADATA_PATH}...')
with open(METADATA_PATH, 'wb') as f:
    pickle.dump({'ids': all_ids, 'docs': all_docs, 'metas': all_metas}, f)

print(f'Metadata saved!')
size = os.path.getsize(METADATA_PATH) / (1024**3)
print(f'   bm25_index.pkl: {size:.2f} GB')
# -- Output confirmation ------------------------------------------
print('\nFiles output:')
for root, dirs, files in os.walk('/kaggle/working'):
    for fname in files:
        fpath = os.path.join(root, fname)
        size  = os.path.getsize(fpath) / (1024**3)
        print(f'  {fpath}: {size:.3f} GB')

print()
print('='*60)
print('DONE! NEXT STEPS:')
print('1. Output -> Download bm25s_index/ and bm25_index.pkl')
print('2. docker cp bm25s_index knowledge_api:/data/bm25s_index')
print('3. docker cp bm25_index.pkl knowledge_api:/data/bm25_index.pkl')
print('4. docker restart knowledge_api')
print('='*60)
```

Παράρτημα Γ

Notebook δημιουργίας Fine-Tuned Reranker

```
!pip install -q sentence-transformers torch
import json
import random
import os
import torch
from sentence_transformers import CrossEncoder, InputExample
from sentence_transformers.cross_encoder.evaluation import CrossEncoderRerankingEvaluator
from torch.utils.data import DataLoader

print(f'GPU available: {torch.cuda.is_available()}')
if torch.cuda.is_available():
    print(f'GPU: {torch.cuda.get_device_name(0)}')
else:
    print('WARNING: No GPU found!')

random.seed(42)
BASE = '/kaggle/input/datasets/yiannisman/techqa-dataset/TechQA'

TECHNOTES_PATH = f'{BASE}/technote_corpus/full_technote_collection.sections.json'
TRAIN_QA_PATH  = f'{BASE}/training_and_dev/training_Q_A.json'
DEV_QA_PATH    = f'{BASE}/training_and_dev/dev_Q_A.json'
for path in [TECHNOTES_PATH, TRAIN_QA_PATH, DEV_QA_PATH]:
    exists = os.path.exists(path)
    status = 'CHECK' if exists else 'FAIL'
    size   = f'{os.path.getsize(path)/1024/1024:.1f} MB' if exists else 'NOT FOUND'
    print(f'{status} {os.path.basename(path)}: {size}')
print('Loading Technotes...')
technotes = {}

with open(TECHNOTES_PATH, 'r', encoding='utf-8') as f:
```

```
    raw = json.load(f)

for doc_id, doc_data in raw.items():
    technotes[doc_id] = doc_data.get('text', '')

print(f'{len(technotes)} Loaded Technotes.')
def load_qa(path):
    with open(path, 'r', encoding='utf-8') as f:
        return json.load(f)

print('Loading Q&A pairs...')
train_data = load_qa(TRAIN_QA_PATH)
dev_data   = load_qa(DEV_QA_PATH)

all_qa = [
    item for item in train_data + dev_data
    if item.get('ANSWERABLE') == 'Y'
    and item.get('DOCUMENT')
    and item.get('DOCUMENT') in technotes
    and item.get('ANSWER')   # <- ANSWER field needed
    and str(item.get('ANSWER')).strip()  # <- Only if blank
]

print(f'Train questions:              {len(train_data)}')
print(f'Dev questions:                {len(dev_data)}')
print(f'Answerable με valid doc+answer: {len(all_qa)}')
# -- Creation Training Pairs (TRUE V2 - With Answer Context) ----------
NUM_NEGATIVES    = 4
all_technote_ids = list(technotes.keys())
MAX_ANSWER_LEN   = 200  # Κρατάμε μόνο τα πρώτα 200 chars της απάντησης

train_samples = []
skipped       = 0
```

```
for item in all_qa:
    question     = str(item.get('QUESTION_TEXT') or item.get('QUESTION_TITLE') or '').strip()
    answer       = str(item.get('ANSWER', '')).strip()[:MAX_ANSWER_LEN]
    correct_id   = item['DOCUMENT']
    correct_doc  = technotes[correct_id]

    if not question:
        skipped += 1
        continue

    # Συνδυάζουμε question + answer.
    # Έτσι το μοντέλο μαθαίνει να αξιοποιεί το "σκονάκι" του LLM!
    enriched_query = f"{question}\n[Expected answer context]: {answer}"

    # Positive pair
    train_samples.append(InputExample(
        texts=[enriched_query, correct_doc],
        label=1.0
    ))
    # Negative pairs (Τυχαία)
    neg_ids = random.sample(
        [tid for tid in all_technote_ids if tid != correct_id],
        NUM_NEGATIVES
    )
    for neg_id in neg_ids:
        train_samples.append(InputExample(
            texts=[enriched_query, technotes[neg_id]],
            label=0.0
        ))

random.shuffle(train_samples)

valid_q = len(all_qa) - skipped
```

```
print(f'Total training samples: {len(train_samples)}')
print(f'  Positive pairs: {valid_q}')
print(f'  Negative pairs: {valid_q * NUM_NEGATIVES}')
split_idx   = int(len(train_samples) * 0.9)
train_split = train_samples[:split_idx]
val_split   = train_samples[split_idx:]

print(f'Training samples:   {len(train_split)}')
print(f'Validation samples: {len(val_split)}')
MODEL_NAME  = 'cross-encoder/ms-marco-MiniLM-L-6-v2'
OUTPUT_PATH = '/kaggle/working/techqa-reranker-v2'
EPOCHS     = 3
BATCH_SIZE  = 16

print(f'Loading base model: {MODEL_NAME}...')
model = CrossEncoder(MODEL_NAME, num_labels=1, max_length=512)

train_dataloader = DataLoader(train_split, shuffle=True, batch_size=BATCH_SIZE)
warmup_steps     = int(len(train_dataloader) * EPOCHS * 0.1)

print(f'Training steps/epoch: {len(train_dataloader)}')
print(f'Warmup steps:        {warmup_steps}')
print(f'Start fine-tuning για {EPOCHS} epochs...')

model.fit(
    train_dataloader=train_dataloader,
    epochs=EPOCHS,
    warmup_steps=warmup_steps,
    show_progress_bar=True,
    save_best_model=False
)

print(f'\nFine-tuning Completed!')
```

```
print(f'Saving Model -> {OUTPUT_PATH}...')
os.makedirs(OUTPUT_PATH, exist_ok=True)
model.save(OUTPUT_PATH)


print(f'\nFiles:')
for fname in os.listdir(OUTPUT_PATH):
    size = os.path.getsize(os.path.join(OUTPUT_PATH, fname)) / (1024*1024)
    print(f'  {fname}: {size:.1f} MB')
```

Παράρτημα Δ

Τμήμα κώδικα psudo_users.py Φάσης Α

```
for item in qa_data:
    if item.get('ANSWERABLE') != 'Y':
        continue
    if total_tested >= limit:
        break

    raw_text      = item.get('QUESTION_TEXT')
    raw_title     = item.get('QUESTION_TITLE')
    question_text = str(raw_text or raw_title or "No description provided")
    gt_doc_id     = item.get('DOCUMENT')
    qid           = item.get('QUESTION_ID', '?')

    payload = json.dumps({
        "issue_description": question_text,
        "n_results":         request_n,
    }).encode('utf-8')

    req = urllib.request.Request(
        API_URL,
        data=payload,
        headers={'Content-Type': 'application/json'}
    )

    try:
        response = urllib.request.urlopen(req)
        result   = json.loads(response.read().decode('utf-8'))

        suggested_ids = [
            sol.get('technote_id')
            for sol in result.get('suggested_solutions', [])
        ]

        # Top-N accuracy (πρώτες TOP_N θέσεις)
        top_n_ids  = suggested_ids[:TOP_N]
        is_correct = gt_doc_id in top_n_ids
```

```
    # Ακριβής θέση του GT στο συνολικό pool
    try:
        gt_position = suggested_ids.index(gt_doc_id)
    except ValueError:
        gt_position = None

    if is_correct:
        correct_predictions += 1
        status = f"SUCCESS (found at #{gt_position + 1})"
    else:
        status = f"FAILURE - {classify_position(gt_position)}"
```

Παράρτημα Ε

Ενεργοποίηση διαθεσιμότητας GPU

```
class GPUEmbeddingFunction(EmbeddingFunction):
    """
    Custom embedding function που φορτώνει ρητά το SentenceTransformer
    στο GPU αν είναι διαθέσιμο.
    """
    def __init__(self, model_name: str, batch_size: int = 64):
        device = "cuda" if torch.cuda.is_available() else "cpu"
        print(f"[GPUEmbeddingFunction] Loading {model_name} on {device}", flush=True)
        self.model      = SentenceTransformer(model_name, device=device)
        self.device     = device
        self.batch_size = batch_size

    def __call__(self, input: Documents) -> Embeddings:
        embeddings = self.model.encode(
            input,
            batch_size=self.batch_size,
            convert_to_numpy=True,
            show_progress_bar=False,
            normalize_embeddings=True,
        )
        return embeddings.tolist()

# Device για reranker
RERANKER_DEVICE = "cuda" if torch.cuda.is_available() else "cpu"
print(f"[CONFIG] PyTorch device:       {RERANKER_DEVICE}", flush=True)
if RERANKER_DEVICE == "cuda":
    print(f"[CONFIG] GPU:                  {torch.cuda.get_device_name(0)}", flush=True)
```

Παράρτημα ΣΤ

Συνάρτηση extract_technical_tokens() του αρχείου main.py

```
def extract_technical_tokens(text: str) -> set[str]:
    """
    Εξάγει "technical" tokens από το query - αυτά που είναι εξειδικευμένα
    και πιθανότατα εμφανίζονται αυτούσια στο σωστό document:

    - Version numbers (8.1.0.4, 9.0.0.0)
    - APARs & technote IDs (PM50683, swg21138332, IV83315)
    - Error codes (EJPDB0085W)
    - CamelCase identifiers (StaleConnectionException)
    - Acronyms (WAS, DASH, ODM, DVS, RES)
    - Specific command/file names (jextract, nzudxcompile, configmgr)
    - Specific product/tech nouns εκτός των πιο γενικών (datacap, datapower, jdk)
    """
    if not text:
        return set()

    tokens: set[str] = set()

    # Version numbers: 8.1.0.4, 9.0.0.0, v2.0.3
    tokens.update(re.findall(r'\b[vV]?\d+(?:\.\d+){1,4}\b', text))

    # APARs, technote IDs (case-insensitive)
    tokens.update(m.lower() for m in re.findall(
        r'\b(?:swg|nas|isg|ibm)\d{5,}[A-Z]?\b', text, re.IGNORECASE
    ))

    # All-caps code pattern (PM50683, IV83315)
    tokens.update(m.lower() for m in re.findall(
        r'\b[A-Z]{2,}[0-9]{4,}[A-Z]?\b', text
    ))

    # EJP... error codes
    tokens.update(m.lower() for m in re.findall(r'\bEJP[A-Z0-9]+\b', text))

    # CamelCase identifiers
    tokens.update(m.lower() for m in re.findall(
        r'\b[A-Z][a-z]+(?:[A-Z][a-z]+)+\b', text
    ))

    # Acronyms (3-5 uppercase letters)
    tokens.update(m.lower() for m in re.findall(r'\b[A-Z]{3,5}\b', text))

    # snake_case και kebab-case
    tokens.update(re.findall(r'\b[a-z]+(?:_[a-z]+)+\b', text.lower()))
    tokens.update(re.findall(r'\b[a-z]+-[a-z]+(?:-[a-z0-9]+)*\b', text.lower()))

    # Τεχνικά nouns που εμφανίζονται αυτούσια ως product/tool names.
    # Είναι "rare vocabulary" - λέξεις που σπάνια εμφανίζονται σε γενικό κείμενο
    # αλλά είναι signature για specific products/tools.
    text_lower = text.lower()
    rare_nouns = [
```

```
    # Tools / commands
    r'\bjextract\b', r'\bconfigmgr\b', r'\bnzudxcompile\b',
    r'\bupdateinstaller\b', r'\bjavacore\b', r'\bcrypto-export\b',
    # Products (lowercase forms)
    r'\bdatacap\b', r'\bdatapower\b', r'\bwebsphere\b', r'\bnetcool\b',
    r'\bomnibus\b', r'\bteamserver\b', r'\bfilenet\b', r'\bjazz\b',
    r'\btwinfin\b', r'\bfixpack\b', r'\bfixpacks\b', r'\binfocenter\b',
    # Short but critical IBM acronyms (lowercase)
    r'\bwas\b', r'\bodm\b', r'\bdash\b', r'\brad\b', r'\brsa\b',
    r'\bdw\b', r'\bxu\b', r'\bssp\b', r'\bcpe\b', r'\bitm\b',
    r'\bicm\b', r'\bjdk\b', r'\bjre\b', r'\bhsm\b', r'\bgpf\b',
    r'\bdb2\b', r'\bwsp\b', r'\bdvs\b', r'\bres\b', r'\bnoi\b',
    r'\bnoi\b', r'\bgc\b',
]
for pat in rare_nouns:
    if re.search(pat, text_lower):
        tokens.add(pat.strip(r'\b'))

# File paths / commands με slashes
tokens.update(re.findall(
    r'/(?:[a-zA-Z0-9._-]+/){0,4}[a-zA-Z0-9._-]+',
    text
))

# Κανονικοποίηση: lowercase + μήκος
tokens = {t.lower() for t in tokens if len(t) >= MIN_OVERLAP_TOKEN_LEN}

# Αφαίρεση ψεύτικων acronyms που δεν μας λένε κάτι
stop_acronyms = {
    "the", "and", "for", "how", "why", "can", "use", "api", "all",
    "yes", "new", "old", "not", "any", "get", "set", "run", "one",
    "two", "ibm", "but", "now", "has", "our", "was",  # "was" είναι ambiguous
    "gui", "url", "xml", "pdf", "csv", "sql", "fix", "app", "see",
    "error", "info", "warn", "debug", "null", "true", "false",
}
# ΠΡΟΣΟΧΗ: "was" το αφαιρούμε από την blacklist γιατί στον τεχνικό χώρο
# είναι IBM WebSphere Application Server. Αν εμφανίζεται σε context τεχνικό,
# το κρατάμε. Το αφήνουμε στη blacklist παραπάνω και βασιζόμαστε στο
# rare_nouns για το "was" ως acronym.
tokens -= stop_acronyms
# Επιστροφή του "was" αν είχε εντοπιστεί από τα rare_nouns
if re.search(r'\bwas\b', text_lower):
    tokens.add("was")

return tokens
```

Παράρτημα Ζ

Notebook qlora_finetune_llama3 με χρήση του sft dataset

```
# --- Μοντελο & δεδομενα ---

MODEL_NAME   = "NousResearch/Meta-Llama-3-8B-Instruct"   # ungated mirror - ΙΔΙΑ βαρη με το served μοντελο (llama3:8b-instruct)

DATASET_PATH = "/kaggle/input/datasets/yiannisman/sft-dataset/sft_dataset.jsonl"


# --- Output paths ---

OUTPUT_DIR  = "/kaggle/working/llama3-techqa-qlora"

ADAPTER_DIR = "/kaggle/working/adapter"

MERGED_DIR  = "/kaggle/working/merged-fp16"


# --- Ακολουθια ---

MAX_LENGTH  = 4096      # καλυπτει το max μηκος ΧΩΡΙΣ truncation (επαληθευεται στο cell 5)


# --- LoRA ---

LORA_R      = 16

LORA_ALPHA   = 32

LORA_DROPOUT = 0.05


# --- Training ---

EPOCHS     = 3

LR         = 2e-4       # τυπικο QLoRA adapters θελουν υψηλοτερο LR απο full-FT

BATCH      = 1

GRAD_ACCUM = 8          # effective batch = BATCH * GRAD_ACCUM = 8

SEED       = 42

import json

from datasets import Dataset


rows = []

with open(DATASET_PATH, encoding="utf-8") as f:

    for line in f:

        line = line.strip()
```

```
        if line:
            rows.append(json.loads(line))

ABSTAIN = "does not contain a confident solution"
n_b = sum(1 for r in rows if ABSTAIN in r["messages"][-1]["content"])
print("συνολικα παραδειγματα:", len(rows))
print("MODE A (solve):", len(rows) - n_b, " | MODE B (abstain):", n_b,
      f" ({100*n_b/len(rows):.0f}% abstain)")

ds = Dataset.from_list(rows)
split = ds.train_test_split(test_size=0.10, seed=SEED)
train_ds, eval_ds = split["train"], split["test"]
print("\ntrain:", len(train_ds), " | eval:", len(eval_ds))
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
if tokenizer.pad_token is None:
    tokenizer.pad_token = tokenizer.eos_token   # το padding γινεται mask ουτως η αλλως
tokenizer.padding_side = "right"
print("pad:", tokenizer.pad_token, "| eos:", tokenizer.eos_token)
import numpy as np

def _ntok(msgs):
    out = tokenizer.apply_chat_template(msgs, tokenize=True, add_generation_prompt=False)
    ids = out["input_ids"] if isinstance(out, dict) else out   # νεες εκδοσεις επιστρεφουν dict
    return len(ids)

lengths = np.array([_ntok(r["messages"]) for r in rows])
for p in [50, 90, 95, 99, 100]:
    print(f"p{p:<3}: {int(np.percentile(lengths, p)):>5} tokens")

over = int((lengths > MAX_LENGTH).sum())
print(f"\nδειγματα > MAX_LENGTH({MAX_LENGTH}): {over} / {len(lengths)} ({100*over/len(lengths):.1f}%)")
```

```
if over == 0:
    print("OK - κανενα truncation το target μενει ακεραιο σε ολα τα δειγματα.")
else:
    print("[ΠΡΟΣΟΧΗ] καποια δειγματα ξεπερνουν το MAX_LENGTH. Αυξησε το MAX_LENGTH,")
from transformers import AutoModelForCausalLM, BitsAndBytesConfig

bnb_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_compute_dtype=torch.float16,   # T4: float16 (OXI bf16)
    bnb_4bit_use_double_quant=True,
)

model = AutoModelForCausalLM.from_pretrained(
    MODEL_NAME,
    quantization_config=bnb_config,
    device_map={"": 0},       # ολο το μοντελο στη GPU 0 (αποφυγη sharding σε 2×T4)
    dtype=torch.float16,      # transformers 5.x: 'dtype' (οχι 'torch_dtype') - αλλιως φορτωνει bf16
)
model.config.use_cache = False   # απαραιτητο με gradient checkpointing
print("Το μοντελο φορτωθηκε σε 4-bit.")
from peft import LoraConfig

peft_config = LoraConfig(
    r=LORA_R,
    lora_alpha=LORA_ALPHA,
    lora_dropout=LORA_DROPOUT,
    bias="none",
    task_type="CAUSAL_LM",
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj",
                    "gate_proj", "up_proj", "down_proj"],   # ολες οι γραμμικες προβολες
)
from trl import SFTConfig, SFTTrainer
```

```
sft_config = SFTConfig(
    output_dir=OUTPUT_DIR,
    max_length=MAX_LENGTH,
    assistant_only_loss=True,     # loss MONO στο assistant - mask system+user (Llama-3 template auto-patched)
    packing=False,                # ασυμβατο με σταθερο masking
    num_train_epochs=EPOCHS,
    per_device_train_batch_size=BATCH,
    per_device_eval_batch_size=BATCH,
    gradient_accumulation_steps=GRAD_ACCUM,
    learning_rate=LR,
    lr_scheduler_type="cosine",
    warmup_ratio=0.03,
    optim="paged_adamw_8bit",
    fp16=True, bf16=False,        # T4
    gradient_checkpointing=True,
    gradient_checkpointing_kwargs={"use_reentrant": False},
    activation_offloading=True,   # κατεβαζει τα activations στη CPU RAM - εξοικονομηση GPU μνημης (T4 16GB)
    logging_steps=5,
    eval_strategy="epoch",
    save_strategy="epoch",
    load_best_model_at_end=True,
    metric_for_best_model="eval_loss",
    greater_is_better=False,
    save_total_limit=2,
    seed=SEED,
    report_to="none",
)

trainer = SFTTrainer(
    model=model,
    args=sft_config,
    train_dataset=train_ds,
```

```
    eval_dataset=eval_ds,
    peft_config=peft_config,
    processing_class=tokenizer,
)
# Cast trainable (LoRA) params -> fp32 (bulletproof fix για τον fp16 GradScaler στον T4)
n = 0
for _name, p in trainer.model.named_parameters():
    if p.requires_grad and p.dtype != torch.float32:
        p.data = p.data.float()
        n += 1
print(f"cast {n} trainable tensors -> fp32")

# επιβεβαιωση: κανενα trainable param δεν ειναι bf16
bad = [nm for nm, p in trainer.model.named_parameters()
       if p.requires_grad and p.dtype == torch.bfloat16]
assert not bad, f"Υπαρχουν ακομα bf16 trainable params: {bad[:3]}"
print("OK - ολα τα trainable params ειναι fp32.")
trainer.save_model(ADAPTER_DIR)
tokenizer.save_pretrained(ADAPTER_DIR)
print("adapter ->", ADAPTER_DIR)
!ls -lh {ADAPTER_DIR}
import gc, torch
from transformers import AutoModelForCausalLM
from peft import PeftModel

# απελευθερωση μνημης (αν υπαρχουν ακομα απο το training ασφαλες και μετα απο restart)
for _n in ["trainer", "model", "merged", "merged4"]:
    if _n in globals():
        del globals()[_n]
gc.collect()
if torch.cuda.is_available():
    torch.cuda.empty_cache()
```

```
base = AutoModelForCausalLM.from_pretrained(
    MODEL_NAME, dtype=torch.float16, low_cpu_mem_usage=True,
)   # χωρις device_map -> CPU
merged = PeftModel.from_pretrained(base, ADAPTER_DIR)
merged = merged.merge_and_unload()
merged.save_pretrained(MERGED_DIR, safe_serialization=True)
tokenizer.save_pretrained(MERGED_DIR)
print("merged fp16 ->", MERGED_DIR)


del base, merged
gc.collect()
if torch.cuda.is_available():
    torch.cuda.empty_cache()
```

Παράρτημα Η

Υπολογισμός διαστήματος εμπιστοσύνης κατά Wilson σε μορφή κώδικα

```
def wilson_ci(correct, total, z=1.96):
    if total == 0:
        return (0.0, 0.0, 0.0)
    p = correct / total
    denom = 1 + z * z / total
    center = (p + z * z / (2 * total)) / denom
    margin = (z * math.sqrt(p * (1 - p) / total + z * z / (4 * total * total))) / denom
    return (p, max(0.0, center - margin), min(1.0, center + margin))
```

Παράρτημα Θ

Συναρτήσεις cited_ids() και decide() του αρχείου jira_worker.py

```
def cited_ids(answer: str):
    """Αναγνωριστικα technote που επικαλειται η απαντηση."""
    out = []
    for m in CITE_RE.findall(answer or ""):
        if m.lower().startswith(ID_PREFIXES) and m not in out:
            out.append(m)
    return out


def decide(result: dict):
    """Επιστρεφει (escalate: bool, reason: str)."""
    answer  = result.get("answer") or ""
    sources = {s.get("technote_id") for s in (result.get("sources") or [])}

    if ABSTAIN_MARK in answer:
        return True, "MODE B - το μοντέλο δήλωσε αποχή"
    if result.get("gated"):
        return True, "GATE - χαμηλή εμπιστοσύνη ανάκτησης"

    cites = cited_ids(answer)
    if not cites:
        return True, "FAITH - η απάντηση δεν παραπέμπει σε κανένα technote"
    invented = [c for c in cites if c not in sources]
    if invented:
        return True, f"FAITH - επικαλείται ανύπαρκτο αναγνωριστικό: {', '.join(invented[:3])}"
    return False, "AUTO - τεκμηριωμένη λύση"
```